ARVEXA SCHOOL

COURS ULTRA-DÉTAILLÉ · PARTIE 2 SUR 5

Écart-type & Ajustement linéaire

Mesurer la dispersion : variance par les DEUX formules, écart-type, puis premier ajustement : nuage, point moyen G et droite de Mayer.

MATIÈRE	Mathématiques — Terminale D
CHAPITRE	Statistiques
CONTENU	11 sections · 22 pages · chaque notion sur sa page · QCM et exercices corrigés

ARVEXA School — Préparation au BAC, Côte d'Ivoire

Écart-type & Ajustement linéaire

Chapitre 11 · Statistiques — Partie 2 sur 5 · Cours ultra-détaillé

Deux parcelles peuvent afficher la même moyenne et produire l'une régulièrement, l'autre en dents de scie : la variance V et l'écart-type σ mesurent cette différence invisible pour la Partie 1. Puis on passe aux ***séries doubles*** *: la pluie fait-elle le rendement ? On trace le nuage de points, on calcule son point moyen G, et on cherche la droite qui résume le nuage — d'abord « à la main » avec la droite de Mayer, puis par la méthode exacte des* ***moindres carrés****, avec la covariance, les démonstrations complètes (dont celle-ci :* toute droite de régression passe par G*). Ici, rien n'est survolé : chaque notion explique d'abord* pourquoi *elle existe, ensuite* comment *on l'obtient, puis* quand *on l'utilise ; chaque calcul est fait pas à pas. Les 10 parcelles de mil de la Partie 1 restent notre fil rouge, rejointes par 5 parcelles de sorgho.*

25 min **5 notions** **11 sections** **Terminale D**

Table des matières

1 Ce que tu dois retenir de la partie 1 2

2 Motivation — Même moyenne, récoltes différentes 3

3 La variance V 4

4 L'écart-type σ 7

5 Série double, nuage de points et point moyen G 9

6 La droite de Mayer (méthode des deux points moyens) 11

7 Covariance et droite des moindres carrés 13

8 Applications types de la partie 2 17

9 Fiches méthodes de la partie 2 19

10 Exercices d'entraînement de la partie 2 20

11 Table de synthèse de la partie 2 22

1. Ce que tu dois retenir de la partie 1

La Partie 1 a appris à **résumer une liste** par quelques valeurs. Avant d'ajouter de nouveaux outils, resserons l'acquis — tout ce qui suit s'appuie dessus.

Objet	Règle	Fil rouge (mil, t/ha)
Fréquence	$f_i = n_i/N$ avec $\sum f_i = 1$	0,3 pour la valeur 1,2
ECC	« combien d'individus $\leq x_i$ »	5 parcelles $\leq 1{,}2$
Mode	valeur de plus grand effectif	1,2 t/ha
Moyenne	$\bar{x} = \dfrac{\sum n_i x_i}{N} = \sum f_i x_i$	$\bar{x} = \dfrac{13{,}8}{10} = 1{,}38$ t/ha
Médiane	série ordonnée, rangs centraux	$\text{Me} = \dfrac{1{,}2 + 1{,}5}{2} = 1{,}35$ t/ha
Quartiles	seuils $0{,}25N$ et $0{,}75N$ dans les ECC	$Q_1 = 1{,}2$; $Q_3 = 1{,}7$; EI $= 0{,}5$
Étendue	$e = x_{\max} - x_{\min}$	$e = 2{,}0 - 0{,}8 = 1{,}2$

PROPRIÉTÉ — [

Les deux identités qui reviendront sans cesse]

1. $\sum n_i = N$: les effectifs reconstituent l'effectif total (et $\sum f_i = 1$) ;
2. $\sum n_i(x_i - \bar{x}) = 0$: les écarts pondérés à la moyenne se compensent *exactement* — démontré en Partie 1, utilisé dès aujourd'hui comme contrôle de calcul.

ASTUCE — Le pont vers cette partie

Deux lacunes, deux projets. **Lacune 1 :** mode, moyenne et médiane disent *où* est la série, pas *à quel point elle est resserrée* — il faut des indicateurs de **dispersion** (variance, écart-type). **Lacune 2 :** jusqu'ici chaque individu portait *un* nombre ; on veut maintenant en porter **deux** (pluie *et* rendement) — ce sont les **séries doubles**, leurs nuages et leurs droites d'ajustement. Les deux projets occupent cette partie.

2. Motivation — Même moyenne, récoltes différentes

POURQUOI ? — [

Le problème que la Partie 1 ne peut pas résoudre] Deux villages récoltent en moyenne 1,38 t/ha de mil. Dans le premier, les parcelles donnent toutes entre 1,30 et 1,46 : une récolte **prévisible**, rassurante pour les familles. Dans le second, elles oscillent de 0,8 à 2,0 selon les pluies : même moyenne, mais un **risque** bien plus grand — une année peut être presque perdue. La Partie 1 ne voyait rien de cette différence : deux séries de moyennes égales y étaient interchangeables. Il faut un nombre qui mesure « de combien les valeurs s'écartent, en moyenne, de $\bar{x}$ » : ce sera la **variance** V et sa racine, l'**écart-type** σ.

Second fil de la partie. Chaque saison, l'agronome relève aussi la pluviométrie : à chaque parcelle correspondent maintenant **deux nombres** (pluie x_i, rendement y_i). En plaçant les points $M_i(x_i\,;y_i)$ dans le plan, le nuage dessine souvent une tendance — et une tendance rectiligne peut se résumer par une **droite d'ajustement**, capable de prédire : quelle récolte attendre pour telle pluie ? Nous construirons cette droite de deux façons : la droite de Mayer (simple, approximative) puis la droite des moindres carrés (exacte), avec la covariance comme ingrédient central.

Les objectifs de cette partie :

- calculer la variance V et l'écart-type σ, **par les deux formules** ;
- construire un nuage de points et son point moyen $G(\bar{x}\,;\bar{y})$;
- déterminer une droite d'ajustement $y = ax+b$ par Mayer puis par les moindres carrés, et prouver qu'elle passe par G.

3. La variance V

POURQUOI ? — [

Pourquoi élever les écarts au carré ?] L'idée naïve serait de moyenner les écarts $x_i - \bar{x}$... mais on vient de le rappeler : $\sum n_i(x_i - \bar{x}) = 0$ **toujours** — les écarts au-dessus et en dessous se compensent exactement, et la moyenne des écarts est éternellement nulle, pour n'importe quelle série. Aucune information de dispersion ne survit. La parade : **élever au carré**, car un carré est toujours positif — plus aucun écart ne peut se compenser avec un autre. Une série resserrée a de petits carrés, une série éparpillée de grands : la moyenne des carrés des écarts mesure bien la dispersion. (Et le carré a une seconde vertu, que tu verras à la section 7 : il rend les calculs de minimisation possibles.)

DÉFINITION — [

Variance — définition officielle] La **variance** d'une série statistique de moyenne $\bar{x}$ est la moyenne des carrés des écarts à la moyenne :

$$\boxed{V = \frac{\sum n_i(x_i - \bar{x})^2}{N} = \sum f_i(x_i - \bar{x})^2}$$

C'est un nombre **positif**, exprimé dans l'**unité du caractère au carré**. V grande : valeurs très dispersées autour de $\bar{x}$; V petite (proche de 0) : valeurs toutes proches de $\bar{x}$.

COMMENT ON L'OBTIENT ? — [

La seconde formule (König-Huygens) — comment on l'obtient] Développons le carré dans la somme, en distribuant :

$$\begin{aligned}\sum n_i(x_i - \bar{x})^2 &= \sum n_i\left(x_i^2 - 2\bar{x}\,x_i + \bar{x}^2\right)\\ &= \sum n_i x_i^2 \;-\; 2\bar{x}\underbrace{\sum n_i x_i}_{=N\bar{x}} + \bar{x}^2\underbrace{\sum n_i}_{=N}\\ &= \sum n_i x_i^2 \;-\; 2N\bar{x}^2 \;+\; N\bar{x}^2 \;=\; \sum n_i x_i^2 - N\bar{x}^2\end{aligned}$$

En divisant par N :

$$\boxed{V = \frac{\sum n_i x_i^2}{N} - \bar{x}^2}$$

En mots : « **moyenne des carrés moins carré de la moyenne** ». *Pourquoi est-ce utile ?* Aucun écart à calculer : juste des carrés des valeurs — souvent plus rapide à la calculatrice, et moins d'erreurs de signe. Les deux formules donnent *toujours* le même résultat (ce sont deux écritures de la même somme).

Exemple complet n°1 — la variance du fil rouge (par les écarts)

Point de départ : $\bar{x} = 1{,}38$ et $N = 10$ (Partie 1). On prépare le tableau, une colonne par étape :

x_i	n_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$	$n_i(x_i - \bar{x})^2$
0,8	1	−0,58	0,3364	0,3364
0,9	1	−0,48	0,2304	0,2304
1,2	3	−0,18	0,0324	0,0972
1,5	2	0,12	0,0144	0,0288
1,7	1	0,32	0,1024	0,1024
1,8	1	0,42	0,1764	0,1764
2,0	1	0,62	0,3844	0,3844
Σ	10	contrôle : $\sum n_i(x_i - \bar{x}) = 0$		1,3560

Étape 1 — Somme des carrés pondérés : $\sum n_i(x_i - \bar{x})^2 = 1{,}3560$.
Étape 2 — Formule, puis développement :

$$V = \frac{\sum n_i(x_i - \bar{x})^2}{N} = \frac{1{,}3560}{10}$$

Résultat : $\boxed{V = 0{,}1356 \text{ (t/ha)}^2}$
Contrôle (obligatoire) : $\sum n_i(x_i - \bar{x}) = -0{,}58 - 0{,}48 - 0{,}54 + 0{,}24 + 0{,}32 + 0{,}42 + 0{,}62 = 0$ ✓ — si ce n'était pas 0, la moyenne ou un écart serait faux.

Exemple complet n°2 — la même variance par König-Huygens

On reprend les carrés des valeurs, pondérés par les effectifs :

x_i	n_i	x_i^2	$n_i x_i^2$
0,8	1	0,64	0,64
0,9	1	0,81	0,81
1,2	3	1,44	4,32
1,5	2	2,25	4,50
1,7	1	2,89	2,89
1,8	1	3,24	3,24
2,0	1	4,00	4,00
Σ	$N = 10$	—	20,40

Une transformation par ligne :

$$V = \frac{\sum n_i x_i^2}{N} - \bar{x}^2$$
$$V = \frac{20{,}40}{10} - 1{,}38^2$$
$$V = 2{,}04 - 1{,}9044$$

Résultat : $V = 0{,}1356$ — **le même résultat** ✓ (il le fallait : les deux formules sont équivalentes, la démonstration ci-dessus l'établit pour toute série).

ERREUR FRÉQUENTE — Trois pièges classiques de la variance

(1) **Oublier le carré** : diviser $\sum n_i(x_i - \bar{x})$ par N donne 0, pas la variance — le carré est la définition même. (2) **Partir d'une moyenne mal arrondie** : ici $\bar{x} = 1{,}38$ est exact ; garde tous les chiffres pendant les calculs intermédiaires. (3) **Annoncer V en t/ha** : son unité est le $(\text{t/ha})^2$, peu parlant — c'est justement pour cela qu'on introduit σ juste après.

PROPRIÉTÉ — [

Un lemme précieux : où la somme des carrés est-elle minimale ?] Pour des nombres $u_1, \ldots, u_N$ de moyenne $\bar{u}$ et *n'importe quel* réel c :

$$\sum(u_i - c)^2 = \sum(u_i - \bar{u})^2 + N(\bar{u} - c)^2 \;\geq\; \sum(u_i - \bar{u})^2$$

La somme des carrés des écarts est **minimale exactement quand** $c = \bar{u}$. *Démonstration :* écris $u_i - c = (u_i - \bar{u}) + (\bar{u} - c)$, développe le carré : la somme devient $\sum(u_i - \bar{u})^2 + 2(\bar{u} - c)\underbrace{\sum(u_i - \bar{u})}_{=0} + N(\bar{u} - c)^2$ — le terme croisé disparaît (écarts pondérés nuls !) et il reste l'identité annoncée, avec $N(\bar{u} - c)^2 \geq 0$. *Ce lemme est le moteur secret de toute la partie : il choisira l'ordonnée à l'origine de la droite des moindres carrés (section 7).*

À TOI DE JOUER — Variance à toi de jouer

Calcule V et σ... non, d'abord V seule : pour la série 1 ; 2 ; 3 ; 4 ; 5, par les deux formules.

Correction

$\bar{x} = 3$. **Par les écarts :** $V = \frac{(1-3)^2+(2-3)^2+(3-3)^2+(4-3)^2+(5-3)^2}{5} = \frac{4+1+0+1+4}{5} = 2$. **Par König-Huygens :** $\sum x_i^2 = 1+4+9+16+25 = 55$, donc $V = \frac{55}{5} - 9 = 11 - 9 = 2$. ✓ Même résultat, comme promis.

4. L'écart-type σ

POURQUOI ? — [

Pourquoi prendre la racine carrée de la variance ?] La variance du fil rouge vaut 0,1356 **(t/ha)**^{2} : on ne sait pas la lire — personne ne voit ce que signifie « un hectare-hectare par tonne carrée ». En prenant la racine carrée, on revient à l'**unité du caractère** (t/ha) : le nombre obtenu, l'**écart-type** σ, est l'indicateur de dispersion le plus utilisé au monde. Il se lit ainsi : les valeurs s'écartent de la moyenne d'environ σ « en moyenne » — il a donc une interprétation concrète directe, contrairement à V. (D'où vient le symbole ? σ est la lettre grecque « s » de *spread*, l'étalement.)

DÉFINITION — [

Écart-type] L'**écart-type** d'une série de variance V est :

$$\boxed{\sigma = \sqrt{V}}$$

C'est un nombre **positif**, dans la **même unité** que les données. $\sigma \approx 0$: série homogène (valeurs proches de $\bar{x}$) ; σ grand : série dispersée (forte hétérogénéité).

Exemple pas à pas — l'écart-type du fil rouge

Étape 1 — On part de la variance : $\sigma = \sqrt{V} = \sqrt{0{,}1356}$.
Étape 2 — À la calculatrice : $\sigma \approx 0{,}368$; arrondi au centième : $\sigma \approx 0{,}37$.
Étape 3 — **Lecture :** $\boxed{\sigma \approx 0{,}37 \text{ t/ha}}$ — les rendements s'écartent en moyenne d'environ 0,37 t/ha autour de la moyenne 1,38 t/ha : une dispersion modérée, typique d'une saison de pluies irrégulière. *Et l'unité est redevenue parlante.*

Exemple complet — le village régulier (la comparaison qui explique tout)

Un second village donne les rendements 1,30 ; 1,34 ; 1,38 ; 1,42 ; 1,46 (en t/ha).
Étape 1 — Moyenne : $\bar{x} = \frac{1{,}30+1{,}34+1{,}38+1{,}42+1{,}46}{5} = \frac{6{,}90}{5} = 1{,}38$ — **exactement la même moyenne** que le fil rouge.
Étape 2 — Variance, une transformation par ligne :

$$V = \frac{(-0{,}08)^2 + (-0{,}04)^2 + 0^2 + 0{,}04^2 + 0{,}08^2}{5}$$
$$V = \frac{0{,}0064 + 0{,}0016 + 0 + 0{,}0016 + 0{,}0064}{5} = \frac{0{,}016}{5}$$
$$V = 0{,}0032$$

Étape 3 — $\sigma = \sqrt{0{,}0032} \approx 0{,}06$ t/ha : **six fois moins** que le premier village (0,37).
Conclusion : c'est σ, et non $\bar{x}$, qui révèle la différence entre les deux villages — même moyenne, récoltes de nature très différente. ✓

Valeur de σ	Lecture de la série
$\sigma \approx 0$	toutes les valeurs sont proches de $\bar{x}$ — série homogène
σ modéré	dispersion moyenne autour de $\bar{x}$ (ici $0{,}37$ pour une moyenne de $1{,}38$)
σ grand	valeurs très étalées : forte hétérogénéité (risque agricole, inégalité de revenus...)

QUAND L'UTILISER ? — [

Quand calculer σ ?] Signaux de l'énoncé : « comparer la **régularité** de deux séries », « quelle série est la plus **homogène** / la plus dispersée ? », « mesurer le **risque** » (agricole, financier), « préciser la dispersion autour de la moyenne ». Méthode d'examen : si les moyennes sont égales (ou proches), c'est σ qui tranche — calcule les deux σ et conclus par une phrase comparée. Et si l'on demande l'indicateur dans l'unité de la donnée, c'est σ (jamais V).

ERREUR FRÉQUENTE — Racine trop tôt, racine trop tard

Calcule V **exactement** jusqu'au bout, puis seulement $\sigma = \sqrt{V}$. Prendre la racine de chaque écart avant de moyenner est une faute grave (cela donne autre chose que la variance), et arrondir V avant la racine dégrade σ. Ici : $\sqrt{0{,}1356} \approx 0{,}3682$ — si tu arrondis V à $0{,}14$, tu obtiens $0{,}374$: faux au millième près, coûteux en précision.

5. Série double, nuage de points et point moyen G

POURQUOI ? — [

Pourquoi mettre deux caractères sur un dessin ?] Jusqu'ici, chaque parcelle portait un seul nombre. Mais la vraie question de l'agronome est **relationnelle** : la pluie fait-elle le rendement ? Pour voir une relation, il faut porter les deux caractères **en même temps** : chaque individu devient un point $M_i(x_i\,;y_i)$ du plan — x_i pour le premier caractère (explicatif, en abscisse), y_i pour le second (expliqué, en ordonnée). Le dessin obtenu, le **nuage de points**, est souvent parlant avant tout calcul : il monte, il descend, ou il ne dit rien. On aura ensuite besoin du « centre » du nuage — l'analogue bidimensionnel de la moyenne : le point moyen G.

DÉFINITION — [

Série statistique double, nuage, point moyen] Une **série statistique double** associe à chaque individu un couple de valeurs $(x_i\,;y_i)$. Le **nuage de points** est l'ensemble des points $M_i(x_i\,;y_i)$ dans le plan rapporté à un repère. Le **point moyen** G a pour coordonnées la moyenne des x_i et la moyenne des y_i :

$$G\,(\bar{x}\,;\bar{y}) \qquad \text{avec} \qquad \bar{x}=\frac{\sum x_i}{n} \qquad \text{et} \qquad \bar{y}=\frac{\sum y_i}{n}$$

où n est le nombre de points.

Exemple complet — les 5 parcelles de sorgho

On étudie 5 parcelles de sorgho : pour chacune, la pluviométrie de saison x_i (en dm, donc 1 dm = 100 mm) et le rendement y_i (en t/ha) :

Parcelle	Pluie x_i (dm)	Rendement y_i (t/ha)
A	2	5
B	4	8
C	6	9
D	8	12
E	10	16

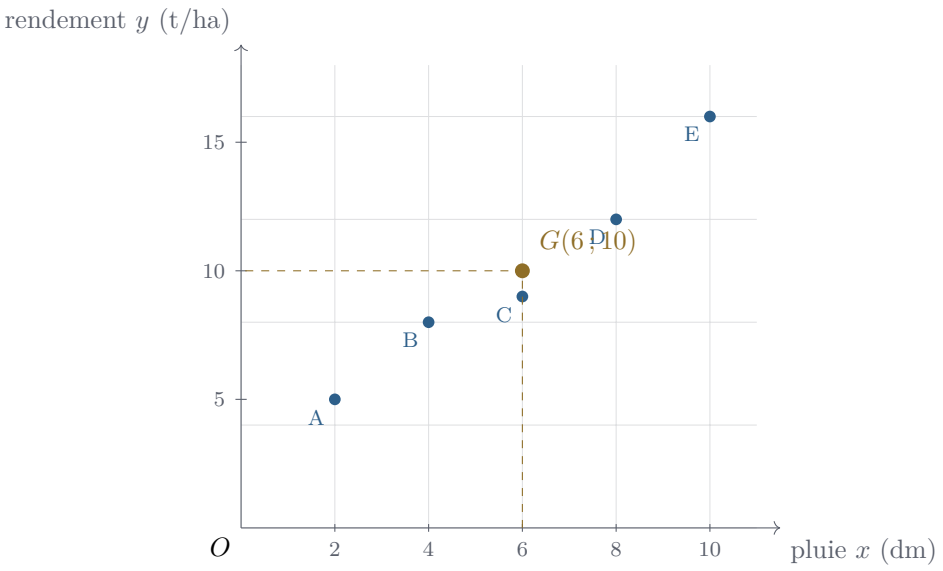
Étape 1 — Moyenne des abscisses, sur sa ligne :

$$\bar{x}=\frac{2+4+6+8+10}{5}=\frac{30}{5}=6$$

Étape 2 — Moyenne des ordonnées, sur sa ligne :

$$\bar{y}=\frac{5+8+9+12+16}{5}=\frac{50}{5}=10$$

Résultat : $\boxed{G(6\,;10)}$ — soit 6 dm de pluie (600 mm), 10 t/ha de sorgho.
Remarque : G n'est pas l'un des points M_i du nuage : c'est normal, c'est le **centre de gravité** du nuage, pas une observation.



ASTUCE — Lire ce nuage

Les cinq points montent : plus il pleut, plus le sorgho rend — et ils sont **presque alignés** : une droite semble pouvoir les résumer. Le point moyen $G(6\,;10)$ siège au cœur du nuage. Les deux sections suivantes construisent la droite — et tu y vérifieras une propriété remarquable : *quelle que soit la méthode, la droite passera par G.*

ERREUR FRÉQUENTE — G se calcule colonne par colonne, jamais ligne par ligne

On moyenne les x_i entre eux et les y_i entre eux. Écrire $\bar{x} = \frac{2+5}{2} + \cdots$ en mélangeant pluie et rendement est une erreur grave : les unités ne sont même pas les mêmes (dm contre t/ha) ! **Réflexe :** dans le tableau, une colonne = une moyenne ; jamais de somme en travers des colonnes.

6. La droite de Mayer (méthode des deux points moyens)

POURQUOI ? — [

Pourquoi une première méthode « à la main » ?] Le nuage de sorgho « monte » presque en ligne droite : une droite peut le résumer. Mais laquelle ? La méthode de Mayer est la plus simple à poser : **couper le nuage en deux**, faire de chaque moitié un *point moyen* (chaque moitié devient « un gros point » placé à son centre de gravité), puis tracer la droite qui joint ces deux points moyens. Chaque moitié est résumée par un seul point — la droite traverse les deux résumés. C'est la méthode qu'on pose à la main sur un graphique, celle qui donne une première idée — avant la méthode exacte de la section 7.

MÉTHODE — [

Droite de Mayer — la recette]

1. **Découper** le nuage en deux groupes de points (usuellement : petites et grandes valeurs de x) ;
2. **Calculer** le point moyen $G_1(\bar{x}_1\,;\bar{y}_1)$ du premier groupe et $G_2(\bar{x}_2\,;\bar{y}_2)$ du second ;
3. **Pente** de la droite (G_1G_2) :

$$a = \frac{\bar{y}_2 - \bar{y}_1}{\bar{x}_2 - \bar{x}_1}$$

4. **Ordonnée à l'origine** avec le point moyen global $G(\bar{x}\,;\bar{y})$: $b = \bar{y} - a\,\bar{x}$ — puis conclure : $y = ax + b$.

Exemple complet — Mayer sur les 5 parcelles de sorgho

Étape 1 — Groupe 1 (pluie faible) : A(2 ; 5), B(4 ; 8), C(6 ; 9). Point moyen, un calcul par ligne :

$$\bar{x}_1 = \frac{2+4+6}{3} = 4 \;;\qquad \bar{y}_1 = \frac{5+8+9}{3} = \frac{22}{3} \approx 7{,}33$$

D'où $G_1\left(4\,;\frac{22}{3}\right)$.

Étape 2 — Groupe 2 (pluie forte) : D(8 ; 12), E(10 ; 16). Point moyen :

$$\bar{x}_2 = \frac{8+10}{2} = 9 \;;\qquad \bar{y}_2 = \frac{12+16}{2} = 14$$

D'où $G_2(9\,;14)$.

Étape 3 — Pente de (G_1G_2), une transformation par ligne :

$$a = \frac{\bar{y}_2 - \bar{y}_1}{\bar{x}_2 - \bar{x}_1} = \frac{14 - \frac{22}{3}}{9-4} = \frac{\frac{20}{3}}{5} = \frac{4}{3}$$

soit $a = \frac{4}{3} \approx 1{,}33$.

Étape 4 — Ordonnée à l'origine via $G(6\,;10)$:

$$b = \bar{y} - a\,\bar{x} = 10 - \frac{4}{3}\times 6 = 10 - 8 = 2$$

Équation finale : $\boxed{y = \frac{4}{3}x + 2 \;\approx\; 1{,}33x + 2}$ — une tendance croissante : plus il pleut, plus le sorgho rend.

COMMENT ON L'OBTIENT ? — [

Pourquoi la droite de Mayer passe toujours par G — la démonstration] Soient n_1 points dans le groupe 1 et n_2 dans le groupe 2 ($n_1 + n_2 = n$). Le point moyen global est la **moyenne des moyennes**, pondérée par les tailles des groupes :

$$\bar{x} = \frac{n_1\bar{x}_1 + n_2\bar{x}_2}{n_1 + n_2} \qquad \text{et} \qquad \bar{y} = \frac{n_1\bar{y}_1 + n_2\bar{y}_2}{n_1 + n_2}$$

Pourquoi ? Additionner les x_i de tous les points, c'est additionner n_1 fois « la moyenne du groupe 1 » et n_2 fois celle du groupe 2. Or le point de coordonnées $\left(\frac{n_1\bar{x}_1+n_2\bar{x}_2}{n_1+n_2} ; \frac{n_1\bar{y}_1+n_2\bar{y}_2}{n_1+n_2}\right)$ est un **barycentre** de G_1 et G_2 (coefficients positifs de somme 1) : il est donc **sur la droite** (G_1G_2). Conclusion : G appartient à la droite de Mayer — c'est pourquoi l'étape 4 peut utiliser G pour trouver b. *Vérification sur le fil rouge :* $G = \frac{3G_1+2G_2}{5} = \left(\frac{3\times4+2\times9}{5} ; \frac{3\times\frac{22}{3}+2\times14}{5}\right) = (6\,;10)$ ✓

QUAND L'UTILISER ? — [

Quand utiliser la droite de Mayer ?] Signaux de l'énoncé : « méthode des **points moyens** », « droite de **Mayer** », ou question guidée qui fait découper le nuage en deux groupes explicites. C'est aussi l'outil des questions « à vue » : quand on te demande une droite *sans* tableau des sommes $\sum x_i^2$, $\sum x_iy_i$, c'est Mayer qu'on attend. Dès que ces sommes sont données (ou demandées), passe aux moindres carrés — et si l'on compare les deux méthodes, dis explicitement que Mayer dépend du découpage, pas la méthode exacte.

ERREUR FRÉQUENTE — Mayer est une méthode approximative

Le résultat **dépend du découpage choisi** : un autre partage des points donnerait une autre droite (ici, couper en $2+3$ au lieu de $3+2$ change le résultat). C'est une droite « à la main », utile pour démarrer — mais l'examen demande presque toujours la méthode exacte, celle des **moindres carrés**, qui ne dépend d'aucun choix. Si l'énoncé dit « droite de Mayer », fais Mayer ; s'il dit « droite de régression » ou « ajustement », c'est la section 7.

7. Covariance et droite des moindres carrés

POURQUOI ? — [

Pourquoi « moindres carrés » ?] On cherche *la* droite qui passe « le plus près possible » de **tous** les points : pour chaque point M_i, on mesure l'écart **vertical** d_i entre le point et la droite candidate $y = ax + b$, on **élève au carré** (pour que les écarts vers le haut et vers le bas ne se compensent pas — même parade qu'à la variance !), on somme : $S = \sum d_i^2$. La droite des moindres carrés est celle qui rend S **minimale** : aucun autre choix de a et b ne fait mieux. Elle ne dépend d'aucun découpage, d'aucun jugement : c'est la droite *optimale* au sens des carrés — et nous allons la calculer explicitement.

DÉFINITION — [

Covariance] Pour une série double de n points (ou pondérée par les effectifs n_i, d'effectif total N), la **covariance** de x et y est :

$$\boxed{\operatorname{cov}(x\,;y) = \frac{\sum x_i y_i}{n} - \bar{x}\,\bar{y} \;=\; \frac{\sum n_i x_i y_i}{N} - \bar{x}\,\bar{y}}$$

C'est la version « croisée » de la variance : moyenne des produits $x_i y_i$ moins produit des moyennes. Son **signe** donne le sens de la liaison : positive ⇒ liaison croissante, négative ⇒ liaison décroissante.

PROPRIÉTÉ — [

L'écriture centrée de la covariance — et son équivalence] La covariance s'écrit aussi avec les écarts aux moyennes :

$$\operatorname{cov}(x\,;y) = \frac{1}{N}\sum n_i (x_i - \bar{x})(y_i - \bar{y})$$

Démonstration. Développons $(x_i - \bar{x})(y_i - \bar{y}) = x_i y_i - \bar{x}\,y_i - \bar{y}\,x_i + \bar{x}\bar{y}$, puis sommons pondéré :

$$\sum n_i x_i y_i - \bar{x}\underbrace{\sum n_i y_i}_{=N\bar{y}} - \bar{y}\underbrace{\sum n_i x_i}_{=N\bar{x}} + N\bar{x}\bar{y} = \sum n_i x_i y_i - N\bar{x}\bar{y}$$

En divisant par N, on retrouve $\frac{\sum n_i x_i y_i}{N} - \bar{x}\bar{y}$: les deux écritures sont **la même quantité**. C'est l'analogue exact de König-Huygens, en croisé.

COMMENT ON L'OBTIENT ? — [

Comment on obtient la droite des moindres carrés — la démonstration complète] On minimise $S(a,b) = \sum (y_i - ax_i - b)^2$ (somme des carrés des écarts verticaux, n points).
Étape 1 — le meilleur b pour un a donné. Pour a fixé, posons $u_i = y_i - ax_i$; alors $S = \sum (u_i - b)^2$. Par le **lemme de la section 3**, cette somme est minimale quand $b = \bar{u} = \bar{y} - a\bar{x}$. Donc, quel que soit a :

$$\boxed{b = \bar{y} - a\,\bar{x}}$$

Première conséquence immédiate : avec ce b, $a\bar{x} + b = a\bar{x} + \bar{y} - a\bar{x} = \bar{y}$: **la droite passe par** $G(\bar{x}\,;\bar{y})$ — pour toute pente, donc pour la pente optimale : toute droite de régression passe par G. ✓

Étape 2 — les écarts se recentrent. Avec $b = \bar{y} - a\bar{x}$, chaque écart s'écrit :

$$y_i - ax_i - b = (y_i - \bar{y}) - a(x_i - \bar{x})$$

donc $S(a) = \sum(y_i - \bar{y})^2 - 2a\sum(x_i - \bar{x})(y_i - \bar{y}) + a^2\sum(x_i - \bar{x})^2$.
Étape 3 — minimiser un trinôme. Notons $A = \dfrac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2}$ (la somme des carrés est > 0 dès que les x_i ne sont pas tous égaux). Par l'identité remarquable $a^2 - 2aA = (a-A)^2 - A^2$:

$$S(a) = \sum(x_i - \bar{x})^2\,(a - A)^2 \;+\; \text{constante}$$

Le minimum est atteint pour $a = A$. **Conclusion :**

$$\boxed{a = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sum(x_i - \bar{x})^2} = \frac{\operatorname{cov}(x\,;y)}{V(x)} \qquad \text{et} \qquad b = \bar{y} - a\,\bar{x}}$$

(la seconde égalité vient des écritures centrées de cov et V : les facteurs $\frac{1}{N}$ se simplifient). La droite $D : y = ax + b$ s'appelle **droite de régression** de y en x (ou droite des moindres carrés).

Exemple complet — la droite des moindres carrés du fil rouge sorgho

Étape 0 — Tableau des sommes utiles :

i	x_i	y_i	x_i^2	y_i^2	x_iy_i
1	2	5	4	25	10
2	4	8	16	64	32
3	6	9	36	81	54
4	8	12	64	144	96
5	10	16	100	256	160
Σ	30	50	220	570	352

Rappels : $\bar{x} = 6$, $\bar{y} = 10$, $n = 5$.
Étape 1 — Covariance, sur sa ligne :

$$\operatorname{cov}(x\,;y) = \frac{352}{5} - 6 \times 10 = 70{,}4 - 60$$

Résultat : $\operatorname{cov}(x\,;y) = 10{,}4$ — positive, comme le nuage croissant.
Étape 2 — Variance de x, sur sa ligne :

$$V(x) = \frac{220}{5} - 6^2 = 44 - 36$$

Résultat : $V(x) = 8$.
Étape 3 — Pente, sur sa ligne :

$$a = \frac{\operatorname{cov}(x\,;y)}{V(x)} = \frac{10{,}4}{8}$$

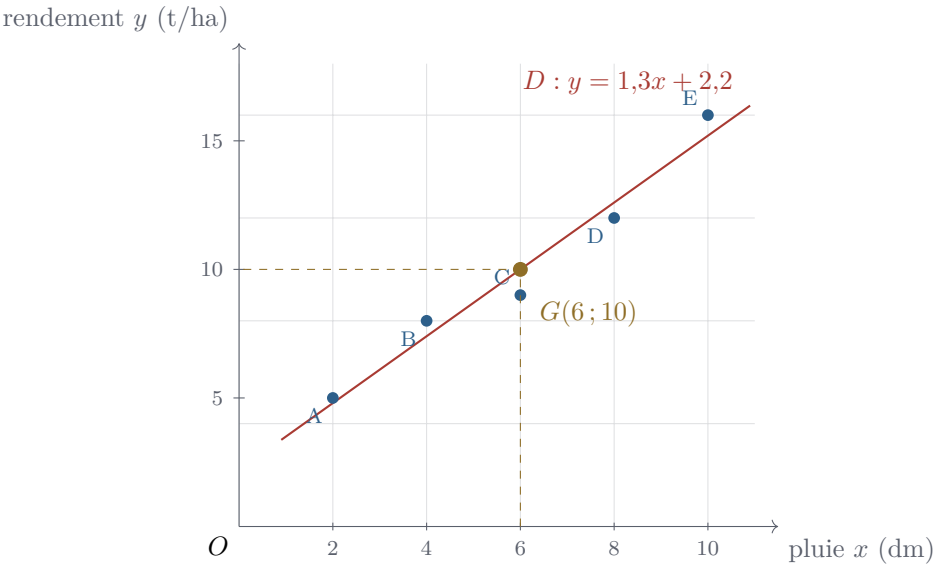
Résultat : $a = 1{,}3$. *Contrôle par la seconde écriture :* $\sum(x_i - \bar{x})(y_i - \bar{y}) = 20+4+0+4+24 = 52$ et $\sum(x_i - \bar{x})^2 = 16 + 4 + 0 + 4 + 16 = 40$, donc $a = \frac{52}{40} = 1{,}3$ ✓
Étape 4 — Ordonnée à l'origine, sur sa ligne :

$$b = \bar{y} - a\,\bar{x} = 10 - 1{,}3 \times 6 = 10 - 7{,}8$$

Résultat : $b = 2{,}2$.
Étape 5 — Équation finale : $\boxed{D : y = 1{,}3x + 2{,}2}$
Étape 6 — Contrôle obligatoire :

$$1{,}3 \times 6 + 2{,}2 = 7{,}8 + 2{,}2 = 10 = \bar{y}\ \checkmark$$

La droite passe bien par $G(6\,;10)$ — sans ce contrôle, une erreur sur a ou b passerait inaperçue. **Lecture concrète :** chaque dm de pluie supplémentaire apporte environ 1,3 t/ha de sorgho (c'est la pente) ; avec 2,2 t/ha « de base » à pluie nulle (c'est b, à interpréter avec prudence hors du domaine observé).



ASTUCE — Sur la figure

La droite $D : y = 1{,}3x + 2{,}2$ résume le nuage des 5 points, et elle passe par le point moyen $G(6\,;10)$: ce n'est pas un hasard du dessin, c'est le théorème démontré plus haut. La Partie 3 mesurera *à quel point* ce résumé est fidèle — avec le coefficient de corrélation r.

ERREUR FRÉQUENTE — Trois confusions à bannir

(1) Le dénominateur de a est $V(x)$, **jamais** $V(y)$: la pente mesure l'effet de x sur y. (2) $\sum x_i y_i$ (produits croisés, terme à terme) n'est **ni** $\sum x_i^2$, **ni** $(\sum x_i)(\sum y_i)$ — ici 352, et non $30 \times 50 = 1500$. (3) Garde **toutes les décimales** pendant les calculs et n'arrondis qu'à la fin : un $\bar{y}$ arrondi trop tôt fausse b.

QUAND L'UTILISER ? — [

Quand utiliser la droite des moindres carrés ?] Signaux de l'énoncé : « ajustement **linéaire** », « droite de **régression** », « droite des **moindres carrés** », « déterminer une droite $y = ax + b$ qui résume le nuage », « **prédire** » (avec la Partie 3). Et dès qu'un tableau donne *deux* colonnes de mesures (pluie/rendement, prix/demande, âge/taille...), le réflexe est : tableau des sommes $(\sum x_i, \sum y_i, \sum x_i^2, \sum x_i y_i) \to G \to a = \frac{\text{cov}}{V(x)} \to b = \bar{y} - a\bar{x} \to$ contrôle $G \in D$.

À TOI DE JOUER — Moindres carrés à toi de jouer

Pour les points $(2\,;5)$, $(6\,;7)$, $(10\,;12)$: calculer G, puis la droite des moindres carrés, et contrôler que G est dessus.

Correction

$G\left(\frac{2+6+10}{3}\,;\frac{5+7+12}{3}\right) = G(6\,;8)$. Sommes : $\sum x_i^2 = 4+36+100 = 140$; $\sum x_i y_i = 10+42+120 = 172$. Donc $\text{cov} = \frac{172}{3} - 6\times 8 = \frac{28}{3} \approx 9{,}33$ et $V(x) = \frac{140}{3} - 36 = \frac{32}{3} \approx 10{,}67$, d'où

$$a = \frac{28/3}{32/3} = \frac{28}{32} = 0{,}875 \ ; \qquad b = 8 - 0{,}875\times 6 = 2{,}75$$

$D : y = 0{,}875x + 2{,}75$. **Contrôle :** $0{,}875\times 6 + 2{,}75 = 5{,}25 + 2{,}75 = 8 = \bar{y}$ ✓ — $G(6\,;8)$ est bien sur D.

8. Applications types de la partie 2

Application type n°1 — comparer deux séries par leur écart-type

Énoncé. Village A (rendements en t/ha) : 9 ; 10 ; 11 ; 10 ; 10. Village B : 6 ; 14 ; 8 ; 12 ; 10. Les deux villages ont-ils la même régularité ?
Étape 1 — Moyennes. $\bar{x}_A = \frac{50}{5} = 10$; $\bar{x}_B = \frac{50}{5} = 10$: **mêmes moyennes** — la moyenne ne peut pas trancher.
Étape 2 — Variances. Village A : écarts $-1\,;0\,;1\,;0\,;0 \to V_A = \frac{1+0+1+0+0}{5} = 0{,}4$. Village B : écarts $-4\,;4\,;-2\,;2\,;0 \to V_B = \frac{16+16+4+4+0}{5} = 8$.
Étape 3 — Écart-types. $\sigma_A = \sqrt{0{,}4} \approx 0{,}63$ t/ha ; $\sigma_B = \sqrt{8} \approx 2{,}83$ t/ha.
Conclusion (rédaction attendue) : les deux villages ont la même moyenne (10 t/ha) mais $\sigma_B \approx 4{,}5 \times \sigma_A$: le village A est **plus homogène** (récolte prévisible), le village B est **dispersé** (risque fort pour les familles). ✓

Application type n°2 — variance avec effectifs, par les deux formules

Énoncé. Série : 2 (3 fois), 4 (5 fois), 6 (2 fois). Calculer $\bar{x}$, puis V et σ par les deux formules.
Étape 1 — Moyenne. $N = 10$; $\sum n_i x_i = 6 + 20 + 12 = 38$, donc $\bar{x} = 3{,}8$.
Étape 2 — Par les écarts. $\sum n_i (x_i - \bar{x})^2 = 3 \times (-1{,}8)^2 + 5 \times (0{,}2)^2 + 2 \times (2{,}2)^2 = 9{,}72 + 0{,}20 + 9{,}68 = 19{,}6$:

$$V = \frac{19{,}6}{10} = 1{,}96$$

Étape 3 — Par König-Huygens. $\sum n_i x_i^2 = 3 \times 4 + 5 \times 16 + 2 \times 36 = 12 + 80 + 72 = 164$:

$$V = \frac{164}{10} - 3{,}8^2 = 16{,}4 - 14{,}44 = 1{,}96 \ \checkmark \text{ — même résultat.}$$

Étape 4 — Écart-type. $\sigma = \sqrt{1{,}96} = 1{,}4$ (exact : $1{,}4^2 = 1{,}96$).
Contrôle des écarts pondérés : $3 \times (-1{,}8) + 5 \times 0{,}2 + 2 \times 2{,}2 = -5{,}4 + 1 + 4{,}4 = 0$ ✓

Application type n°3 — pipeline complet : G, Mayer, moindres carrés

Énoncé. Quatre élèves relèvent leurs heures de révision hebdomadaires x et leur moyenne y (sur 20) : (1 ; 8), (2 ; 10), (3 ; 12), (6 ; 18). Déterminer le point moyen, la droite de Mayer, puis la droite des moindres carrés. Comparer.
a) Point moyen. $\bar{x} = \frac{1+2+3+6}{4} = 3$; $\bar{y} = \frac{8+10+12+18}{4} = 12$: $G(3\,;12)$.
b) Mayer. Groupe 1 : (1 ; 8), (2 ; 10) $\to G_1(1{,}5\,;9)$. Groupe 2 : (3 ; 12), (6 ; 18) $\to G_2(4{,}5\,;15)$. Pente :

$$a = \frac{15 - 9}{4{,}5 - 1{,}5} = \frac{6}{3} = 2$$

et $b = 12 - 2 \times 3 = 6$: droite de Mayer $y = 2x + 6$.
c) Moindres carrés. Sommes : $\sum x_i^2 = 1 + 4 + 9 + 36 = 50$; $\sum x_i y_i = 8 + 20 + 36 + 108 = 172$. Alors :

$$\operatorname{cov}(x\,;y) = \frac{172}{4} - 3 \times 12 = 43 - 36 = 7 \ ; \qquad V(x) = \frac{50}{4} - 9 = 3{,}5$$

$$a = \frac{7}{3{,}5} = 2 \ ; \qquad b = 12 - 2 \times 3 = 6$$

$D : y = 2x + 6$. **Contrôle :** $2 \times 3 + 6 = 12 = \bar{y}$ ✓
d) Comparaison. Ici Mayer et les moindres carrés donnent **la même droite** — cela arrive quand les points sont bien « équilibrés ». Sur le fil rouge sorgho, elles différaient (1,33 contre 1,3) : la méthode exacte reste la référence. ✓

9. Fiches méthodes de la partie 2

MÉTHODE — [

Fiche n°1 — Calculer V et σ (les deux routes)] **Recette :** (1) calculer $\bar{x}$ *exactement* ; (2) route 1 : colonne des écarts $(x_i - \bar{x})$, carrés, produits $n_i(\cdot)^2$, somme, division par N ; route 2 : colonne x_i^2, produits $n_i x_i^2$, somme, division par N, soustraire $\bar{x}^2$; (3) **contrôle** : $\sum n_i(x_i - \bar{x}) = 0$; (4) $\sigma = \sqrt{V}$, arrondi *à la fin* ; (5) conclure avec les unités : V en unité^2, σ en unité.
Exemple : fil rouge — $V = 0{,}1356$ (t/ha)^2 par les deux routes ; $\sigma \approx 0{,}37$ t/ha autour de $\bar{x} = 1{,}38$. ✓

MÉTHODE — [

Fiche n°2 — Droite de Mayer en 4 étapes] **Recette :** (1) découper le nuage en deux groupes (par les x) ; (2) G_1 et G_2 (moyennes colonne par colonne !) ; (3) $a = \frac{\bar{y}_2 - \bar{y}_1}{\bar{x}_2 - \bar{x}_1}$; (4) $b = \bar{y} - a\bar{x}$ avec le point moyen *global* G ; conclure $y = ax + b$.
Exemple : sorgho — $G_1(4\,;\frac{22}{3})$, $G_2(9\,;14)$, $a = \frac{4}{3} \approx 1{,}33$, $b = 2$: $y = \frac{4}{3}x + 2$; et $G(6\,;10) = \frac{3G_1 + 2G_2}{5}$ est sur la droite. ✓

MÉTHODE — [

Fiche n°3 — Droite des moindres carrés en 6 étapes] **Recette :** (1) tableau : x_i, y_i, x_i^2, y_i^2 (pour la Partie 3), $x_i y_i$; totaux en bas ; (2) $\bar{x}$, $\bar{y} \to G$; (3) $\text{cov}(x\,;y) = \frac{\sum x_i y_i}{n} - \bar{x}\bar{y}$; (4) $V(x) = \frac{\sum x_i^2}{n} - \bar{x}^2$; (5) $a = \frac{\text{cov}}{V(x)}$, $b = \bar{y} - a\bar{x}$; (6) **contrôle** : $a\bar{x} + b = \bar{y}$ (la droite passe par G), puis conclure avec une phrase concrète sur la pente.
Exemple : sorgho — cov $= 10{,}4$; $V(x) = 8$; $a = 1{,}3$; $b = 2{,}2$; $D : y = 1{,}3x + 2{,}2$; contrôle $1{,}3 \times 6 + 2{,}2 = 10$ ✓

RÉFLEXE RÉDACTION — Rédaction attendue sur ta copie

Quatre gestes qui rapportent des points : (1) **présenter** le tableau des sommes avec sa ligne Σ ; (2) **écrire chaque formule** avant de la remplacer ($V = \frac{\sum n_i x_i^2}{N} - \bar{x}^2$, puis les valeurs) ; (3) **contrôler** ($\sum n_i(x_i - \bar{x}) = 0$; $G \in D$) ; (4) **conclure avec les unités** et une phrase d'interprétation (« chaque dm de pluie supplémentaire apporte 1,3 t/ha »). Le correcteur cherche ces quatre étapes dans cet ordre.

ASTUCE — Ce que la Partie 3 va construire

Tu sais mesurer une dispersion (V, σ) et résumer un nuage par sa droite (G, moindres carrés). Il reste LA question : à quel point cette droite est-elle **fiable** ? Sur un nuage presque aligné et sur un nuage éparpillé, les moindres carrés donnent toutes les deux une droite... avec une fiabilité radicalement différente. La Partie 3 construit le juge de paix : le **coefficient de corrélation** r — et il ne te manquait que $V(y)$, déjà dans ton tableau.

10. Exercices d'entraînement de la partie 2

10.1 QCM — teste tes réflexes (réponses en bas de page)

1. Pour la série $1\,;\,3$: a) $V=1\,;\,\sigma=1$ b) $V=2\,;\,\sigma=1$ c) $V=1\,;\,\sigma=2$ d) $V=4\,;\,\sigma=2$
2. Le point moyen des points $(1\,;2)$, $(3\,;4)$, $(5\,;6)$ est : a) $G(9\,;12)$ b) $G(3\,;4)$ c) $G(2\,;3)$ d) $G(4{,}5\,;6)$
3. On donne cov $=4$; $V(x)=8$; $\bar{x}=5$; $\bar{y}=9$. La droite de régression est : a) $y=2x-1$ b) $y=0{,}5x+9$ c) $y=0{,}5x+6{,}5$ d) $y=8x-31$
4. Pour toute série statistique, $\sum n_i(x_i-\bar{x})$ vaut : a) 1 b) N c) 0 d) $\bar{x}$
5. Des rendements en t/ha : la variance s'exprime en : a) t/ha b) $(\text{t/ha})^2$ c) sans unité d) t/ha^2
6. Si $V=2{,}25$, alors $\sigma=$ a) 5,06 b) 1,125 c) 0,47 d) 1,5
7. Mayer : $G_1(1\,;2)$, $G_2(4\,;8)$, $G(2{,}5\,;5)$. La droite est : a) $y=2x+1$ b) $y=2x$ c) $y=x+2{,}5$ d) $y=3x$
8. La droite des moindres carrés passe toujours par : a) l'origine b) le premier point du nuage c) le point le plus haut d) $G(\bar{x}\,;\bar{y})$

10.2 Exercices d'application (du plus facile au plus corsé) — solutions détaillées

Exercice 1 — Variance et écart-type, les deux routes

Pour la série $1\,;\,3\,;\,5\,;\,7$: calculer $\bar{x}$, puis V par les deux formules, puis σ.
Solution. $\bar{x}=\frac{1+3+5+7}{4}=4$. **Route 1 (écarts) :** $V=\frac{(1-4)^2+(3-4)^2+(5-4)^2+(7-4)^2}{4}=\frac{9+1+1+9}{4}=5$. **Route 2 (König-Huygens) :** $\sum x_i^2=1+9+25+49=84$, donc $V=\frac{84}{4}-16=21-16=5$ ✓ — même résultat. **Écart-type :** $\sigma=\sqrt{5}\approx 2{,}24$. *Contrôle :* $\sum(x_i-\bar{x})=-3-1+1+3=0$ ✓

Exercice 2 — Variance avec effectifs : comparaison des routes

Série : 2 (3 fois), 4 (5 fois), 6 (2 fois). Reprendre l'application type n°2 en détaillant *pourquoi* les deux routes coïncident.
Solution. $\bar{x}=\frac{38}{10}=3{,}8$. Route 1 : $\sum n_i(x_i-\bar{x})^2=3\times 3{,}24+5\times 0{,}04+2\times 4{,}84=9{,}72+0{,}20+9{,}68=19{,}6$, d'où $V=1{,}96$. Route 2 : $\sum n_i x_i^2=164$, d'où $V=16{,}4-14{,}44=1{,}96$ ✓. *Pourquoi coïncident-elles ?* Parce que König-Huygens n'est pas une approximation mais une *identité* : $\sum n_i(x_i-\bar{x})^2=\sum n_i x_i^2-N\bar{x}^2$ (démontré à la section 3). La route 2 est souvent plus courte : pas d'écarts à calculer. $\sigma=\sqrt{1{,}96}=1{,}4$.

Exercice 3 — Point moyen et lecture du nuage

Relever G pour les points $(2\,;5)$, $(6\,;7)$, $(10\,;12)$, puis dire si le nuage suggère une liaison croissante ou décroissante.
Solution. $\bar{x}=\frac{2+6+10}{3}=6$; $\bar{y}=\frac{5+7+12}{3}=8$: $G(6\,;8)$. Les points montent quand x croît (y passe de 5 à 12 pendant que x passe de 2 à 10) : le nuage suggère une liaison **croissante** — on s'attend donc à une pente $a>0$ et une covariance positive (le calcul de la joubox ci-dessous le confirmera : $a=0{,}875>0$). *Réflexe :* l'œil d'abord (allure du nuage), le calcul ensuite.

Exercice 4 — Liaison décroissante : prix et demande

Un commerçant relève le prix x (en centaines de FCFA) et la quantité demandée y (en sacs) : $(1\,;18)$, $(2\,;16)$, $(3\,;13)$, $(4\,;11)$, $(5\,;7)$. Déterminer la droite des moindres carrés et interpréter le signe de a.

Solution. $\bar{x}=3\,;\ \bar{y}=13 \to G(3\,;13)$. Sommes : $\sum x_i^2=55\,;\ \sum x_iy_i=18+32+39+44+35=168$. Alors :

$$\operatorname{cov}(x\,;y)=\frac{168}{5}-3\times 13=33{,}6-39=-5{,}4\ ;\qquad V(x)=\frac{55}{5}-9=2$$

$$a=\frac{-5{,}4}{2}=-2{,}7\ ;\qquad b=13-(-2{,}7)\times 3=13+8{,}1=21{,}1$$

$D:\ y=-2{,}7x+21{,}1$. **Contrôle :** $-2{,}7\times 3+21{,}1=13=\bar{y}$ ✓. **Interprétation :** $a<0$ (covariance négative) : quand le prix monte d'une centaine de FCFA, la demande baisse d'environ 2,7 sacs — liaison **décroissante**, cohérente avec le nuage descendant.

Exercice 5 (corsé) — Le pipeline complet sur 6 points

Données : $(1\,;10)$, $(2\,;12)$, $(4\,;14)$, $(5\,;16)$, $(7\,;19)$, $(11\,;27)$. **a)** G. **b)** Droite de Mayer (groupes 1-2-4 et 5-7-11). **c)** Droite des moindres carrés + contrôle. **d)** Comparer les deux droites.

Solution a. $\bar{x}=\frac{30}{6}=5\,;\ \bar{y}=\frac{98}{6}=\frac{49}{3}\approx 16{,}33$: $G\left(5\,;\frac{49}{3}\right)$.

Solution b. Groupe 1 : $G_1\left(\frac{1+2+4}{3}\,;\frac{10+12+14}{3}\right)=G_1\left(\frac{7}{3}\,;12\right)$. Groupe 2 : $G_2\left(\frac{23}{3}\,;\frac{62}{3}\right)$. Pente :

$$a=\frac{\frac{62}{3}-12}{\frac{23}{3}-\frac{7}{3}}=\frac{\frac{26}{3}}{\frac{16}{3}}=\frac{13}{8}=1{,}625$$

et $b=\frac{49}{3}-\frac{13}{8}\times 5=\frac{197}{24}\approx 8{,}21$: Mayer donne $y=\frac{13}{8}x+\frac{197}{24}$.

Solution c. Sommes : $\sum x_i^2=216\,;\ \sum x_iy_i=600$. Alors $\operatorname{cov}=\frac{600}{6}-5\times\frac{49}{3}=100-\frac{245}{3}=\frac{55}{3}$ et $V(x)=\frac{216}{6}-25=11$:

$$a=\frac{55/3}{11}=\frac{5}{3}\approx 1{,}67\ ;\qquad b=\frac{49}{3}-\frac{5}{3}\times 5=8$$

$D:y=\frac{5}{3}x+8$. **Contrôle :** $\frac{5}{3}\times 5+8=\frac{25+24}{3}=\frac{49}{3}=\bar{y}$ ✓

Solution d. Mayer donne $a=1{,}625$ et $b\approx 8{,}21$; les moindres carrés $a\approx 1{,}67$ et $b=8$: les deux droites sont **proches mais différentes** — c'est la preuve concrète que Mayer dépend du découpage, tandis que les moindres carrés n'en dépendent pas. À l'examen, c'est la droite c) qui vaut. ✓

Exercice 6 — Une donnée manquante par la covariance

Une série double de 5 points a $\sum x_iy_i=180$, $\bar{x}=4$, $\bar{y}=7$; on sait que $\operatorname{cov}(x\,;y)=2$. Vérifier la cohérence des données, puis calculer $V(x)$ sachant que $a=0{,}5$.

Solution. Cohérence : $\operatorname{cov}=\frac{180}{5}-4\times 7=36-28=8\neq 2$: les données **ne sont pas cohérentes** telles quelles — c'est justement l'usage du contrôle. Avec cov $=8$ (donnée corrigée), la pente $a=\frac{\operatorname{cov}}{V(x)}=0{,}5$ impose :

$$V(x)=\frac{\operatorname{cov}}{a}=\frac{8}{0{,}5}=16$$

Morale : les formules se lisent dans les deux sens — un a connu détermine $V(x)$. ✓

QCM : 1-a 2-b 3-c 4-c 5-b 6-d 7-b 8-d

11. Table de synthèse de la partie 2

Objet	Formule / règle	Ce qu'il faut retenir
Variance (définition)	$V = \dfrac{\sum n_i(x_i-\bar{x})^2}{N} = \sum f_i(x_i-\bar{x})^2$	moyenne des carrés des écarts ; positive ; unité^2
Variance (König-Huygens)	$V = \dfrac{\sum n_i x_i^2}{N} - \bar{x}^2$	« moyenne des carrés − carré de la moyenne » ; identité démontrée
Contrôle écart	$\sum n_i(x_i-\bar{x}) = 0$	sinon, une erreur plus haut
Écart-type	$\sigma = \sqrt{V}$	même unité que les données ; homogène $\Leftrightarrow$ σ petit
Série double	points $M_i(x_i\,;y_i)$; $G(\bar{x}\,;\bar{y})$	moyennes colonne par colonne ; G = centre de gravité
Covariance	$\text{cov} = \dfrac{\sum x_i y_i}{n} - \bar{x}\bar{y}$	signe = sens de la liaison ; écriture centrée équivalente
Mayer	$a = \frac{\bar{y}_2-\bar{y}_1}{\bar{x}_2-\bar{x}_1}$; $b = \bar{y} - a\bar{x}$	simple, approximative ; passe par G (barycentre)
Moindres carrés	$a = \dfrac{\text{cov}(x,y)}{V(x)} = \dfrac{\sum(x_i-\bar{x})(y_i-\bar{y})}{\sum(x_i-\bar{x})^2}$; $b = \bar{y} - a\bar{x}$	méthode exacte ; minimise $\sum d_i^2$; **passe toujours par** G
Fil rouge mil	$V = 0{,}1356$; $\sigma \approx 0{,}37$ t/ha	dispersion modérée autour de 1,38
Fil rouge sorgho	$G(6\,;10)$; $D : y = 1{,}3x + 2{,}2$	cov $= 10{,}4$; $V(x) = 8$; contrôle $G \in D$ ✓

ASTUCE — Cap sur la Partie 3

Le trio nuage–point moyen–droite est monté. Mais une droite, on en trouve toujours une : sur un nuage presque aligné comme sur un nuage éparpillé, les moindres carrés rendent leur verdict... avec une fiabilité très inégale. La Partie 3 construit le nombre qui mesure cette fiabilité — le **coefficient de corrélation** r — et apprend à prédire avec la droite sans dépasser les bornes de la raison : interpolation, extrapolation, et le recours à l'ajustement exponentiel quand le nuage se courbe.