ARVEXA SCHOOL

MATHÉMATIQUES · TERMINALE D

Statistiques

PARTIE 03

Corrélation linéaire

20 min · Partie 3 / 4 · 8 sections

📘 PARTIE 03 · STATISTIQUES

Corrélation *linéaire*

Une droite d'ajustement se trouve toujours — encore faut-il savoir si elle **mérite** de représenter le nuage. Cette partie introduit le juge de paix : le **coefficient de corrélation** r. Cette partie couvre **5 notions** : l'idée de **corrélation**, le **coefficient** r et ses propriétés, l'**interprétation** de ses valeurs, les **prédictions** par la droite (interpolation et extrapolation) et, en bref, le recours à l'**ajustement exponentiel** quand le nuage se courbe.

⏱ 20 min 🧱 5 notions 📊 8 sections 🎓 Terminale D

DANS CETTE PARTIE

5 NOTIONS · 8 SECTIONS

00 Motivation — La droite a-t-elle le droit de prédire ?

01 Notion 1 · correlation — Voir la corrélation sur le nuage

02 Notion 2 · coef_r — Le coefficient de corrélation r

03 Notion 3 · interpretation_r — Interpréter les valeurs de r

04 Notion 2 · coef_r — Calculer r pas à pas

05 Notion 4 · predictions — Interpolation et extrapolation

06 Notion 5 · exponentiel — Limites du linéaire

07 Bilan — L'essentiel de la partie

La droite a-t-elle le droit de prédire ?

En Partie 2, nous avons trouvé

$$D : y = 1{,}3x + 2{,}2$$

pour les 5 parcelles de sorgho. Le service agricole l'utilise pour annoncer la récolte avant la fin des pluies. Mais une question honnête s'impose : les points du nuage sont-ils *vraiment* proches de cette droite ? Sur deux nuages différents — l'un presque aligné, l'autre éparpillé — la méthode des moindres carrés donnerait toutes les deux une droite… avec une fiabilité radicalement différente.

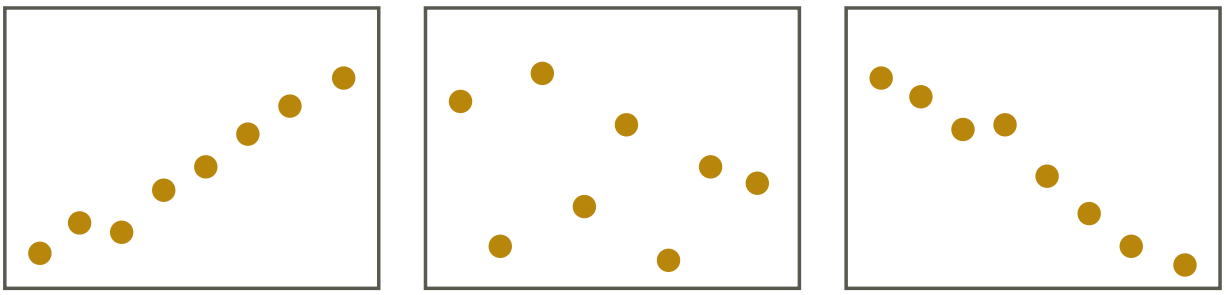
Il faut donc un **nombre** qui mesure à quel point le nuage est « rectiligne ». C'est le **coefficient de corrélation** r, calculé à partir de ce que nous savons déjà : covariance, variances, écart-types. Et son interprétation conditionne tout le reste : peut-on **prédire** avec la droite, et jusqu'où ?

LES OBJECTIFS DE CETTE PARTIE

- **Reconnaître** sur un nuage une corrélation positive, négative ou nulle.
- **Calculer** et **interpréter** le coefficient r sur l'exemple de la Partie 2.
- **Prédire** avec la droite, en distinguant interpolation et extrapolation.

Voir la corrélation sur le nuage

Avant tout calcul, l'œil donne déjà le verdict. Trois allures typiques de nuages :



r ≈ +1 | r ≈ 0 | r ≈ –1

*À gauche, les points montrent une **corrélation positive** (x grand ⇔ y grand) ; au centre, aucune liaison rectiligne (**corrélation quasi nulle**) ; à droite, une **corrélation négative** (x grand ⇔ y petit). Le coefficient r va chiffrer cette impression.*

↗

Corrélation positive

nuage croissant : r > 0 (pluie ↑, rendement ↑)

↘

Corrélation négative

nuage décroissant : r < 0 (prix ↑, demande ↓)

✖

Corrélation nulle

nuage éparpillé : r ≈ 0, aucune droite fiable

📐

Corrélation linéaire

r mesure uniquement la LIAISON RECTILIGNE

Le coefficient de corrélation r

Le coefficient de corrélation relie ce que nous connaissons déjà : la covariance, qui donne le **sens** de la liaison, et les écart-types de x et de y, qui donnent les **échelles**. Leur quotient est un nombre pur, sans unité, toujours compris entre −1 et 1.

📗 DÉFINITION OFFICIELLE — COEFFICIENT DE CORRÉLATION

Pour une série double $(x_i ; y_i)$, le **coefficient de corrélation linéaire** est :

$$r = \text{cov}(x, y) / (\sigma_x \cdot \sigma_y)$$

où

$$\sigma_x = \sqrt{V(x)}$$

et

$$\sigma_y = \sqrt{V(y)}$$

sont les écart-types des deux séries. C'est un nombre sans unité.

LA FORMULE DU COEFFICIENT DE CORRÉLATION

$$r = \text{cov}(x, y) / (\sigma_x \cdot \sigma_y)$$

Tous les ingrédients sont déjà connus : cov(x, y) et V(x) viennent du calcul de la droite ; il ne manque que V(y), l'écart-type de y.

$$-1 \leq r \leq 1$$

Propriété fondamentale : r est toujours entre −1 et 1. r ≈ 1 : points presque alignés sur une droite croissante ; r ≈ −1 : alignés sur une droite décroissante ; r ≈ 0 : aucune liaison rectiligne.

|r| ≥ 0,9 ⇒ ajustement linéaire justifié

Critère d'usage (convention usuelle) : si la valeur absolue de r atteint 0,9, les points sont suffisamment proches d'une droite pour qu'on l'utilise — et on la justifie ainsi à l'examen.

signe de r = signe de a = signe de cov(x, y)

r et la pente a ont toujours le même signe, car $a = r \cdot \sigma_Y / \sigma_X$ avec $\sigma_Y / \sigma_X > 0$. Nuage croissant → a > 0 et r > 0.

⚠️ **R NE MESURE QUE LA LIAISON RECTILIGNE**

Un r proche de 0 ne prouve pas « aucune relation » : des points parfaitement posés sur une parabole ont r ≈ 0 alors que la liaison est parfaite… mais courbe ! r juge uniquement l'alignement rectiligne. Et attention : r n'a **pas d'unité** — ne jamais écrire « r = 0,98 t/ha ».

03 NOTION 3 · INTERPRETATION_R

Interpréter les valeurs de r

Voici la grille de lecture usuelle — à connaître et à citer correctement à l'examen. On travaille toujours sur |r| pour la **force**, puis sur le **signe** pour le **sens**.

VALEUR DE $\lvert r \rvert$	FORCE DE LA LIAISON	CONCLUSION PRATIQUE
$0{,}9 \leq \lvert r \rvert \leq 1$	très forte	nuage presque aligné : ajustement linéaire **justifié**, prédictions fiables
$0{,}7 \leq \lvert r \rvert < 0{,}9$	forte	tendance nette mais points plus dispersés : prudence sur les prédictions
$0{,}5 \leq \lvert r \rvert < 0{,}7$	modérée	liaison réelle mais faible : la droite ne résume qu'une partie du phénomène
$\lvert r \rvert < 0{,}5$	faible	aucun ajustement linéaire sérieux : ne pas prédire avec la droite
$\lvert r \rvert \approx 0$	nulle	aucune liaison rectiligne : le nuage ne suit aucune tendance droite

💡 LA PHRASE D'EXAMEN À CONNAÎTRE

« Comme

$$\lvert r \rvert \approx 0{,}98 \geq 0{,}9,$$

la corrélation est très forte et l'ajustement linéaire du nuage par la droite D est justifié. » Une telle phrase, appuyée par le calcul de r, valide tout l'exercice de statistiques.

⚠️ DES SEUILS, PAS DES LOIS

Le seuil 0,9 est une **convention** de travail (certains ouvrages utilisent 0,8). Cite-la comme telle : « selon la convention usuelle ». Et souviens-toi qu'un r fort ne dit **rien** sur la cause — voir la section 06.

Calculer r pas à pas

Reprenons l'exemple de la Partie 2 : les 5 parcelles de sorgho (2 ; 5), (4 ; 8), (6 ; 9), (8 ; 12), (10 ; 16). On y a déjà calculé : $\bar{x} = 6$, $\bar{y} = 10$,

$$\text{cov}(x, y) = 10{,}4,$$

$$V(x) = 8,$$

et la droite

$$D : y = 1{,}3x + 2{,}2.$$

Il ne manque que V(y).

EXEMPLE COMPLET — LE COEFFICIENT R DU NUAGE DE SORGHO

Il nous faut V(y) : on dresse le tableau de calcul des carrés y_i^2 :

ORDONNÉE Y_i	CARRÉ Y_i^2
5	25
8	64
9	81
12	144
16	256
Σ	**570**

1. La somme des carrés vaut 570.

2. **Variance de y**, une transformation par ligne :

$$V(y) = (\Sigma\, y_i^2) / 5 - \bar{y}^2$$

$$V(y) = 570 / 5 - 10^2$$

$$V(y) = 114 - 100$$

Résultat sur sa propre ligne :

$$V(y) = 14.$$

3 **Écart-types**, un calcul par ligne :

$\sigma_x = \sqrt{V(x)}$

$\sigma_x = \sqrt{8} \approx 2{,}83$

$\sigma_y = \sqrt{V(y)}$

$\sigma_y = \sqrt{14} \approx 3{,}74$

4 On applique la formule, une transformation par ligne :

$r = \text{cov}(x, y) / (\sigma_x \cdot \sigma_y)$

$r = 10{,}4 / (\sqrt{8} \times \sqrt{14})$

5 Au dénominateur :

$\sqrt{8} \times \sqrt{14} = \sqrt{112} \approx 10{,}58.$

6 Le résultat final, sur sa propre ligne :

$r \approx 10{,}4 / 10{,}58 \approx 0{,}98$

7 Force :

$|r| = 0{,}98 \geq 0{,}9$

— corrélation très forte, **l'ajustement linéaire est justifié**.

8 Signe : r > 0 et

$a = 1{,}3 > 0$

— même signe ✓, cohérent avec le nuage croissant.

9 **Contrôle de cohérence** :

$r \times (\sigma y/\sigma x) \approx 0{,}98 \times (3{,}74/2{,}83) \approx 1{,}3$

— on retrouve la pente a = 1,3 ✓ (lien $a = r \cdot \sigma y/\sigma x$).

9 Cohérence supplémentaire, une transformation par ligne :

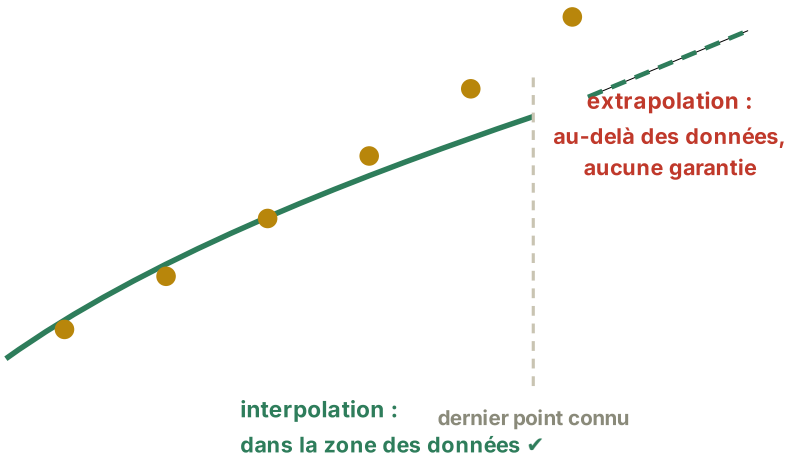
$a = r \cdot \sigma_y / \sigma_x$

$a \approx 0{,}98 \times 3{,}74 / 2{,}83$

$a \approx 1{,}3$ ✓ — on retrouve la pente de la Partie 2.

ERREUR FRÉQUENTE AU BAC

Ne prends pas la racine carrée trop tôt ni trop tard : calcule cov, V(x), V(y) **exactement**, passe aux écart-types seulement à l'étape finale, et n'arrondis qu'à la fin. Arrondir σ_y à 0,1 près avant de diviser peut faire sortir r du bon ordre de grandeur — et te coûter la conclusion.



Interpolation et extrapolation : prédire entre les points connus est raisonnable ; au-delà du dernier point, la tendance peut s'inverser — aucune garantie.

05 NOTION 4 · PREDICTIONS

Prédire avec la droite : interpolation et extrapolation

La droite

D : y = 1,3x + 2,2

est maintenant validée (r ≈ 0,98). Elle permet de **prédire** un rendement pour une pluviométrie donnée — mais la fiabilité dépend de la **position** de la valeur de x par rapport aux données observées.

📗 DÉFINITIONS — INTERPOLATION ET EXTRAPOLATION

— **Interpolation** : prédire pour une valeur de x **à l'intérieur** du domaine observé — fiable, car la tendance y est bien établie.

— **Extrapolation** : prédire pour une valeur de x **à l'extérieur** du domaine observé — risquée, car rien ne garantit que la tendance continue.

EXEMPLE COMPLET — PRÉDICTIONS DE RENDEMENT

1 Rappel des unités : x est en dm et

$$1 \text{ dm} = 100 \text{ mm} ;$$

les pluies observées vont de 2 à 10 dm (200 à 1 000 mm).

2 **Prévision pour 600 mm** :

$$600 \text{ mm} = 6 \text{ dm},$$

donc x = 6 — valeur bien dans le domaine observé.

3 On remplace dans la droite, une transformation par ligne :

$$y = 1{,}3 \times 6 + 2{,}2$$

$$y = 7{,}8 + 2{,}2$$

Résultat sur sa propre ligne :

$$y = 10{,}0.$$

4 **Rendement prévu : 10,0 t/ha**. On remarque qu'on retrouve $\bar{y} = 10$: normal, car

$$x = 6 = \bar{x}$$

et la droite passe par G(6 ; 10) — un contrôle de cohérence apprécié des correcteurs.

5 **Interpolation** pour 500 mm (x = 5, dedans) :

$$y = 1{,}3 \times 5 + 2{,}2$$

$$y = 6{,}5 + 2{,}2$$

Résultat :

$$y = 8{,}7 \text{ t/ha}$$

— prévision fiable.

6 **Extrapolation** pour 1 200 mm (x = 12, dehors) :

$$y = 1{,}3 \times 12 + 2{,}2$$

$$y = 15{,}6 + 2{,}2$$

Résultat :

$$y = 17{,}8 \text{ t/ha}$$

— calcul possible mais **prudence** : au-delà du domaine observé, le sol peut être saturé, les maladies se développer… la tendance peut changer.

7 **Contrôle final.** Avant de conclure, on revérifie que le point moyen G(x̄ ; ȳ) appartient bien à la droite

$y = ax + b$:

$a \cdot \bar{x} + b = \bar{y}$

✓. Sans ce contrôle, une erreur de calcul sur a ou b passerait inaperçue.

ERREUR FRÉQUENTE AU BAC

Une prédiction par la droite se rédige toujours en trois temps : (1) rappeler que l'ajustement est justifié ($|r| \geq 0{,}9$) ; (2) remplacer x par sa valeur et calculer y ; (3) préciser **interpolation** ou **extrapolation** avec la prudence qui s'impose. Omettre le point 3 fait perdre les points d'interprétation.

06 NOTION 5 · EXPONENTIEL

Limites du linéaire : causalité et nuages courbes

⚠ CORRÉLATION N'EST PAS CAUSALITÉ

Un r fort prouve que les deux séries **varient ensemble**, pas que l'une **cause** l'autre. Exemple classique : les ventes de glaces et le nombre de noyades sont fortement corrélés… parce qu'une **variable cachée**, la chaleur, fait monter les deux. Pour le sorgho, l'explication agronomique (l'eau fait pousser le mil et le sorgho) rend la liaison crédible — mais c'est un raisonnement *extérieur* aux statistiques.

Autre limite : la droite ne convient qu'à un nuage **rectiligne**. Si le nuage s'incurve — c'est typique des phénomènes de **croissance** (population d'une ville, effet de l'engrais qui sature) — le coefficient r baisse alors même que la liaison est évidente. La solution classique : rendre le nuage rectiligne en changeant d'échelle.

🧠 MÉTHODE — AJUSTEMENT EXPONENTIEL (APERÇU)

- On **pose**

$$Z = \ln y :$$

on étudie la série double $(x_i ; Z_i)$.

- Si les points $(x_i ; Z_i)$ sont presque alignés, on ajuste **linéairement** :

$$Z = a \cdot x + b.$$

- On revient à y en composant par l'exponentielle :

$$y = e^{(a \cdot x + b)} = e^b \times e^{(a \cdot x)}$$

— un modèle de **croissance exponentielle**.

🌍 PETITE HISTOIRE DES SCIENCES

C'est en étudiant la taille des parents et celle de leurs enfants que Francis Galton remarque, vers 1886, que les enfants de parents très grands sont en moyenne un peu moins grands qu'eux : il nomme ce phénomène « régression vers la moyenne ». Le mot **régression** est depuis resté collé à la droite des moindres carrés — et on parle aujourd'hui de « régression linéaire » dans tous les logiciels de statistique.

L'essentiel de la partie

Le trio est complet : le nuage montre, la droite résume, et r **juge**. Avec

$r \approx 0{,}98$,

notre droite

$y = 1{,}3x + 2{,}2$

a le droit de prédire — à l'intérieur du domaine observé.

LE COEFFICIENT DE CORRÉLATION EN UNE LIGNE

$$-1 \leq r \leq 1$$

$$|r| \geq 0{,}9 \rightarrow \text{ajustement justifié}$$

$$\text{signe de } r = \text{signe de } a$$

Fil rouge : $r = 10{,}4 / (\sqrt{8} \times \sqrt{14}) \approx 0{,}98$ — corrélation très forte, droite fiable pour interpoler, prudence pour extrapoler.

Allures de nuage : croissant ($r > 0$), décroissant ($r < 0$), éparpillé ($r \approx 0$).

Formule : $r = \text{cov}(x, y) / (\sigma_x \cdot \sigma_y)$ — sans unité, toujours entre −1 et 1.

Critère d'usage : $|r| \geq 0,9$ justifie l'ajustement linéaire ; la force se lit sur $|r|$, le sens sur le signe.

Calcul de r : il ne manque jamais que $V(y)$ — tout le reste (cov, $V(x)$) est déjà là depuis la droite.

Prédictions : interpolation (dedans, fiable) vs extrapolation (dehors, risquée) — toujours préciser laquelle.

Limites : corrélation ≠ causalité ; nuage courbe → poser $Z = \ln y$ et ajuster $y = e^b \times e^{(a \cdot x)}$.

EXERCICES D'APPLICATION

Exercice 1

Pour un nuage de points, on trouve r = −0,95. Que conclure ?

CORRECTION

Ajustement linéaire justifié, avec pente négative. $|r| = 0,95 \geq 0,9$: corrélation très forte. Le signe négatif donne le sens : le nuage est décroissant, donc $a < 0$. (A confond force et sens.)

Exercice 2

On donne cov(x,y) = 3 ; σ_x = 2 ; σ_y = 1,5. Le coefficient r vaut :

CORRECTION

1. Le calcul, une transformation par ligne :

$$r = \text{cov}(x, y) / (\sigma_x \cdot \sigma_y)$$

$$r = 3 / (2 \times 1{,}5)$$

$$r = 3 / 3 = 1$$

Les points seraient parfaitement alignés sur une droite croissante (cas limite).

Exercice 3

Avec D : y = 0,8x + 1 ajustée sur des données où x ∈ [2 ; 10], prédire y pour x = 25 est :

CORRECTION

Une extrapolation risquée. x = 25 est loin du domaine observé [2 ; 10] : le calcul donne y = 0,8 × 25 + 1 = 21, mais rien ne prouve que la tendance rectiligne persiste si loin. On précise toujours ce risque.

📌 **CE QU'IL FAUT RETENIR**

- ✓ **[correlation]** Nuage croissant → r > 0 ; décroissant → r < 0 ; éparpillé → r ≈ 0 — l'œil d'abord, le calcul ensuite

- ✓ **[coef_r]** r = cov(x,y)/($\sigma_x \cdot \sigma_y$) avec σ_x = √V(x) et σ_y = √V(y) — nombre sans unité, $-1 \leq r \leq 1$
- ✓ **[coef_r]** signe de r = signe de a = signe de cov(x,y) — car a = $r \cdot \sigma_y / \sigma_x$
- ✓ **[coef_r]** Fil rouge : V(y) = 14, $\sigma_x \approx 2{,}83$, $\sigma_y \approx 3{,}74$, $r \approx 10{,}4/10{,}58 \approx 0{,}98$
- ✓ **[interpretation_r]** $|r| \geq 0{,}9$ → ajustement linéaire justifié (convention usuelle) ; les seuils 0,9 / 0,7 / 0,5 classent la force de la liaison
- ✓ **[interpretation_r]** r ne mesure que la liaison RECTILIGNE : un nuage en parabole parfaite a $r \approx 0$
- ✓ **[predictions]** Interpolation = prédiction à l'intérieur du domaine observé (fiable) ; extrapolation = à l'extérieur (risquée)
- ✓ **[predictions]** Rédaction : justifier par r, calculer y = ax + b, préciser interpolation ou extrapolation
- ✓ **[exponentiel]** Corrélation ≠ causalité : une variable cachée peut expliquer un r fort
- ✓ **[exponentiel]** Nuage courbe : poser Z = ln y, ajuster Z = a·x + b, conclure y = e^b × e^(a·x)

🎯

Partie 3 terminée !

Passe à la dernière partie : la fiche complète de révision du chapitre