ARVEXA SCHOOL

COURS ULTRA-DÉTAILLÉ · PARTIE 3 SUR 5

Corrélation linéaire

Voir et mesurer le lien entre deux grandeurs : le coefficient de corrélation r, sa grille de lecture, le calcul pas à pas, interpolation et extrapolation.

MATIÈRE	Mathématiques — Terminale D
CHAPITRE	Statistiques
CONTENU	13 sections · 23 pages · chaque notion sur sa page · QCM et exercices corrigés

ARVEXA School — Préparation au BAC, Côte d'Ivoire

Corrélation linéaire

Chapitre 11 · Statistiques — Partie 3 sur 5 · Cours ultra-détaillé

Une droite d'ajustement se trouve toujours — encore faut-il savoir si elle ***mérite*** *de représenter le nuage. Cette partie construit le juge de paix : le* ***coefficient de corrélation*** r*, un nombre sans unité, toujours entre* -1 *et* 1*, qui mesure à quel point un nuage est « rectiligne ». Nous verrons pourquoi il est toujours compris entre* -1 *et* 1 *(démonstration complète), comment l'interpréter avec la grille des seuils* $0{,}9$ */* $0{,}7$ */* $0{,}5$*, comment le calculer pas à pas sur le nuage de sorgho de la Partie 2, puis comment prédire avec la droite en distinguant* ***interpolation*** *(fiable) et* ***extrapolation*** *(risquée). Enfin : les limites du linéaire — corrélation n'est pas causalité — et le recours à l'****ajustement exponentiel*** *quand le nuage se courbe. Ici, rien n'est survolé : chaque notion explique d'abord* pourquoi *elle existe, ensuite* comment *on l'obtient, puis* quand *on l'utilise ; chaque calcul est fait pas à pas.*

20 min **5 notions** **13 sections** **Terminale D**

Table des matières

1 Ce que tu dois retenir de la partie 2 2

2 Motivation — La droite a-t-elle le droit de prédire ? 3

3 Voir la corrélation sur le nuage 4

4 Le coefficient de corrélation r : définition et propriétés 5

5 Interpréter les valeurs de r : la grille des seuils 7

6 Calculer r pas à pas — le fil rouge de la Partie 2 9

7 Prédire avec la droite : interpolation et extrapolation 11

8 Limites du linéaire : causalité, nuages courbes 13

9 Applications types de la partie 3 15

10 Fiches méthodes de la partie 3 17

11 Exercices d'entraînement de la partie 3 18

12 Pour aller plus loin : le coefficient de détermination r^2 22

13 Table de synthèse de la partie 3 23

1. Ce que tu dois retenir de la partie 2

La Partie 2 a appris à **mesurer une dispersion** (V, σ) et à **résumer un nuage** par sa droite. Avant de juger cette droite, resserons l'acquis — tout ce qui suit s'appuie dessus.

Objet	Règle	Fil rouge (sorgho)
Variance	$V = \dfrac{\sum n_i(x_i-\bar{x})^2}{N} = \dfrac{\sum n_i x_i^2}{N} - \bar{x}^2$	$V(x) = 8$ pour la pluie
Écart-type	$\sigma = \sqrt{V}$	$\sigma_x = \sqrt{8} \approx 2{,}83$
Point moyen	$G(\bar{x}\,;\bar{y})$, moyennes colonne par colonne	$G(6\,;10)$
Covariance	$\mathrm{cov}(x\,;y) = \dfrac{\sum x_i y_i}{n} - \bar{x}\bar{y}$	$\mathrm{cov}(x\,;y) = 10{,}4 > 0$
Moindres carrés	$a = \dfrac{\mathrm{cov}(x\,;y)}{V(x)}\,;\quad b = \bar{y} - a\bar{x}$	$D : y = 1{,}3x + 2{,}2$
Contrôle	$a\bar{x} + b = \bar{y}$ (la droite passe par G)	$1{,}3 \times 6 + 2{,}2 = 10$ ✓

PROPRIÉTÉ — [

L'identité qui gouverne toute la partie] La somme minimale des carrés des écarts verticaux (atteinte par la droite des moindres carrés) vaut

$$S_{\min} \;=\; \sum (y_i - a x_i - b)^2 \;=\; N\,V(y) - a^2\,N\,V(x)$$

Pourquoi ? Par le lemme de la Partie 2, le meilleur b recentre les écarts : $S_{\min} = \sum(y_i-\bar{y})^2 - a^2\sum(x_i-\bar{x})^2$, c'est-à-dire $NV(y) - a^2 NV(x)$. Cette quantité est **toujours positive**... et elle va nous donner $|r| \le 1$ en deux lignes (section 4). Sur le fil rouge : $S_{\min} = 5\times 14 - 1{,}3^2 \times 5 \times 8 = 70 - 67{,}6 = 2{,}4$ — la droite D laisse un résidu total de 2,4 (t/ha)^2 : très petit, signe d'un bon ajustement.

ASTUCE — Le pont vers cette partie

Deux questions, deux projets. **Question 1 :** la droite D résume-t-elle *fidèlement* le nuage ? Sur un nuage presque aligné et sur un nuage éparpillé, les moindres carrés donnent toutes les deux une droite — avec une fiabilité radicalement différente. Il faut un **nombre qui mesure** cette fidélité : le coefficient de corrélation r. **Question 2 :** une fois la droite jugée fiable, *comment* l'utiliser pour prédire, et *jusqu'où* ? Réponses : r (sections 4 à 6), puis interpolation et extrapolation (section 7).

2. Motivation — La droite a-t-elle le droit de prédire ?

POURQUOI ? — [

Le problème que la Partie 2 ne peut pas résoudre] En Partie 2, nous avons trouvé $D : y = 1{,}3x + 2{,}2$ pour les 5 parcelles de sorgho, et le service agricole s'en sert pour **annoncer la récolte** avant la fin des pluies. Mais une question honnête s'impose : les points du nuage sont-ils *vraiment* proches de cette droite ? Imagine deux nuages : l'un presque aligné, l'autre éparpillé comme une tir de chevrotine. La méthode des moindres carrés donnerait **une droite pour les deux** — la méthode ne refuse jamais de travailler ! — mais avec une fiabilité radicalement différente. Il faut donc un nombre qui mesure à quel point le nuage est « rectiligne » : un *juge*. C'est le coefficient de corrélation r, calculé à partir de ce que nous savons déjà : covariance, variances, écart-types. Son interprétation conditionne tout le reste : peut-on prédire avec la droite, et jusqu'où ?

Les objectifs de cette partie :

- reconnaître sur un nuage une corrélation positive, négative ou nulle ;
- calculer et interpréter le coefficient r sur l'exemple de la Partie 2 ;
- prédire avec la droite, en distinguant interpolation et extrapolation ;
- connaître les limites : corrélation $\neq$ causalité, nuages courbes, ajustement exponentiel.

3. Voir la corrélation sur le nuage

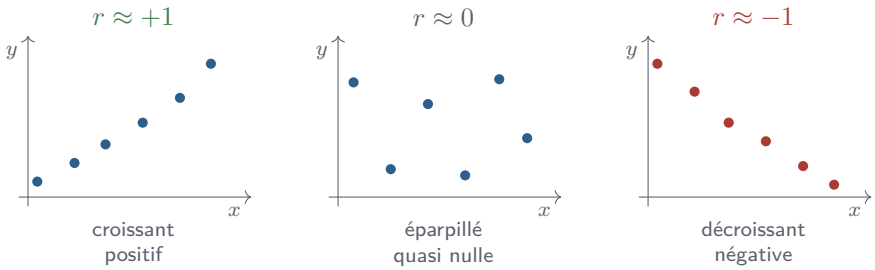
Avant tout calcul, l'œil donne déjà le verdict. Reconnaissez les trois allures typiques d'un nuage de points :

DÉFINITION — [

Corrélation positive, négative, nulle — d'abord à l'œil]

- **Corrélation positive** : le nuage est **croissant** — x grand $\Leftrightarrow$ y grand (pluie ↑, rendement ↑). On attend $r > 0$.
- **Corrélation négative** : le nuage est **décroissant** — x grand $\Leftrightarrow$ y petit (prix ↑, demande ↓). On attend $r < 0$.
- **Corrélation quasi nulle** : le nuage est **éparpillé**, aucune tendance droite visible. On attend $r \approx 0$.

r ne mesure que la **liaison rectiligne** : c'est un juge d'alignement, rien d'autre.



ASTUCE — La méthode en deux temps

Temps 1 — l'œil : le nuage monte, descend, ou ne dit rien ? Cela prévoit déjà le *signe* de r et de la pente a. **Temps 2 — le calcul :** r chiffre la *force* de la liaison que l'œil a repérée. Un exercice d'examen demande presque toujours les deux dans cet ordre : « Allure du nuage, puis calcul de r et conclusion. » Ne saute jamais le temps 1 : c'est lui qui te protège des erreurs de calcul (un r positif sur un nuage descendant est forcément suspect).

4. Le coefficient de corrélation r : définition et propriétés

DÉFINITION — [

Coefficient de corrélation linéaire] Pour une série double $(x_i\,;y_i)$, le **coefficient de corrélation linéaire** est :

$$\boxed{r=\frac{\operatorname{cov}(x\,;y)}{\sigma_x\,\sigma_y}=\frac{\operatorname{cov}(x\,;y)}{\sqrt{V(x)}\,\sqrt{V(y)}}}$$

où $\sigma_x=\sqrt{V(x)}$ et $\sigma_y=\sqrt{V(y)}$ sont les écart-types des deux séries. C'est un **nombre sans unité**, toujours compris entre -1 et 1.

POURQUOI ? — [

Pourquoi diviser par les écart-types ?] La covariance donne déjà le *sens* de la liaison (positive ou négative) — mais pas sa *force comparable* : elle dépend des unités. Calcule la pluie en mm au lieu de dm : les nombres deviennent cent fois plus grands, la covariance aussi, alors que la liaison n'a pas changé d'un poil ! En divisant par $\sigma_x\sigma_y$, on **normalise** : chaque série est ramenée à son échelle propre, et le quotient devient un **nombre pur**, identique quelle que soit l'unité choisie. C'est ce qui permet de comparer la force d'une liaison pluie/rendement avec celle d'une liaison prix/demande — deux études qui n'ont a priori rien en commun.

COMMENT ON L'OBTIENT ? — [

Comment on l'obtient à partir du tableau de la Partie 2] Tous les ingrédients sont déjà connus depuis le calcul de la droite : $\operatorname{cov}(x\,;y)$ et $V(x)$ viennent des colonnes $\sum x_iy_i$ et $\sum x_i^2$. Il ne manque qu'**une seule** quantité nouvelle : $V(y)$, obtenue avec la colonne $\sum y_i^2$ (que la fiche de la Partie 2 faisait déjà calculer « pour la Partie 3 » !). La recette complète :

1. $V(y)=\dfrac{\sum y_i^2}{n}-\bar{y}^2$ (seule nouvelle colonne à calculer) ;
2. $\sigma_x=\sqrt{V(x)}$ et $\sigma_y=\sqrt{V(y)}$ (racines en **dernière** étape) ;
3. $r=\dfrac{\operatorname{cov}(x\,;y)}{\sigma_x\sigma_y}$ (quotient final, sans unité).

PROPRIÉTÉ — [

Propriété fondamentale : $-1\le r\le 1$] Pour toute série double : $\boxed{-1\le r\le 1}$, avec $\operatorname{cov}^2\le V(x)\,V(y)$. Et r atteint les bornes exactement quand les points sont **parfaitement alignés** : $r=1$ sur une droite croissante, $r=-1$ sur une droite décroissante. $r\approx 1$: points presque alignés sur une droite croissante ; $r\approx -1$: alignés sur une droite décroissante ; $r\approx 0$: aucune liaison rectiligne.

COMMENT ON L'OBTIENT ? — [

Pourquoi $|r| \leq 1$ — la démonstration complète] Reprenons la somme minimale de la section 2 : $S_{\min} = N\,V(y) - a^2\,N\,V(x)$, avec $a = \dfrac{\text{cov}}{V(x)}$. Remplaçons :

$$S_{\min} = N\,V(y) \;-\; \frac{\text{cov}^2}{V(x)^2}\,N\,V(x) \;=\; N\,V(y) - N\,\frac{\text{cov}^2}{V(x)}$$

$$= \;N\,V(y)\left(1 - \frac{\text{cov}^2}{V(x)\,V(y)}\right) \;=\; N\,V(y)\,\left(1 - r^2\right)$$

Or une somme de carrés est **toujours positive**, et $N\,V(y) > 0$ dès que les y_i ne sont pas tous égaux : donc $1 - r^2 \geq 0$, c'est-à-dire $r^2 \leq 1$, d'où $|r| \leq 1$. *Contrôle sur le fil rouge :* $S_{\min} = 5 \times 14 \times (1 - r^2) \approx 5 \times 14 \times 0{,}034 \approx 2{,}4$ ✓ — on retrouve la valeur de la section 2. La démonstration tient en une ligne parce que la Partie 2 a tout préparé : c'est le lemme de la somme minimale qui, appliqué à la droite, *impose* la borne.

PROPRIÉTÉ — [

Même signe pour r et pour a] r et la pente a ont **toujours le même signe** :

$$a = r \cdot \frac{\sigma_y}{\sigma_x} \qquad (\text{donc } \text{signe}(r) = \text{signe}(a) = \text{signe}\,\text{cov}(x\,;y))$$

Pourquoi ? $a = \dfrac{\text{cov}}{V(x)} = \dfrac{\text{cov}}{\sigma_x^2} = \dfrac{\text{cov}}{\sigma_x\,\sigma_y} \cdot \dfrac{\sigma_y}{\sigma_x} = r\,\dfrac{\sigma_y}{\sigma_x}$, et le facteur $\frac{\sigma_y}{\sigma_x}$ est **strictement positif** : il ne peut pas changer le signe. Nuage croissant $\Rightarrow a > 0$ et $r > 0$ — l'œil, la pente et le coefficient racontent la même histoire.

PROPRIÉTÉ — [

Critère d'usage : $|r| \geq 0{,}9$ justifie l'ajustement linéaire] **Convention usuelle :** si $|r| \geq 0{,}9$, les points sont suffisamment proches d'une droite pour qu'on l'utilise — c'est la phrase qui **justifie** l'ajustement linéaire à l'examen. On travaille sur $|r|$ pour la *force*, sur le signe pour le *sens*.

ERREUR FRÉQUENTE — r n'a pas d'unité — et ne juge que le rectiligne

Deux fautes à bannir. (1) **Écrire « $r = 0{,}98$ t/ha »** : r est un quotient de deux produits d'écart-types, les unités se simplifient — r est un nombre *pur*, comme un cosinus. (2) **Croire qu'un $r \approx 0$ prouve « aucune relation »** : des points parfaitement posés sur une *parabole* ont $r \approx 0$ alors que la liaison est parfaite... mais courbe ! r juge uniquement l'alignement *rectiligne* — la section 8 en fait un exercice complet.

QUAND L'UTILISER ? — [

Quand calculer r ?] Signaux de l'énoncé : « montrer que l'ajustement linéaire est **justifié** », « calculer le **coefficient de corrélation** », « la droite est-elle **fiable** / **représentative** du nuage ? », « peut-on **prédire** ? ». Le réflexe complet : tableau des sommes → G → droite des moindres carrés → $V(y)$ → r → phrase de conclusion avec $|r|$. Note bien l'ordre : on calcule *d'abord* la droite, *ensuite* r — jamais l'inverse, car tout ce qu'il faut pour r est déjà là.

5. Interpréter les valeurs de r : la grille des seuils

Voici la grille de lecture usuelle — à connaître et à citer correctement. On travaille toujours sur $|r|$ pour la **force**, puis sur le signe pour le **sens**.

Valeur de $\lvert r\rvert$	Force	Conclusion pratique
$0{,}9 \leq \lvert r\rvert \leq 1$	très forte	nuage presque aligné : ajustement linéaire **justifié**, prédictions fiables
$0{,}7 \leq \lvert r\rvert < 0{,}9$	forte	tendance nette mais points plus dispersés : prudence sur les prédictions
$0{,}5 \leq \lvert r\rvert < 0{,}7$	modérée	liaison réelle mais faible : la droite ne résume qu'une partie du phénomène
$\lvert r\rvert < 0{,}5$	faible	aucun ajustement linéaire sérieux : **ne pas prédire** avec la droite
$\lvert r\rvert \approx 0$	nulle	aucune liaison rectiligne : le nuage ne suit aucune tendance droite

RÉFLEXE RÉDACTION — La phrase d'examen à connaître par cœur

« Comme $|r| \approx 0{,}98 \geq 0{,}9$, la corrélation est **très forte** et l'ajustement linéaire du nuage par la droite D est **justifié**. » Une telle phrase, appuyée par le calcul de r, valide tout l'exercice de statistiques. Complète-la si besoin par le sens : « de plus, $r > 0$: la liaison est croissante, cohérente avec le nuage. »

ASTUCE — Des seuils, pas des lois

Le seuil 0,9 est une **convention de travail** (certains ouvrages utilisent 0,8) : cite-la comme telle (« selon la convention usuelle »). Et souviens-toi qu'un r fort ne dit *rien* sur la cause — voir la section 8. Dans ta copie, donne toujours la valeur de r *puis* la comparaison au seuil : le correcteur cherche les deux.

À TOI DE JOUER — Juger trois liaisons

On donne cov $= 2$, $\sigma_x = 2$, $\sigma_y = 3$. Calculer r, puis conclure : l'ajustement linéaire est-il justifié ? Quelle est la force de la liaison ?

Correction

Calcul, une transformation par ligne :

$$r = \frac{\text{cov}(x\,;y)}{\sigma_x\,\sigma_y} = \frac{2}{2\times 3}$$

Résultat : $r = \dfrac{2}{6} = \dfrac{1}{3} \approx 0{,}33$. **Conclusion :** $|r| = 0{,}33 < 0{,}5$ — corrélation **faible** : aucun ajustement linéaire sérieux, on ne prédira pas avec la droite. *Remarque :* $r > 0$ dit seulement que la tendance, si faible soit-elle, est *croissante* — force et sens sont deux questions distinctes. ✓

ERREUR FRÉQUENTE — Arrondir les écart-types trop tôt

Ne prends pas la racine carrée trop tôt ni trop tard : calcule cov, $V(x)$, $V(y)$ **exactement**, passe aux écart-types seulement à l'étape finale, et n'arrondis qu'à la fin. Exemple concret sur le fil rouge : en arrondissant σ_y à 3,7 au lieu de 3,74, on trouve $r = \frac{10{,}4}{2{,}83 \times 3{,}7} \approx 0{,}99$ au lieu de 0,98 — et un arrondi plus grossier peut faire changer la *catégorie* de la grille. La conclusion (« ajustement justifié ») vaut des points : ne la compromets pas par une étourderie d'arrondi.

6. Calculer r pas à pas — le fil rouge de la Partie 2

Reprenons les 5 parcelles de sorgho : $(2\,;5)$, $(4\,;8)$, $(6\,;9)$, $(8\,;12)$, $(10\,;16)$. On y a déjà calculé : $\bar{x}=6$, $\bar{y}=10$, $\text{cov}(x\,;y)=10{,}4$, $V(x)=8$, et la droite $D : y=1{,}3x+2{,}2$. Il ne manque que $V(y)$.

MÉTHODE — [

Calculer r — la recette en 6 étapes]

1. **Rappeler** ce qui est déjà calculé : $\bar{x}$, $\bar{y}$, $\text{cov}(x\,;y)$, $V(x)$ (Partie 2) ;
2. **Compléter** le tableau avec la colonne y_i^2, puis sommer : $\sum y_i^2$;
3. **Calculer** $V(y)=\dfrac{\sum y_i^2}{n}-\bar{y}^2$ (forme de König-Huygens) ;
4. **Racines** : $\sigma_x=\sqrt{V(x)}$ et $\sigma_y=\sqrt{V(y)}$ (arrondir *ici* seulement) ;
5. **Quotient** : $r=\dfrac{\text{cov}(x\,;y)}{\sigma_x\,\sigma_y}$ — nombre sans unité ;
6. **Conclure** : force ($|r|$ comparé à 0,9), sens (signe), et contrôle de cohérence $a=r\,\sigma_y/\sigma_x$.

Exemple complet — le coefficient r du nuage de sorgho

Étape 2 — Il nous faut $V(y)$: on dresse le tableau des carrés :

i	Ordonnée y_i	Carré y_i^2
1	5	25
2	8	64
3	9	81
4	12	144
5	16	256
Σ	50	570

Étape 3 — La somme des carrés vaut 570. Variance de y, une transformation par ligne :

$$V(y)=\frac{\sum y_i^2}{5}-\bar{y}^2$$
$$V(y)=\frac{570}{5}-10^2=114-100$$

Résultat sur sa propre ligne : $V(y)=14$ (en $(\text{t/ha})^2$).

Étape 4 — Écart-types, un calcul par ligne :

$$\sigma_x=\sqrt{V(x)}=\sqrt{8}\approx 2{,}83\ ;\qquad \sigma_y=\sqrt{V(y)}=\sqrt{14}\approx 3{,}74$$

Au dénominateur : $\sqrt{8}\times\sqrt{14}=\sqrt{112}\approx 10{,}58$.

Étape 5 — On applique la formule, une transformation par ligne :

$$r=\frac{\text{cov}(x\,;y)}{\sigma_x\,\sigma_y}=\frac{10{,}4}{\sqrt{8}\times\sqrt{14}}=\frac{10{,}4}{10{,}58}$$

Résultat : $\boxed{r\approx 0{,}98}$

Étape 6 — Conclusions et contrôles :

- **Force :** $|r| = 0{,}98 \geq 0{,}9$ — corrélation **très forte**, l'ajustement linéaire est **justifié** ;
- **Sens :** $r > 0$ et $a = 1{,}3 > 0$ — même signe ✓, cohérent avec le nuage croissant ;
- **Cohérence :** $a = r \cdot \dfrac{\sigma_y}{\sigma_x} \approx 0{,}98 \times \dfrac{3{,}74}{2{,}83} \approx 1{,}3$ ✓ — on retrouve exactement la pente de la Partie 2.

ASTUCE — Pourquoi ce contrôle $a = r\,\sigma_y/\sigma_x$ est en or

Il relie les deux moitiés du calcul : si ta droite (Partie 2) et ton r (Partie 3) sont justes, la formule doit les recoller au millième près. Une divergence signale une erreur dans l'un des deux calculs — autant la trouver avant le correcteur. Et à l'examen, cette ligne de contrôle prouve que tu *comprends* les formules, pas seulement que tu les appliques.

7. Prédire avec la droite : interpolation et extrapolation

La droite $D : y = 1{,}3x + 2{,}2$ est maintenant validée ($r \approx 0{,}98$). Elle permet de prédire un rendement pour une pluviométrie donnée — mais la fiabilité dépend de la position de la valeur de x par rapport aux données observées.

DÉFINITION — [

Interpolation et extrapolation]

- **Interpolation** : prédire pour une valeur de x **à l'intérieur** du domaine observé $[x_{\min}\,;x_{\max}]$ — fiable, car la tendance y est bien établie par les données.
- **Extrapolation** : prédire pour une valeur de x **à l'extérieur** du domaine observé — risquée, car rien ne garantit que la tendance rectiligne continue au-delà.

Sur le fil rouge : pluies observées de 2 à 10 dm (200 à 1 000 mm). Prédire pour 600 mm : interpolation. Pour 1 200 mm : extrapolation.

POURQUOI ? — [

Pourquoi l'interpolation est fiable et l'extrapolation risquée] Dans le domaine observé, la droite est *encadrée* par les données : si elle mentait, on le verrait sur les points eux-mêmes (et r le dirait). En dehors, personne ne nous protège : le sol peut être **saturé** (trop de pluie noie les racines), les maladies se développer, un facteur caché changer la donne. La tendance $y = 1{,}3x + 2{,}2$ est un *modèle*, pas une loi physique : extrapoler, c'est parier que le modèle survit hors de la zone où il a été éprouvé. On le fait *parfois* (prévision de campagne), mais en le disant toujours — la prudence fait partie de la réponse.

Exemple complet — prédictions de rendement

Étape 1 — Rappel des unités : x est en dm et 1 dm = 100 mm ; les pluies observées vont de 2 à 10 dm (200 à 1 000 mm).
Étape 2 — Prévision pour 600 mm : 600 mm = 6 dm, donc $x = 6$ — valeur bien dans le domaine observé. On remplace dans la droite, une transformation par ligne :

$$y = 1{,}3 \times 6 + 2{,}2$$

$$y = 7{,}8 + 2{,}2$$

Résultat sur sa propre ligne : $y = 10{,}0$. **Rendement prévu : 10,0 t/ha.** On remarque qu'on retrouve $\bar{y} = 10$: normal, car $x = 6 = \bar{x}$ et la droite passe par $G(6\,;10)$ — un contrôle de cohérence apprécié des correcteurs.
Étape 3 — Interpolation pour 500 mm ($x = 5$, dedans) :

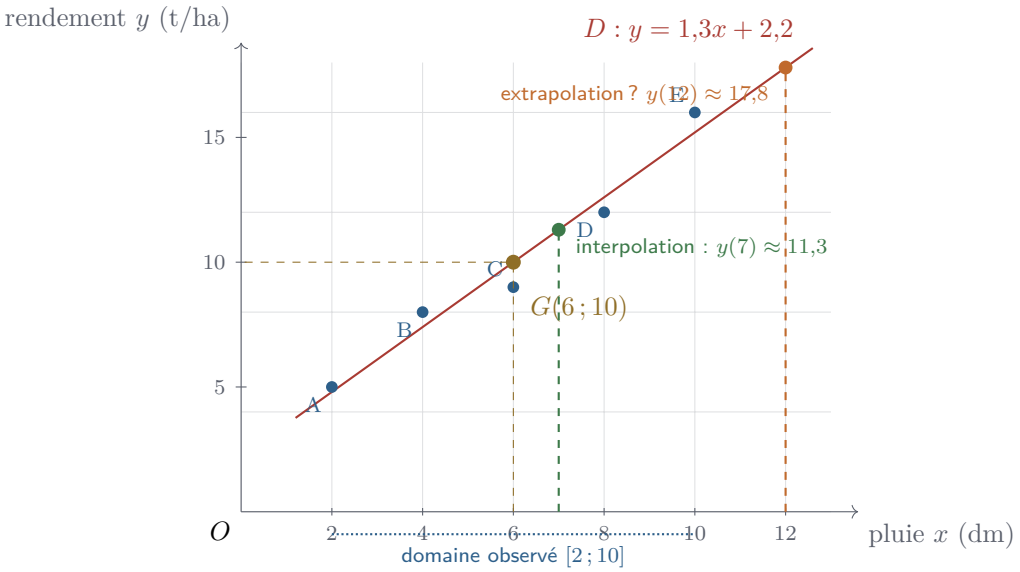
$$y = 1{,}3 \times 5 + 2{,}2 = 6{,}5 + 2{,}2 = 8{,}7$$

Résultat : $y = 8{,}7$ t/ha — prévision **fiable** (interpolation).
Étape 4 — Extrapolation pour 1 200 mm ($x = 12$, dehors) :

$$y = 1{,}3 \times 12 + 2{,}2 = 15{,}6 + 2{,}2 = 17{,}8$$

Résultat : $y = 17{,}8$ t/ha — calcul possible mais **prudence** : au-delà du domaine observé, le sol peut être saturé, les maladies se développer... la tendance peut changer. On annonce le résultat *en le qualifiant* d'extrapolation risquée.

Étape 5 — Contrôle final. Avant de conclure, on revérifie que $G(\bar{x}\,;\bar{y})$ appartient à $y = ax + b$: $a\bar{x} + b = 1{,}3 \times 6 + 2{,}2 = 10 = \bar{y}$ ✓. Sans ce contrôle, une erreur sur a ou b passerait inaperçue.



MÉTHODE — [

Rédiger une prédiction — la méthode en 3 temps]

1. **Justifier** l'ajustement : « $|r| \approx 0{,}98 \geq 0{,}9$, l'ajustement linéaire est justifié » ;
2. **Calculer** : remplacer x par sa valeur dans $y = ax + b$ (une transformation par ligne) ;
3. **Qualifier** : préciser **interpolation** (dedans, fiable) ou **extrapolation** (dehors, risquée), avec la prudence qui s'impose.

Omettre le temps 3 fait perdre les points d'interprétation — c'est le geste le plus rentable de la copie.

ERREUR FRÉQUENTE — Extrapoler sans le dire

Calculer $y(12) = 17{,}8$ et l'annoncer comme une prévision sûre est une faute de jugement, sanctionnée même si le calcul est juste. La prédiction par la droite se rédige **toujours** en trois temps (méthode ci-dessus) ; le mot « extrapolation » avec sa réserve (« la tendance peut changer hors du domaine observé ») fait partie de la réponse attendue.

QUAND L'UTILISER ? — [

Quand prédire, quand s'abstenir ?] On prédit **avec confiance** si les trois conditions sont réunies : $|r| \geq 0{,}9$, valeur de x *dans* le domaine observé, et l'unité de la réponse annoncée. On prédit **avec réserve** si x est juste au bord (extrapolation courte : 1 200 mm contre un domaine à 1 000 mm). On **s'abstient** si $|r| < 0{,}9$ (grille : prudence dès $< 0{,}9$, refus en dessous de 0,5) — ou si x est très loin des données : aucune droite ne certifie une tendance à 2 000 mm quand on a observé jusqu'à 1 000.

8. Limites du linéaire : causalité, nuages courbes

POURQUOI ? — [

Pourquoi « corrélation n'est pas causalité » ?] Un r fort prouve que les deux séries **varient ensemble**, pas que l'une *cause* l'autre. Exemple classique : les ventes de glaces et le nombre de noyades sont fortement corrélés... parce qu'une **variable cachée**, la chaleur, fait monter les deux ! Pour le sorgho, l'explication agronomique (l'eau fait pousser le mil et le sorgho) rend la liaison crédible — mais c'est un **raisonnement extérieur aux statistiques** : les chiffres montrent la liaison, la science du sol explique la cause. À l'examen, ne jamais écrire « r proche de 1 prouve que la pluie *cause* le rendement » : écrire « la corrélation est très forte, et l'interprétation agronomique rend cette liaison plausible ».

COMMENT ON L'OBTIENT ? — [

Comment on traite un nuage courbe — le changement de variable] Autre limite : la droite ne convient qu'à un nuage **rectiligne**. Si le nuage s'incurve — c'est typique des phénomènes de *croissance* (population d'une ville, effet de l'engrais qui sature) — le coefficient r baisse alors même que la liaison est évidente. La solution classique : **rendre le nuage rectiligne en changeant d'échelle**. On pose $Z = \ln y$ et on étudie la série double $(x_i\,;Z_i)$:

1. calculer $Z_i = \ln y_i$ pour chaque point ;
2. si les points $(x_i\,;Z_i)$ sont presque alignés, ajuster linéairement : $Z = ax+b$ (moindres carrés, comme en Partie 2) ;
3. revenir à y en composant par l'exponentielle : $Z = ax+b \iff \ln y = ax+b \iff y = \mathrm{e}^{ax+b} = \mathrm{e}^b \times \mathrm{e}^{ax}$.

Pourquoi ça marche ? Parce que le logarithme **transforme les multiplications en additions** : un phénomène qui multiplie (y double à chaque pas) devient une droite après ln (les Z montent d'une quantité constante $\ln 2$).

PROPRIÉTÉ — [

Le modèle exponentiel obtenu] Si la droite $Z = ax+b$ ajuste bien les points $(x_i\,;\ln y_i)$, alors le modèle initial est :

$$\boxed{y = \mathrm{e}^b \times \mathrm{e}^{ax}}$$

— une **croissance exponentielle** de base e^a : multiplier x d'une unité *multiplie* y par $\mathrm{e}^a \approx 2{,}72^a$. C'est le pendant multiplicatif de la droite additive $y = ax+b$.

MÉTHODE — [

Ajustement exponentiel — la méthode en 4 étapes]

1. **Transformer** : poser $Z_i = \ln y_i$ (nouveaux ordonnés) ;
2. **Vérifier** l'alignement des points $(x_i\,;Z_i)$: soit à l'œil, soit en calculant le r de la série $(x\,;Z)$ — il doit être très proche de ± 1 ;
3. **Ajuster** : moindres carrés sur $(x\,;Z) \to Z = ax+b$ (pente $a = \mathrm{cov}(x\,;Z)/V(x)$) ;
4. **Revenir** à y : $y = \mathrm{e}^b \times \mathrm{e}^{ax}$, puis conclure (en précisant interpolation ou extrapolation !).

QUAND L'UTILISER ? — [

Quand abandonner le linéaire ?] Signaux de l'énoncé : le nuage **s'incurve** (montée qui s'accentue, ou qui s'essouffle), le r est médiocre ($< 0{,}9$) alors que la liaison est évidente à l'œil, l'énoncé parle de « croissance », de « doublement », de « pourcentage annuel », ou donne des y qui se multiplient pendant que x s'additionne. Alors : poser $Z = \ln y$ et vérifier l'alignement des $(x_i\,;Z_i)$ — si c'est aligné, le modèle exponentiel est le bon.

ASTUCE — Petite histoire des sciences

C'est en étudiant la taille des parents et celle de leurs enfants que Francis Galton remarque, vers 1886, que les enfants de parents très grands sont en moyenne un peu moins grands qu'eux : il nomme ce phénomène « régression vers la moyenne ». Le mot *régression* est depuis resté collé à la droite des moindres carrés — et on parle aujourd'hui de « régression linéaire » dans tous les logiciels de statistique.

9. Applications types de la partie 3

Les trois exercices qui suivent sont les grandes configurations d'examen. Fais-les d'abord seul, couvre la correction, vérifie tes contrôles.

Application type n°1 — le pipeline complet : droite, r, prédiction

Énoncé. Cinq marchés de la région relèvent le prix moyen x (en centaines de FCFA) du kilogramme de sorgho et la quantité y (en sacs) vendue par un producteur : $(1\,;2)$, $(3\,;5)$, $(5\,;6)$, $(7\,;9)$, $(9\,;11)$. a) Déterminer la droite des moindres carrés. b) Calculer r et juger l'ajustement. c) Prédire y pour $x = 6$, puis pour $x = 15$.

a) Droite. $\sum x_i = 25$, $\sum y_i = 33$: $\bar{x} = 5$, $\bar{y} = 6{,}6$, donc $G(5\,;6{,}6)$. Sommes : $\sum x_i^2 = 165$, $\sum y_i^2 = 267$, $\sum x_i y_i = 209$. Alors :

$$\operatorname{cov}(x\,;y) = \frac{209}{5} - 5 \times 6{,}6 = 41{,}8 - 33 = 8{,}8 \;\; ; \qquad V(x) = \frac{165}{5} - 25 = 8$$

$$a = \frac{8{,}8}{8} = 1{,}1 \;\; ; \qquad b = 6{,}6 - 1{,}1 \times 5 = 1{,}1$$

$D : y = 1{,}1x + 1{,}1$. **Contrôle :** $1{,}1 \times 5 + 1{,}1 = 6{,}6 = \bar{y}$ ✓

b) Coefficient r. $V(y) = \dfrac{267}{5} - 6{,}6^2 = 53{,}4 - 43{,}56 = 9{,}84$; $\sigma_x = \sqrt{8} \approx 2{,}83$; $\sigma_y = \sqrt{9{,}84} \approx 3{,}14$. Donc

$$r = \frac{8{,}8}{2{,}83 \times 3{,}14} = \frac{8{,}8}{8{,}87} \approx 0{,}99$$

Comme $|r| \approx 0{,}99 \geq 0{,}9$, la corrélation est **très forte** et l'ajustement linéaire par D est **justifié** ; $r > 0$: la liaison est croissante.

c) Prédictions. Domaine observé : $x \in [1\,;9]$. Pour $x = 6$ (dedans) : $y = 1{,}1 \times 6 + 1{,}1 = 7{,}7$ — **interpolation** fiable : environ 7,7 sacs pour un prix de 600 FCFA. Pour $x = 15$ (dehors) : $y = 1{,}1 \times 15 + 1{,}1 = 17{,}6$ — **extrapolation risquée** : le calcul donne 17,6 sacs, mais rien ne garantit que la tendance persiste à un prix si éloigné des données. ✓

Application type n°2 — refuser un ajustement (savoir conclure « non »)

Énoncé. Une série double donne $\operatorname{cov}(x\,;y) = 2{,}4$, $V(x) = 5$ et $V(y) = 6$. Un élève propose d'utiliser la droite des moindres carrés pour prédire. Que penses-tu de sa réponse ?

Solution. Calculons r :

$$r = \frac{\operatorname{cov}(x\,;y)}{\sqrt{V(x)}\,\sqrt{V(y)}} = \frac{2{,}4}{\sqrt{5} \times \sqrt{6}} = \frac{2{,}4}{\sqrt{30}} \approx \frac{2{,}4}{5{,}48}$$

Résultat : $r \approx 0{,}44$. **Conclusion :** $|r| = 0{,}44 < 0{,}5$ — la corrélation est **faible** : selon la grille d'interprétation, **aucun ajustement linéaire sérieux** n'est justifié et il ne faut **pas prédire** avec la droite. L'élève a confondu « on peut toujours calculer une droite » (vrai : les moindres carrés donnent toujours une réponse) et « cette droite mérite de représenter le nuage » (faux ici). *Morale :* le calcul de r n'est pas une formalité — c'est lui qui donne ou retire le droit de prédire. ✓

Application type n°3 — changement de variable : l'ajustement exponentiel

Énoncé. La population d'une petite ville (en milliers d'habitants) est relevée chaque année : $x = 1, 2, 3, 4$ et $y = 6\,;\ 12\,;\ 24\,;\ 48$. a) Pourquoi l'ajustement linéaire est-il inadapté ? b) Poser $Z = \ln y$ et montrer que les points $(x\,;Z)$ sont alignés. c) En déduire le modèle, puis prédire y pour $x = 5$.

a) À l'œil. Les y **se multiplient** par 2 à chaque pas ($6 \to 12 \to 24 \to 48$) pendant que x s'additionne : le nuage s'incurve vers le haut — croissance exponentielle, pas linéaire.

b) Changement de variable. On pose $Z = \ln y$ et on décompose chaque y en facteurs premiers :

x_i	1	2	3	4
y_i	6	12	24	48
$Z_i = \ln y_i$	$\ln 6$	$\ln 12$	$\ln 24$	$\ln 48$

Or $\ln 6 = \ln 2 + \ln 3$, $\ln 12 = 2\ln 2 + \ln 3$, $\ln 24 = 3\ln 2 + \ln 3$, $\ln 48 = 4\ln 2 + \ln 3$ (le logarithme transforme les produits en sommes). Dans tous les cas :

$$Z_i = (\ln 2)\, x_i + \ln 3$$

Les points $(x_i\,;Z_i)$ sont donc **exactement alignés** sur la droite $Z = (\ln 2)\, x + \ln 3$ ✓. (Vérification par la formule générale : chaque $Z_i - \bar{Z}$ vaut $(x_i - \bar{x})\ln 2$, donc la pente des moindres carrés vaut $a = \dfrac{\sum (x_i - \bar{x})(Z_i - \bar{Z})}{\sum (x_i - \bar{x})^2} = \ln 2$ et $b = \bar{Z} - a\bar{x} = \ln 3$.)

c) Modèle et prédiction. On revient à y par l'exponentielle :

$$y = \mathrm{e}^{b} \times \mathrm{e}^{ax} = \mathrm{e}^{\ln 3} \times \mathrm{e}^{x \ln 2} = 3 \times 2^{x}$$

Le modèle est $y = 3 \times 2^x$ — vérification : $y(4) = 3 \times 16 = 48$ ✓. Prédiction pour $x = 5$: $y = 3 \times 2^5 = 96$ milliers d'habitants — **extrapolation risquée** : la croissance ne peut pas doubler indéfiniment (ressources limitées). ✓

10. Fiches méthodes de la partie 3

Trois fiches à relire la veille de l'examen. Chacune : le problème, la recette, l'exemple type.

MÉTHODE — [

Fiche n°1 — Calculer r et juger l'ajustement] **Recette :** (1) tableau : x_i, y_i, x_i^2, y_i^2, x_iy_i, totaux en bas ; (2) $\bar{x}$, $\bar{y}$; (3) cov $= \frac{\sum x_iy_i}{n} - \bar{x}\bar{y}$; $V(x) = \frac{\sum x_i^2}{n} - \bar{x}^2$; $V(y) = \frac{\sum y_i^2}{n} - \bar{y}^2$; (4) $\sigma_x = \sqrt{V(x)}$, $\sigma_y = \sqrt{V(y)}$ (arrondir ici seulement) ; (5) $r = \frac{\text{cov}}{\sigma_x\sigma_y}$; (6) conclusion : $|r|$ comparé à 0,9 (justifié ?), signe de r (sens), contrôle $a = r\,\sigma_y/\sigma_x$.
Exemple : sorgho — $V(y) = 14$; $\sigma_x \approx 2{,}83$; $\sigma_y \approx 3{,}74$; $r = \frac{10{,}4}{10{,}58} \approx 0{,}98$: très forte, croissante, ajustement justifié ; contrôle $0{,}98 \times \frac{3{,}74}{2{,}83} \approx 1{,}3 = a$ ✓

MÉTHODE — [

Fiche n°2 — Juger puis prédire (le plan de copie)] **Problème :** « La droite est-elle fiable ? Prédire pour $x = \ldots$ » **Plan :** (1) calculer r (fiche n°1) ; (2) phrase de jugement : « comme $|r| \approx \ldots \geq 0{,}9$, la corrélation est très forte et l'ajustement linéaire est justifié » (+ sens) ; (3) situer x : dedans (interpolation, fiable) ou dehors (extrapolation, risquée) ; (4) calculer $y = ax + b$ une transformation par ligne ; (5) conclure **avec l'unité** et la réserve qui s'impose ; (6) rappeler le contrôle $a\bar{x} + b = \bar{y}$.
Exemple : sorgho — 600 mm = 6 dm : $y = 1{,}3 \times 6 + 2{,}2 = 10{,}0$ t/ha, interpolation fiable ($= \bar{y}$: la droite passe par G) ; 1 200 mm = 12 dm : $y = 17{,}8$ t/ha, extrapolation risquée. ✓

MÉTHODE — [

Fiche n°3 — Changer de variable (nuage courbe)] **Recette :** (1) poser $Z_i = \ln y_i$; (2) vérifier l'alignement des $(x_i\,;Z_i)$ (à l'œil ou par le r de la série transformée) ; (3) ajuster : moindres carrés $\rightarrow Z = ax + b$; (4) revenir : $y = \mathrm{e}^b \times \mathrm{e}^{ax}$; (5) conclure (croissance multiplicative : y est multiplié par e^a à chaque pas de x).
Exemple : $y = 6\,;12\,;24\,;48$ pour $x = 1$ à 4 : $Z_i = \ln y_i = (\ln 2)x_i + \ln 3$ (alignés) $\rightarrow y = 3 \times 2^x$; prédiction $y(5) = 96$, extrapolation. ✓

RÉFLEXE RÉDACTION — Rédaction attendue sur ta copie

Les trois phrases qui valident un exercice de corrélation : (1) « **Comme** $|r| \approx 0{,}98 \geq 0{,}9$, la corrélation est très forte et l'ajustement linéaire par D est justifié » ; (2) « $r > 0$ (comme $a = 1{,}3 > 0$) : la liaison est **croissante**, cohérente avec le nuage » ; (3) « $x = 6$ appartient au domaine observé $[2\,;10]$: c'est une **interpolation**, prévision fiable de 10,0 t/ha » (ou « $x = 12$ est en dehors : **extrapolation**, résultat à prendre avec prudence »). Trois phrases, trois points.

ASTUCE — Les trois contrôles gratuits de la partie 3

Avant de rendre ta copie : (1) $-1 \leq r \leq 1$ (si tu trouvez $r = 1{,}3$, une erreur s'est glissée) ; (2) signe(r) = signe(a) (sinon, revois cov ou la droite) ; (3) $a = r\,\sigma_y/\sigma_x$ au millième près (elle recolle droite et corrélation). Dix secondes de vérification pour garantir trois calculs.

11. Exercices d'entraînement de la partie 3

11.1 QCM — teste tes réflexes (réponses en bas de page)

1. Pour un nuage de points, on trouve $r = -0{,}95$. Que conclure ?
   a) corrélation faible car r est négatif b) ajustement justifié, avec pente négative
   c) aucun ajustement possible d) la droite passe par l'origine
2. On donne $\text{cov}(x\,;y) = 3$; $\sigma_x = 2$; $\sigma_y = 1{,}5$. Le coefficient r vaut :
   a) 0,25 b) 1 c) 6,75 d) 0,9
3. Avec $D : y = 0{,}8x + 1$ ajustée sur des données où $x \in [2\,;10]$, prédire y pour $x = 25$ est :
   a) une interpolation fiable b) une extrapolation risquée c) impossible à calculer d) la médiane de la série
4. Comparé au signe de la pente a, le signe de r est :
   a) toujours opposé b) toujours le même c) parfois égal d) sans rapport
5. On trouve $|r| = 0{,}4$. La corrélation est :
   a) très forte b) forte c) modérée d) faible
6. On donne $r = 0{,}6$; $\sigma_x = 3$; $\sigma_y = 2$. La pente a vaut :
   a) 0,4 b) 0,9 c) 3,6 d) 0,1
7. Le coefficient r est :
   a) exprimé en t/ha b) un pourcentage c) un nombre sans unité entre -1 et 1 d) une variance
8. Des points parfaitement posés sur une parabole ont :
   a) $r \approx 1$ b) $r \approx 0$ c) $r \approx -1$ d) $r = 0{,}5$

11.2 Exercices d'application (du plus facile au plus corsé) — solutions détaillées

Exercice 1 — Des points parfaitement alignés : $r = 1$

Les points sont $(1\,;3)$, $(2\,;5)$, $(3\,;7)$. **a)** Calculer G, $\text{cov}(x\,;y)$, $V(x)$, $V(y)$. **b)** Calculer r et conclure. **c)** Retrouver la droite des moindres carrés.

Solution a. $\bar{x} = \frac{1+2+3}{3} = 2$; $\bar{y} = \frac{3+5+7}{3} = 5$: $G(2\,;5)$. Sommes : $\sum x_i^2 = 14$, $\sum y_i^2 = 9 + 25 + 49 = 83$, $\sum x_i y_i = 3 + 10 + 21 = 34$. Alors :

$$\text{cov} = \tfrac{34}{3} - 2 \times 5 = \tfrac{4}{3} \approx 1{,}33 \;\; ; \quad V(x) = \tfrac{14}{3} - 4 = \tfrac{2}{3} \;\; ; \quad V(y) = \tfrac{83}{3} - 25 = \tfrac{8}{3}$$

Solution b. $\sigma_x\,\sigma_y = \sqrt{\frac{2}{3}} \times \sqrt{\frac{8}{3}} = \sqrt{\frac{16}{9}} = \frac{4}{3}$, donc

$$r = \frac{4/3}{4/3} = 1$$

$r = 1$: les points sont **parfaitement alignés** sur une droite **croissante** (cas limite de la propriété $-1 \leq r \leq 1$).

Solution c. $a = \dfrac{\text{cov}}{V(x)} = \dfrac{4/3}{2/3} = 2$ et $b = 5 - 2 \times 2 = 1$: $D : y = 2x + 1$. **Contrôles :** $2 \times 2 + 1 = 5 = \bar{y}$ ✓ ; chaque point vérifie l'équation ($3 = 2 \times 1 + 1$, $5 = 2 \times 2 + 1$, $7 = 2 \times 3 + 1$) ✓

Exercice 2 — La grille des seuils en situation

On donne cinq valeurs du coefficient de corrélation : $r_1 = 0{,}98$, $r_2 = -0{,}93$, $r_3 = 0{,}72$, $r_4 = 0{,}45$, $r_5 = -0{,}05$. Pour chacune : force de la liaison (grille), sens, et verdict sur la prédiction.
Solution. On travaille sur $|r|$ pour la force, sur le signe pour le sens :

r	$\lvert r\rvert$: force	sens	verdict
0,98	très forte ($\geq 0{,}9$)	croissante	ajustement justifié, prédictions fiables
$-0{,}93$	très forte ($\geq 0{,}9$)	décroissante	ajustement justifié (pente négative)
0,72	forte (0,7–0,9)	croissante	tendance nette : prudence sur les prédictions
0,45	faible ($< 0{,}5$)	croissante	ne pas prédire avec la droite
$-0{,}05$	quasi nulle	(aucun sens utile)	aucune liaison rectiligne

Attention : $r_2 = -0{,}93$ est **plus forte** que $r_3 = 0{,}72$ (car $|-0{,}93| > |0{,}72|$) — le signe ne dit rien de la force. Et $r_5 \approx 0$ ne prouve pas « aucune relation » : peut-être une liaison courbe. ✓

Exercice 3 — Le r de la liaison prix/demande (retour de la Partie 2)

Reprends les données de la Partie 2 : prix x (centaines de FCFA) et demande y (sacs) : $(1\,;18)$, $(2\,;16)$, $(3\,;13)$, $(4\,;11)$, $(5\,;7)$, pour lesquelles on a trouvé $\text{cov}(x\,;y) = -5{,}4$, $V(x) = 2$ et $D : y = -2{,}7x + 21{,}1$. **a)** Calculer $V(y)$ sachant $\sum y_i^2 = 919$. **b)** Calculer r et conclure. **c)** Vérifier la cohérence $a = r\,\sigma_y/\sigma_x$.
Solution a. $\bar{y} = 13$, donc

$$V(y) = \frac{919}{5} - 13^2 = 183{,}8 - 169 = 14{,}8$$

Solution b. $\sigma_x = \sqrt{2} \approx 1{,}41$; $\sigma_y = \sqrt{14{,}8} \approx 3{,}85$; au dénominateur $\sqrt{2 \times 14{,}8} = \sqrt{29{,}6} \approx 5{,}44$. Donc

$$r = \frac{-5{,}4}{5{,}44} \approx -0{,}99$$

$|r| = 0{,}99 \geq 0{,}9$: corrélation **très forte** ; $r < 0$: liaison **décroissante** (quand le prix monte, la demande baisse) — cohérent avec le nuage descendant et la pente $a = -2{,}7 < 0$. La droite D est donc **fiable** pour interpoler dans $x \in [1\,;5]$.
Solution c. $a = r\,\dfrac{\sigma_y}{\sigma_x} \approx -0{,}99 \times \dfrac{3{,}85}{1{,}41} \approx -2{,}7$ ✓ — on retrouve exactement la pente de la Partie 2 : les deux calculs se recollent.

Exercice 4 — Prédictions sur le fil rouge sorgho

La droite $D : y = 1{,}3x + 2{,}2$ ($r \approx 0{,}98$) ajuste le nuage pluie/rendement, $x \in [2\,;10]$ (en dm). Prédire le rendement pour : **a)** 600 mm ; **b)** 750 mm ; **c)** 1 500 mm — en qualifiant chaque prédiction.
Solution a. 600 mm = 6 dm : $x = 6 = \bar{x}$, dedans. $y = 1{,}3 \times 6 + 2{,}2 = 10{,}0$: **interpolation** — et on retrouve $\bar{y} = 10$ (la droite passe par G) : double contrôle ✓ Environ 10,0 t/ha.
Solution b. 750 mm = 7,5 dm : dedans. Une transformation par ligne :

$$y = 1{,}3 \times 7{,}5 + 2{,}2 = 9{,}75 + 2{,}2$$

Résultat : $y = 11{,}95 \approx 12{,}0$ t/ha — **interpolation** fiable.

Solution c. 1 500 mm = 15 dm : bien **en dehors** de $[2\,;10]$. $y = 1{,}3\times15+2{,}2 = 19{,}5+2{,}2 = 21{,}7$ t/ha — **extrapolation risquée** : à une telle pluie, le sol peut être saturé et la tendance changer ; on annonce 21,7 t/ha avec cette réserve, ou l'on s'abstient. ✓

Exercice 5 (le piège) — Une parabole parfaite a $r \approx 0$

Les points $(-2\,;4)$, $(-1\,;1)$, $(0\,;0)$, $(1\,;1)$, $(2\,;4)$ sont *exactement* posés sur la parabole $y = x^2$. **a)** Calculer G. **b)** Calculer $\text{cov}(x\,;y)$, puis r. **c)** Que conclut-on sur r ? Quel est le vrai problème ?
Solution a. $\bar{x} = \frac{-2-1+0+1+2}{5} = 0$; $\bar{y} = \frac{4+1+0+1+4}{5} = \frac{10}{5} = 2$: $G(0\,;2)$.
Solution b. $\sum x_i y_i = (-2)(4)+(-1)(1)+0+1+8 = -8-1+0+1+8 = 0$, donc

$$\text{cov}(x\,;y) = \frac{0}{5} - 0\times 2 = 0$$

D'où $r = \dfrac{0}{\sigma_x \sigma_y} = 0$ (on peut aussi vérifier : $V(x) = \frac{10}{5} - 0 = 2$, $V(y) = \frac{34}{5} - 4 = 2{,}8$ — tous les ingrédients sont normaux, mais le numérateur est nul).
Solution c. $r \approx 0$ alors que la liaison est **parfaite** — mais courbe ! **Leçon :** r ne mesure que la liaison **rectiligne**. Un r proche de 0 ne signifie jamais « aucune relation » : il signifie « aucune relation *de forme droite* ». Ici, une parabole décrirait le nuage à la perfection — c'est l'argument pour changer de modèle (comme le logarithme le fait pour l'exponentiel), pas pour conclure à l'absence de liaison. ✓

Exercice 6 (corsé) — Étude complète d'un nuage, fil conducteur d'examen

Données : $(2\,;4)$, $(3\,;7)$, $(5\,;9)$, $(6\,;12)$, $(9\,;18)$. **a)** Point moyen. **b)** Droite des moindres carrés + contrôle. **c)** Coefficient r et jugement. **d)** Prédire y pour $x = 7$, puis $x = 12$.
Solution a. $\sum x_i = 25$, $\sum y_i = 50$: $\bar{x} = 5$, $\bar{y} = 10$: $G(5\,;10)$.
Solution b. Sommes : $\sum x_i^2 = 4+9+25+36+81 = 155$; $\sum y_i^2 = 16+49+81+144+324 = 614$; $\sum x_i y_i = 8+21+45+72+162 = 308$. Alors :

$$\text{cov}(x\,;y) = \frac{308}{5} - 5\times 10 = 61{,}6 - 50 = 11{,}6 \ ; \qquad V(x) = \frac{155}{5} - 25 = 6$$

$$a = \frac{11{,}6}{6} = \frac{29}{15} \approx 1{,}93 \ ; \qquad b = 10 - \frac{29}{15}\times 5 = 10 - \frac{29}{3} = \frac{1}{3} \approx 0{,}33$$

$D : y = \frac{29}{15}x + \frac{1}{3} \approx 1{,}93x + 0{,}33$. **Contrôle :** $\frac{29}{15}\times 5 + \frac{1}{3} = \frac{29}{3} + \frac{1}{3} = 10 = \bar{y}$ ✓
Solution c. $V(y) = \dfrac{614}{5} - 100 = 122{,}8 - 100 = 22{,}8$; $\sigma_x = \sqrt{6} \approx 2{,}45$; $\sigma_y = \sqrt{22{,}8} \approx 4{,}77$; au dénominateur $\sqrt{6\times 22{,}8} = \sqrt{136{,}8} \approx 11{,}70$. Donc

$$r = \frac{11{,}6}{11{,}70} \approx 0{,}99$$

$|r| \approx 0{,}99 \geq 0{,}9$: corrélation **très forte**, ajustement linéaire **justifié** ; $r > 0$ et $a > 0$: liaison croissante (mêmes signes ✓). *Contrôle de cohérence :* $a = r\,\sigma_y/\sigma_x \approx 0{,}99 \times \frac{4{,}77}{2{,}45} \approx 1{,}93$ ✓
Solution d. Domaine observé : $x \in [2\,;9]$. Pour $x = 7$ (dedans) : $y = \frac{29}{15}\times 7 + \frac{1}{3} = \frac{203+5}{15} = \frac{208}{15} \approx 13{,}9$ — **interpolation** fiable : environ 13,9 (t/ha). Pour $x = 12$ (dehors) : $y = \frac{29}{15}\times 12 + \frac{1}{3} = \frac{348+5}{15} = \frac{353}{15} \approx 23{,}5$ — **extrapolation risquée**, à annoncer avec réserve. ✓

QCM : 1-b 2-b 3-b 4-b 5-d 6-a 7-c 8-b

À TOI DE JOUER — Prédire en trois temps

Une droite $D : y = 2{,}5x - 20$ a été ajustée sur des données avec $x \in [10\,;40]$, et $|r| = 0{,}93$. **a)** Prédire y pour $x = 25$. **b)** Prédire y pour $x = 60$. **c)** Rédiger les deux conclusions comme à l'examen.

Correction

a) $x = 25 \in [10\,;40]$: $y = 2{,}5 \times 25 - 20 = 62{,}5 - 20 = 42{,}5$. **b)** $x = 60 \notin [10\,;40]$: $y = 2{,}5 \times 60 - 20 = 150 - 20 = 130$. **c)** a) « Comme $|r| = 0{,}93 \geq 0{,}9$, l'ajustement linéaire est justifié ; $x = 25$ est dans le domaine observé : **interpolation** fiable, $y \approx 42{,}5$. » b) « Le calcul donne $y = 130$, mais $x = 60$ est loin du domaine observé : **extrapolation risquée**, la tendance rectiligne n'est pas garantie si loin. » ✓

12. Pour aller plus loin : le coefficient de détermination r^2

Cette courte section va un cran au-delà du programme — elle explique *pourquoi* on dit qu'une droite « explique » le nuage.

PROPRIÉTÉ — [

Le coefficient de détermination r^2] Le carré du coefficient de corrélation s'appelle le **coefficient de détermination** :

$$\boxed{r^2 = \frac{\operatorname{cov}(x\,;y)^2}{V(x)\,V(y)} \;=\; 1 - \frac{S_{\min}}{N\,V(y)}}$$

(la seconde écriture vient de $S_{\min} = N\,V(y)\,(1-r^2)$, section 4). Interprétation : r^2 est la **proportion de la variance de y « expliquée » par la droite** — c'est-à-dire la part de dispersion que le modèle linéaire absorbe.

Sur le fil rouge sorgho

$r^2 = \dfrac{10{,}4^2}{8\times 14} = \dfrac{108{,}16}{112} \approx 0{,}966$: la droite $D : y = 1{,}3x + 2{,}2$ **explique environ 97 %** de la variance des rendements. Dans l'autre sens : $S_{\min} = 5\times 14\times(1-0{,}966) \approx 2{,}4$ (t/ha)^2 — c'est le petit résidu qu'aucune droite ne peut réduire davantage (partie 2). On voit la cohérence d'ensemble : r proche de 1 $\Rightarrow$ r^2 proche de 1 $\Rightarrow$ $S_{\min}$ proche de 0 $\Rightarrow$ nuage presque aligné. ✓

ASTUCE — Ce que la suite du chapitre fait de ces outils

Tu disposes maintenant de la chaîne complète : **décrire** une série (partie 1), **mesurer** sa dispersion et **résumer** un nuage (partie 2), **juger** la droite et **prédire** avec elle (cette partie). La suite du chapitre rassemble ces outils en fiches de révision : c'est elles qu'il faut savoir refaire les yeux fermés la veille de l'examen.

13. Table de synthèse de la partie 3

Objet	Formule / règle	Ce qu'il faut retenir
Allures du nuage	croissant ($r > 0$), décroissant ($r < 0$), éparpillé ($r \approx 0$)	l'œil d'abord, le calcul ensuite
Coefficient r	$r = \dfrac{\operatorname{cov}(x\,;y)}{\sigma_x\,\sigma_y}$	nombre **sans unité** ; il ne manque jamais que $V(y)$
Borne	$-1 \leq r \leq 1$	démontré par $S_{\min} = NV(y)(1-r^2) \geq 0$; bornes = alignement parfait
Signe	$\text{signe}(r) = \text{signe}(a) = \text{signe}\,\text{cov}$	car $a = r\,\sigma_y/\sigma_x$ avec $\sigma_y/\sigma_x > 0$
Critère d'usage	$\lvert r\rvert \geq 0{,}9 \Rightarrow$ ajustement justifié	convention usuelle ; force sur $\lvert r\rvert$, sens sur le signe
Grille	0,9 / 0,7 / 0,5	très forte / forte / modérée ; $< 0{,}5$: ne pas prédire
Interpolation	x *dans* le domaine observé	prévision fiable
Extrapolation	x *en dehors*	calcul possible, résultat risqué : le dire !
Rédaction	justifier $(r) \to$ calculer $(y = ax + b) \to$ qualifier	les trois temps valent trois points
Limites	corrélation $\neq$ causalité ; r ne juge que le rectiligne	parabole parfaite : $r \approx 0$ (ex. $y = x^2$)
Ajustement exponentiel	$Z = \ln y$; si $(x\,;Z)$ alignés : $y = \mathrm{e}^b\,\mathrm{e}^{ax}$	transforme une croissance multiplicative en droite
Détermination	$r^2 = \dfrac{\operatorname{cov}^2}{V(x)V(y)}$	part de variance de y expliquée par la droite (fil rouge : ≈ 97 %)
Fil rouge sorgho	$r = \dfrac{10{,}4}{\sqrt{8}\sqrt{14}} \approx 0{,}98$	très forte, croissante ; D fiable pour interpoler, prudence pour extrapoler

ASTUCE — Le chapitre est complet — relis les trois tables de synthèse

Partie 1 : six nombres pour résumer une série (mode, $\bar{x}$, Me, Q_1, Q_3, étendue). Partie 2 : V, σ pour la dispersion ; G et la droite des moindres carrés pour le nuage. Partie 3 : r pour juger, interpolation/extrapolation pour prédire, ln pour redresser un nuage courbe. Ces trois pages de synthèse sont ta fiche de révision finale : refais les fil rouges (10 parcelles de mil, 5 parcelles de sorgho) sans regarder les corrections, et tu es prêt.