COURS COMPLET · PARTIE 4 SUR 5

Cours complet : Moindres carrés, Corrélation & Études complètes

Le sommet du chapitre déplié : la démonstration des moindres carrés, la preuve que la droite passe par G, covariance en profondeur, changement de variable, étude complète mil/pluviométrie et le piège des deux régressions.

MATIÈRE	Mathématiques — Terminale D
CHAPITRE	Statistiques
CONTENU	11 sections · 33 pages · chaque notion sur sa page · QCM et exercices corrigés

ARVEXA School — Préparation au BAC, Côte d'Ivoire

Moindres carrés, Corrélation & Études complètes

Chapitre 11 · Statistiques — Partie 4 sur 5 · **Cours complet**

*Voici le **sommet du chapitre**, développé en profondeur. Les Parties 1 à 3 ont construit les briques : indicateurs, variance, nuage, point moyen, droite, coefficient r. Cette partie les **assemble et les prouve**. La **démonstration complète des moindres carrés** : on minimise $S(a,b)$, on dérive par rapport à b puis à a, on résout le système 2×2, et la formule $a = \mathrm{cov}\,/V(x)$ apparaît au lieu d'être récité. La **preuve** que toute droite de régression passe par G, avec son cadeau caché (la somme des résidus est nulle). La **covariance** en profondeur (unités, propriétés, pièges), le coefficient r **calculé et prouvé** (borne $|r| \leq 1$ comprise), le **changement de variable** $z = \sqrt{y}$ ou $z = \ln y$ quand le nuage se courbe, l'**étude complète** pluviométrie–rendement du mil menée de bout en bout, le **grand piège** de la régression de x en y, et **deux sujets type BAC** entièrement résolus. Chaque formule est obtenue devant toi, chaque exemple vérifié ligne par ligne.*

50 min **8 grands thèmes** **11 sections** **Terminale D**

Table des matières

1 La chaîne complète de l'étude statistique 2

2 La démonstration des moindres carrés : minimiser $S(a,b)$ 5

3 Toute droite de régression passe par G : la preuve et ses cadeaux 8

4 La covariance en profondeur 10

5 Le coefficient r : le calcul complet, les seuils, la borne $|r| \leq 1$ 12

6 Quand le nuage n'est pas droit : le changement de variable $z = f(y)$ 15

7 Étude complète — pluviométrie et rendement du mil (Niamey) 18

8 Le grand piège : régression de y en x ou de x en y ? 22

9 Fiches méthodes de la partie 4 25

10 Exercices d'entraînement de la partie 4 27

11 Table de synthèse de la partie 4 32

1. La chaîne complète de l'étude statistique

POURQUOI ? — [

Pourquoi une partie 4, alors que tout semble déjà fait ?] Parce que savoir *appliquer* $a = \dfrac{\text{cov}(x\,;y)}{V(x)}$ et savoir *prouver* cette formule sont deux niveaux — et l'examen demande les deux. Les sujets type BAC enchaînent toujours les mêmes gestes : un nuage, un point moyen, une droite, un coefficient, une prévision. Mais ils glissent aussi des questions « **montrer que** » (montrer la formule de la pente, montrer que la droite passe par G, montrer que $|r| \leq 1$). Cette partie fournit les démonstrations complètes, une étude menée de bout en bout sur des données ouest-africaines, et les réflexes qui séparent la copie à 10 de la copie à 16.

ASTUCE — La carte d'identité du chapitre — à connaître les yeux fermés

Un sujet de statistiques descriptives demande presque toujours la même chaîne :

nuage → point moyen G → variances et covariance → droite $D : y = ax + b$ → coefficient r → jugement → prévision.

Maîtrise cette chaîne et tu couvres l'essentiel de l'épreuve. Chaque maillon a sa section dans les Parties 1 à 3 ; cette partie le prouve, le creuse et l'enchaîne.

Indicateur	Formule	Ce qu'il mesure / quand l'utiliser
Mode	valeur du plus grand n_i (ou classe modale)	la valeur la plus fréquente ; seul indicateur possible pour un caractère qualitatif
Médiane Me	rang $(N+1)/2$ si N impair ; moyenne des rangs $N/2$ et $N/2+1$ si N pair	partage la série **ordonnée** en deux moitiés ; insensible aux valeurs extrêmes
Fréquence f_i	$f_i = n_i/N$, $\sum f_i = 1$	part de la population ; compare deux enquêtes de tailles différentes
Quartiles	$\text{EI} = Q_3 - Q_1$; étendue $e = x_{\max} - x_{\min}$	coupes à 25 % et 75 % ; l'EI mesure le cœur (50 % central)
Moyenne $\bar{x}$	$\bar{x} = \dfrac{\sum n_i x_i}{N} = \sum f_i x_i$	centre de gravité ; utilise toutes les valeurs ; base de la variance
Variance	$V(x) = \dfrac{\sum n_i x_i^2}{N} - \bar{x}^2$	dispersion autour de la moyenne (unité au carré)
Écart-type	$\sigma = \sqrt{V(x)}$	dispersion dans l'unité des données ; sert à comparer deux séries
Point moyen	$G(\bar{x}\,;\bar{y})$	centre de gravité du nuage ; D passe toujours par G
Covariance	$\text{cov}(x\,;y) = \dfrac{\sum n_i x_i y_i}{N} - \bar{x}\bar{y}$	sens de la liaison : positive → croissante, négative → décroissante
Corrélation	$r = \dfrac{\text{cov}(x\,;y)}{\sigma_x\,\sigma_y}$	force et sens de la liaison rectiligne ; $\lvert r\rvert \geq 0{,}9$ justifie l'ajustement

PROPRIÉTÉ — [

Les sept contrôles réflexes — cinq secondes chacun] Avant de rendre ta copie, déroule cette liste : chaque contrôle localise une erreur *avant* le correcteur.

1. Effectifs : $\sum n_i = N$; Fréquences : $\sum f_i = 1$;
2. Moyenne : $\sum n_i(x_i - \bar{x}) = 0$ *exactement* (idem pour y) — un résultat non nul = moyenne fausse ;
3. Droite : $a\bar{x} + b = \bar{y}$ — le point moyen $G(\bar{x}\,;\bar{y})$ appartient toujours à D (démontré en section 3) ;
4. Corrélation : $-1 \leq r \leq 1$ — un r dehors signale une erreur de calcul ;
5. Signes : signe(r) = signe(a) = signe cov ;
6. Unités : t/ha, kg/ha, mm, FCFA **annoncées** dans la conclusion ;
7. Arrondis : valeurs exactes (fractions, racines) pendant les calculs, arrondi **seulement à la fin**.

MÉTHODE — [

L'ordre des calculs — un seul tableau sert à tout]

1. **Tracer le nuage** des points $M_i(x_i\,;y_i)$ et juger son allure : allongé autour d'une droite → ajustement linéaire envisagé (sinon, le dire et s'abstenir) ;
2. **Calculer le point moyen** $\bar{x} = \frac{\sum x_i}{n}$, $\bar{y} = \frac{\sum y_i}{n}$, d'où $G(\bar{x}\,;\bar{y})$;
3. **Remplir le tableau de calcul** (colonnes x_i^2, y_i^2, x_iy_i, totaux en bas) puis calculer $V(x)$, $V(y)$, cov$(x\,;y)$;
4. **Pente** : $a = \dfrac{\text{cov}(x\,;y)}{V(x)}$ — le signe de a est celui de la covariance ;
5. **Ordonnée** : $b = \bar{y} - a\bar{x}$, écrire $D : y = ax + b$, et **contrôler** $G \in D$;
6. **Juger** : $\sigma_x = \sqrt{V(x)}$, $\sigma_y = \sqrt{V(y)}$, $r = \frac{\text{cov}}{\sigma_x\sigma_y}$; si $|r| \geq 0{,}9$, l'ajustement est justifié → prévision (interpolation pour une valeur du domaine observé).

On calcule *d'abord* la droite, *ensuite* r : tout ce qu'il faut pour r est déjà prêt à la fin de l'étape 4.

ERREUR FRÉQUENTE — Mélanger les colonnes x_i^2 et x_iy_i

La variance utilise la colonne x_i^2, la covariance la colonne x_iy_i : deux colonnes distinctes, jamais interchangeables. Et $\sum x_iy_i$ (produits terme à terme) n'est **ni** $\sum x_i^2$, **ni** $(\sum x_i)\,(\sum y_i)$ — sur le fil rouge sorgho : 352, et non $30 \times 50 = 1500$. Deuxième variante du piège : oublier $b = \bar{y} - a\bar{x}$ et écrire $D : y = ax$ seul — b peut d'ailleurs être négatif (l'étude complète ci-dessous donnera $b = -345$).

À TOI DE JOUER — Trois contrôles en trois minutes

Trois copies d'élèves, trois résultats à auditer avec les contrôles réflexes :
a) pour cov$(x\,;y) = -7$, $V(x) = 2$, $V(y) = 30$, un élève annonce $r = 1{,}2$;
b) pour le fil rouge sorgho, un élève annonce $D : y = 1{,}3x + 2{,}2$ et $G(6\,;10)$;
c) un élève trouve $r = 0{,}8$ et $a = -2$ sur les mêmes données.

Correction

a) $r = \dfrac{-7}{\sqrt{2}\,\sqrt{30}} = \dfrac{-7}{\sqrt{60}} \approx -0{,}90$: l'élève a trouvé $|r| = 1{,}2 > 1$ — **impossible** (contrôle n°4) : erreur de calcul, à retrouver. **b)** Contrôle n°3 : $1{,}3 \times 6 + 2{,}2 = 7{,}8 + 2{,}2 = 10 = \bar{y}$ ✓ — cohérent. **c)** Contrôle n°5 : $r = 0{,}8 > 0$ mais $a = -2 < 0$: les signes sont **contradictoires** ($a = r\,\sigma_y/\sigma_x$ et $\sigma_y/\sigma_x > 0$) — erreur sur r ou sur a. Trois contrôles, trois verdicts : c'est le réflexe qui sauve des points. ✓

2. La démonstration des moindres carrés : minimiser $S(a,b)$

POURQUOI ? — [

Pourquoi démontrer ce qu'on a déjà utilisé ?] Depuis la Partie 2, tu appliques $a = \dfrac{\text{cov}(x\,;y)}{V(x)}$ et $b = \bar{y} - a\bar{x}$. D'où viennent-elles ? De l'exigence : chercher la droite qui rend **minimale** la somme des carrés des écarts verticaux, $S(a,b) = \sum (y_i - ax_i - b)^2$. La démonstration est à ta portée : elle ne demande que le développement d'un carré et le sommet d'une parabole. Au Bac, elle alimente directement les questions « montrer que … » — et surtout, elle explique *pourquoi* la covariance et $V(x)$ se retrouvent dans la pente.

PROPRIÉTÉ — [

Rappel du point de départ (Partie 2) — et l'outil du sommet] Pour un a fixé, S est un trinôme du second degré en b ; pour b fixé, un trinôme en a. **Outil central :** pour tout trinôme $q(u) = \alpha u^2 + \beta u + \gamma$ avec $\alpha > 0$, on a $q(u) = \alpha\left(u + \frac{\beta}{2\alpha}\right)^2 + \gamma - \frac{\beta^2}{4\alpha}$: le minimum est atteint **uniquement** quand $u = -\frac{\beta}{2\alpha}$ — c'est exactement le point où la dérivée $q'(u) = 2\alpha u + \beta$ **s'annule**. Donc « dériver et annuler » est le geste qui trouve le sommet de la parabole.

COMMENT ON L'OBTIENT ? — [

La démonstration complète — dériver par rapport à b, puis à a, résoudre le système] On minimise $S(a,b) = \displaystyle\sum_{i=1}^{n} (y_i - ax_i - b)^2$ sur les n points.

Étape 1 — Développer S. Avec $(u+v+w)^2 = u^2+v^2+w^2+2uv+2uw+2vw$ et $u = y_i$, $v = -ax_i$, $w = -b$:

$$S = \sum y_i^2 \;+\; a^2 \sum x_i^2 \;+\; nb^2 \;-\; 2a \sum x_i y_i \;-\; 2b \sum y_i \;+\; 2ab \sum x_i$$

(chaque terme est sommé terme à terme ; b^2 apparaît n fois, d'où nb^2).

Étape 2 — Dériver par rapport à b (à a fixé) et annuler. Les termes contenant b sont $nb^2 - 2b\left(\sum y_i - a\sum x_i\right)$: un trinôme en b de coefficient dominant $n > 0$, dont la dérivée est $2nb - 2\left(\sum y_i - a\sum x_i\right)$. On l'annule :

$$nb = \sum y_i - a\sum x_i \quad\Longrightarrow\quad b = \frac{\sum y_i}{n} - a\frac{\sum x_i}{n} \quad\Longrightarrow\quad \boxed{b = \bar{y} - a\,\bar{x}} \quad (1)$$

Justification : c'est le sommet du trinôme (Étape 0) — pas une supposition, une conséquence de $\alpha > 0$.

Étape 3 — Dériver par rapport à a (à b fixé) et annuler. Les termes contenant a sont $a^2\sum x_i^2 - 2a\left(\sum x_i y_i - b\sum x_i\right)$: trinôme en a de coefficient dominant $\sum x_i^2 > 0$, dérivée $2a\sum x_i^2 - 2\left(\sum x_i y_i - b\sum x_i\right)$, qu'on annule :

$$a\sum x_i^2 + b\sum x_i = \sum x_i y_i \quad (2)$$

Étape 4 — Résoudre le système linéaire 2×2 :

$$\begin{cases} a\sum x_i^2 + b\sum x_i = \sum x_i y_i & (2) \\ a\sum x_i + nb = \sum y_i & (1)\ \text{réécrite} \end{cases}$$

Par substitution : de (1), $b = \bar{y} - a\bar{x}$. On remplace dans (2) :

$$a\sum x_i^2 + (\bar y - a\bar x)\sum x_i = \sum x_i y_i \implies a\left(\sum x_i^2 - \bar x\sum x_i\right) = \sum x_i y_i - \bar y\sum x_i$$

Or $\sum x_i = n\bar x$, donc $\sum x_i^2 - \bar x\sum x_i = n\left(\dfrac{\sum x_i^2}{n} - \bar x^2\right) = n\,V(x)$, et de même $\sum x_i y_i - \bar y\sum x_i = n\,\mathrm{cov}(x\,;y)$. Donc $a\,nV(x) = n\,\mathrm{cov}(x\,;y)$, d'où — dès que $V(x) > 0$, c'est-à-dire les x_i non tous égaux :

$$\boxed{a = \frac{\mathrm{cov}(x\,;y)}{V(x)} \qquad \text{et} \qquad b = \bar y - a\,\bar x}$$ ■

Remarque sur l'ordre : on a dérivé d'abord par rapport à b parce que l'équation (1) donne b directement en fonction de a — la substitution devient une ligne. La Partie 2 suivait l'autre route (lemme « le meilleur b est $\bar y - a\bar x$ ») : deux chemins, un même sommet, les résultats coïncident.

PROPRIÉTÉ — [

Énoncé exact — la droite des moindres carrés] Soit une série double de n points $M_i(x_i\,;y_i)$ avec les x_i **non tous égaux** (donc $V(x) > 0$). La fonction $S(a,b) = \sum(y_i - ax_i - b)^2$ atteint un **unique minimum**, atteint pour la seule droite

$$D : y = ax + b \qquad \text{avec} \qquad a = \frac{\mathrm{cov}(x\,;y)}{V(x)} \qquad \text{et} \qquad b = \bar y - a\,\bar x.$$

D s'appelle **droite de régression** de y en x (ou droite des moindres carrés). Aucun autre couple (a,b) ne fait mieux.

Contrôle : les équations normales vérifiées sur les données du mil

L'étude complète (section 7) donne, pour 6 années de pluie x (mm) et rendement du mil y (kg/ha) : $\sum x_i = 2\,520$, $\sum y_i = 5\,400$, $\sum x_i^2 = 1\,092\,000$, $\sum x_i y_i = 2\,367\,600$, et la droite $a = \frac{83}{28}$, $b = -345$. Vérifions les **deux équations normales** — c'est le test qui prouve que la droite est bien la solution du système :

Équation (1) : $\dfrac{83}{28} \times 2\,520 + 6 \times (-345) = 7\,470 - 2\,070 = 5\,400 = \sum y_i$ ✓

Équation (2) : $\dfrac{83}{28} \times 1\,092\,000 + (-345) \times 2\,520 = 3\,237\,000 - 869\,400 = 2\,367\,600$ ✓

et l'on retrouve bien $\sum x_i y_i = 2\,367\,600$ et $\sum y_i = 5\,400$: les deux lignes tombent **exactement** juste. Le couple $\left(\frac{83}{28}\,;\,-345\right)$ est bien la solution du système 2×2. ✓

QUAND L'UTILISER ? — [

Quand cette démonstration sert-elle ?]

- « **Montrer que la pente vaut** $\mathrm{cov}/V(x)$ » : c'est la question de cours classique — tu réécris les étapes 2 à 4 (voir fiche n°1, section 9) ;
- « **Montrer que la droite passe par** G » : l'équation (1) le donne en deux lignes (section suivante) ;
- « **Pourquoi le dénominateur est-il** $V(x)$ **et pas** $V(y)$ **?** » : parce que l'on minimise les écarts **verticaux** — y est expliqué, x explique ;

- **Toute question qui guide l'énoncé** : « on pose $S(a,b) = \ldots$, montrer que S est minimal pour … » — le plan est toujours : développer, dériver, annuler, résoudre.

ERREUR FRÉQUENTE — Deux pièges de rédaction

(1) **Annuler la dérivée sans justifier le minimum** : « la dérivée s'annule » ne prouve un minimum que si le coefficient dominant est **positif** ($n > 0$, $\sum x_i^2 > 0$) — cite-le, c'est la ligne qui rapporte les points. (2) **Oublier la condition** $V(x) > 0$: si tous les x_i sont égaux, le nuage est une colonne verticale, $a = \frac{\text{cov}}{V(x)}$ n'a pas de sens — la droite de régression n'existe pas.

À TOI DE JOUER — Vérifier les équations normales sur le fil rouge sorgho

Fil rouge de la Partie 2 : $(2\,;5)$, $(4\,;8)$, $(6\,;9)$, $(8\,;12)$, $(10\,;16)$, pour lesquelles $\sum x_i = 30$, $\sum y_i = 50$, $\sum x_i^2 = 220$, $\sum x_i y_i = 352$, $n = 5$, $a = 1{,}3$, $b = 2{,}2$. Vérifier les deux équations normales.

Correction

Équation (1) **:** $1{,}3\times 30 + 5\times 2{,}2 = 39 + 11 = 50 = \sum y_i$ ✓ **Équation** (2) **:** $1{,}3\times 220 + 2{,}2\times 30 = 286 + 66 = 352 = \sum x_i y_i$ ✓ — le couple $(1{,}3\,;2{,}2)$ résout le système : deux données, deux contrôles exacts, zéro doute. ✓

3. Toute droite de régression passe par G : la preuve et ses cadeaux

POURQUOI ? — [

Pourquoi cette propriété est le contrôle n°1 du chapitre] Tu vérifies $a\bar{x}+b=\bar{y}$ depuis la Partie 2 sans savoir pourquoi ça marche *toujours*. La preuve tient en deux lignes — et elle s'accompagne d'un cadeau inattendu : la droite de régression **équilibre** le nuage (la somme de ses résidus est exactement nulle). Comprendre ces deux faits transforme un « contrôle de routine » en outil de compréhension — et sauve des points : si ton couple (a, b) ne vérifie pas $G \in D$, l'erreur est certaine, il faut la chercher avant de prédire quoi que ce soit.

COMMENT ON L'OBTIENT ? — [

La preuve par substitution — deux lignes] L'équation normale (1) de la section précédente donne, **quelle que soit la pente** a :

$$b = \bar{y} - a\bar{x} \quad \Longrightarrow \quad a\bar{x} + b = a\bar{x} + \bar{y} - a\bar{x} = \bar{y}$$

Or « $a\bar{x} + b = \bar{y}$ » signifie précisément que le point $G(\bar{x}\,;\bar{y})$ vérifie l'équation de la droite : G appartient à D. ■ *Variante par l'équation normale réécrite :* $a\sum x_i + nb = \sum y_i$; en divisant par n : $a\bar{x} + b = \bar{y}$ — même conclusion, encore plus direct. Et la même preuve vaut pour la **droite de Mayer** (Partie 2 : G est barycentre de G_1 et G_2) : toutes les droites d'ajustement usuelles passent par G ; c'est leur **pente** qui les départage.

COMMENT ON L'OBTIENT ? — [

Le cadeau caché : la somme des résidus est exactement nulle] Un **résidu** est l'écart vertical d'un point à la droite : $e_i = y_i - ax_i - b$. Sommons-les :

$$\sum e_i = \sum y_i - a\sum x_i - nb = \sum y_i - n(a\bar{x} + b) = \sum y_i - n\bar{y} = 0$$

(la parenthèse centrale est l'équation normale (1) divisée par n). ■ **Lecture :** la droite de régression coupe le nuage en écarts vers le haut et vers le bas qui se **compensent exactement** — c'est une droite d'équilibre, au sens du centre de gravité. C'est aussi un contrôle de calcul gratuit : *si ta somme de résidus n'est pas nulle, ta droite est fausse.*

PROPRIÉTÉ — [

Forme centrée de la droite de régression] Comme $a\bar{x} + b = \bar{y}$, l'équation $y = a\bar{x} + b + a(x - \bar{x})$ se réécrit :

$$\boxed{y - \bar{y} = a\,(x - \bar{x})}$$

C'est la **forme centrée** : droite de pente a *passant par* G, sans jamais calculer b. Les trois écritures — $y = ax+b$, $b = \bar{y}-a\bar{x}$, forme centrée — sont équivalentes ; choisis la plus économique selon la question.

La forme centrée en action — prédire sans calculer b

Sur les données du mil (section 7) : $\bar{x} = 420$, $\bar{y} = 900$, pente $a = \frac{83}{28}$. La droite s'écrit $y - 900 = \frac{83}{28}(x - 420)$. Prévision pour $x = 480$ mm, une étape par ligne :

$$y = 900 + \frac{83}{28} \times (480 - 420) = 900 + \frac{83}{28} \times 60 = 900 + 177{,}86 \approx 1\,077{,}9$$

On retrouve exactement la valeur de la section 7 ($y \approx 1\,078$ kg/ha) — la forme centrée évite le calcul de b et **garde G sous les yeux**, donc limite les erreurs d'arrondi. ✓

ERREUR FRÉQUENTE — $G \in D$ ne prouve pas que la droite est bonne !

La preuve ci-dessus vaut pour **toute** pente a : une droite arbitraire de pente 7 avec $b = \bar{y} - 7\bar{x}$ passe aussi par G. Donc : (1) $G \in D$ est un contrôle de **calcul** (cohérence entre a, b, $\bar{x}$, $\bar{y}$), pas un certificat de **qualité** — la qualité se juge avec r ; (2) attention, si tu calcules b *à partir* d'un a arrondi, le contrôle $G \in D$ reste vrai et **cache** l'erreur d'arrondi (voir le piège de la section 7 : $b = -343{,}2$ au lieu de -345 passe quand même le test). Le vrai rempart contre l'arrondi : garder les fractions exactes jusqu'au bout.

ASTUCE — La géométrie derrière

Le point moyen G est le **centre de gravité** du nuage : si les points étaient des masses égales posées sur une plaque, la plaque tiendrait en équilibre posée sur la pointe d'un crayon en G. La droite de régression est la droite qui passe par ce point d'équilibre et qui « penche » exactement comme le nuage — la pente $a = \text{cov}/V(x)$ en est la mesure précise. C'est pour cela que toute l'analyse pivote autour de G : décrire la droite, c'est décrire *où est le centre* (les moyennes) et *comment ça penche* (la covariance).

4. La covariance en profondeur

POURQUOI ? — [

Pourquoi une « variance croisée » ?] La variance mesure comment une série s'écarte de sa propre moyenne : $V(x) = \frac{1}{N}\sum n_i(x_i - \bar{x})^2$. Mais la droite de régression a besoin de savoir comment x et y s'écartent **ensemble** de leurs moyennes : quand x_i est au-dessus de $\bar{x}$, y_i est-il au-dessus de $\bar{y}$? La covariance répond : elle multiplie les deux écarts — positif × positif ou négatif × négatif donne positif (la liaison « pousse dans le même sens »), positif × négatif donne négatif (la liaison « pousse en sens contraires »). C'est le moteur de la pente $a = \text{cov}/V(x)$: au numérateur, le « pousser ensemble » ; au dénominateur, la dispersion de x qui sert de règle de mesure.

PROPRIÉTÉ — [

Définition et écritures équivalentes (rappel Partie 2, avec la notation espérance)]

$$\text{cov}(x\,;y) = \frac{\sum n_i x_i y_i}{N} - \bar{x}\,\bar{y} \;=\; \frac{1}{N}\sum n_i(x_i - \bar{x})(y_i - \bar{y})$$

Si l'on note $E(X) = \bar{x}$ la moyenne (notation « espérance » des probabilistes), la première écriture se lit : $\text{cov}(X\,;Y) = E(XY) - E(X)E(Y)$ — « moyenne des produits moins produit des moyennes ». Cas particulier précieux : $\text{cov}(x\,;x) = V(x)$ — la covariance de x avec lui-même *est* sa variance (les deux écritures deviennent celles de König-Huygens).

COMMENT ON L'OBTIENT ? — [

Trois propriétés démontrées pas à pas] **Propriété 1 — Symétrie :** $\text{cov}(x\,;y) = \text{cov}(y\,;x)$. Évident sur l'écriture centrée : $(x_i - \bar{x})(y_i - \bar{y}) = (y_i - \bar{y})(x_i - \bar{x})$ — la multiplication commute. ✓

Propriété 2 — Effet d'un changement affine sur y : si $y' = \alpha y + \beta$ (avec α, β réels, $\alpha \neq 0$), alors

$$\text{cov}(x\,;y') = \alpha\ \text{cov}(x\,;y)$$

Démonstration. La nouvelle moyenne : $\bar{y}' = \alpha\bar{y} + \beta$ (la moyenne d'une somme est la somme des moyennes, Partie 1). Calcul direct sur la première écriture, une étape par ligne :

$$\text{cov}(x\,;y') = \frac{\sum n_i x_i(\alpha y_i + \beta)}{N} - \bar{x}(\alpha\bar{y} + \beta) = \alpha\frac{\sum n_i x_i y_i}{N} + \beta\frac{\sum n_i x_i}{N} - \alpha\bar{x}\bar{y} - \beta\bar{x}$$

Le terme en β se simplifie : $\beta\bar{x} - \beta\bar{x} = 0$. Reste $\alpha\left(\frac{\sum n_i x_i y_i}{N} - \bar{x}\bar{y}\right) = \alpha\ \text{cov}(x\,;y)$. ■

Conséquence sur la pente : $a' = \dfrac{\text{cov}(x\,;y')}{V(x)} = \alpha\, a$ — **changer l'unité de y multiplie la pente** dans le même rapport (et change b en conséquence). La covariance, elle, **voit** ce changement : c'est qu'elle a des unités.

Les unités de la covariance — le fil rouge sorgho en tonnes puis en kilogrammes

Sur le fil rouge sorgho : $\text{cov}(x\,;y) = 10{,}4$ quand x est en dm et y en t/ha — la covariance s'exprime en **dm × t/ha**. Passons y aux kg/ha : $y' = 1\,000\,y$, donc $\bar{y}' = 10\,000$ et, par la propriété 2 : $\text{cov}(x\,;y') = 1\,000 \times 10{,}4 = 10\,400$ *(vérification directe :* $\sum x_i y_i' = 2\sum x_i y_i + 0 =$

704, *donc* $\text{cov} = \frac{704}{5} - 6 \times 10 = 140{,}8 \times 10 - 60$ *; reprenons proprement :* $\sum x_i y'_i = 1\,000 \times 352 = 352\,000$, *d'où* $\text{cov} = \frac{352\,000}{5} - 6 \times 10\,000 = 70\,400 - 60\,000 = 10\,400$ ✓*).* La pente suit : $a' = \dfrac{10\,400}{8} = 1\,300$ kg/ha par dm $= 1{,}3$ t/ha par dm — même droite, autre unité. ✓

$\text{cov}(x\,;y) = 0$ ne signifie pas « aucune liaison » — la parabole

Les points $(-2\,;4)$, $(-1\,;1)$, $(0\,;0)$, $(1\,;1)$, $(2\ 4)$ sont *exactement* sur la parabole $y = x^2$ (Partie 3). Or $\sum x_i y_i = -8 - 1 + 0 + 1 + 8 = 0$, donc $\text{cov} = 0 - 0 \times 2 = 0$ et $r = 0$. **Leçon :** les écarts $x_i - \bar{x}$ négatifs et positifs se compensent *symétriquement* : le produit croisé s'annule alors même que la liaison est parfaite — mais courbe. La covariance (comme r) ne mesure que la liaison **rectiligne** ; un r proche de 0 impose de *regarder le nuage* avant de conclure à l'absence de relation.

ERREUR FRÉQUENTE — La covariance a des unités, le coefficient r n'en a pas

cov s'exprime en (unité de x) × (unité de y) : dm×t/ha, mm×kg/ha, points×points… Comparer des covariances entre deux études d'unités différentes **n'a aucun sens** ; changer l'unité de y change la covariance (propriété 2). Le coefficient r, lui, divise par $\sigma_x \sigma_y$ (mêmes unités que cov) : le résultat est un **nombre pur**, sans unité, toujours entre -1 et 1 — c'est lui (et seulement lui) qu'on compare entre études, seuils à l'appui.

QUAND L'UTILISER ? — [

Quand manipuler la covariance ?]

- « **Montrer que** $\text{cov}(x\,;x) = V(x)$ » ou « **montrer les deux écritures de** cov » : questions de cours directes (Partie 2 + cette section) ;
- **Changement d'unité en cours d'exercice** (« même étude, rendement exprimé en kg ») : ne jamais recalculer tout — appliquer cov $\to \alpha\,$cov, $a \to \alpha a$;
- **Signe de la pente** : signe(a) = signe cov, car $V(x) > 0$ — première vérification de tout calcul de droite ;
- cov ≈ 0 **avec un nuage visiblement courbe** : ne pas conclure « pas de liaison », changer de regard (changement de variable, section 6).

5. Le coefficient r : le calcul complet, les seuils, la borne $|r| \leq 1$

MÉTHODE — [

Calculer r — la recette (rappel de la Partie 3, appliquée au mil)] (1) Rappeler $\bar{x}$, $\bar{y}$, cov, $V(x)$ (déjà calculés pour la droite) ; (2) calculer $V(y) = \frac{\sum y_i^2}{n} - \bar{y}^2$; (3) racines : $\sigma_x = \sqrt{V(x)}$, $\sigma_y = \sqrt{V(y)}$ — arrondir *ici* seulement ; (4) quotient $r = \dfrac{\text{cov}}{\sigma_x\,\sigma_y}$; (5) conclure : force ($|r|$ vs 0,9), sens (signe), contrôle $a = r\,\sigma_y/\sigma_x$.

Le calcul complet de r sur les données du mil — chaque ligne justifiée

Données (section 7) : 6 années, x = pluviométrie (mm), y = rendement du mil (kg/ha). Déjà connu : $\text{cov}(x\,;y) = 16\,600$, $V(x) = 5\,600$, $V(y) = 50\,400$, $a = \frac{83}{28}$.

Étape 1 — Les écart-types (arrondi seulement ici) :

$$\sigma_x = \sqrt{5\,600} \approx 74{,}83 \qquad \text{et} \qquad \sigma_y = \sqrt{50\,400} \approx 224{,}50$$

Étape 2 — Le produit, gardé exact le plus longtemps possible :

$$\sigma_x\,\sigma_y = \sqrt{5\,600} \times \sqrt{50\,400} = \sqrt{5\,600 \times 50\,400} = \sqrt{282\,240\,000} = 16\,800$$

(le produit des racines est la racine du produit ; et $16\,800^2 = 282\,240\,000$ exactement — d'où un quotient exact).

Étape 3 — Le quotient :

$$r = \frac{\text{cov}(x\,;y)}{\sigma_x\,\sigma_y} = \frac{16\,600}{16\,800} = \frac{83}{84} \approx 0{,}99$$

Étape 4 — Contrôle de cohérence (en or) : $\dfrac{\sigma_y}{\sigma_x} = \sqrt{\dfrac{50\,400}{5\,600}} = \sqrt{9} = 3$, donc la formule $a = r\,\dfrac{\sigma_y}{\sigma_x}$ prédit $a = \dfrac{83}{84} \times 3 = \dfrac{83}{28}$ — **exactement** la pente de la section 7 ✓. **Étape 5 — Seconde route (écriture centrée) :** $\sum(x_i - \bar{x})(y_i - \bar{y}) = 99\,600$, $\sum(x_i - \bar{x})^2 = 33\,600$, $\sum(y_i - \bar{y})^2 = 302\,400$, d'où

$$r = \frac{99\,600}{\sqrt{33\,600 \times 302\,400}} = \frac{99\,600}{100\,800} = \frac{83}{84}\ \checkmark$$

— deux routes, un même quotient exact.

Lire r : quatre valeurs, quatre verdicts

La grille des seuils (Partie 3) : $|r| \geq 0{,}9$ très forte ; $0{,}7 \leq |r| < 0{,}9$ forte ; $0{,}5 \leq |r| < 0{,}7$ modérée ; $|r| < 0{,}5$ faible — et le signe donne le sens.

r	force ($\lvert r\rvert$)	verdict rédigé
0,91	très forte	ajustement justifié ; liaison croissante ($r > 0$)
−0,55	modérée	liaison réelle mais faible ; prudence, ajustement discutable
0,38	faible	**ne pas prédire** avec la droite
−0,999	très forte	ajustement justifié ; liaison **décroissante** ($r < 0$, pente $a < 0$)

Remarque : $-0{,}999$ est la plus **forte** des quatre — le signe ne dit rien de la force ; $|r|$ dit tout.

PROPRIÉTÉ — [

La borne $-1 \le r \le 1$ (énoncé admis) — et son intuition] Pour toute série double, $-1 \le r \le 1$. Les cas limites $r = \pm 1$ correspondent à un nuage **exactement aligné** (croissant pour $r = 1$, décroissant pour $r = -1$). *Énoncé admis*, avec l'intuition suivante (Partie 3) : la somme minimale des carrés des écarts vaut $S_{\min} = n\,V(y)\,(1 - r^2)$, qui ne peut pas être négative — donc $1 - r^2 \ge 0$, donc $r^2 \le 1$. Autrement dit : r^2 mesure la **part de variance expliquée** par la droite, et une part ne peut pas dépasser $100\,\%$.

COMMENT ON L'OBTIENT ? — [

Deux démonstrations accessibles : le cas aligné, puis la borne complète] **A — Si les points sont exactement alignés, $r = \pm 1$ (démonstration).** Supposons $y_i = p\,x_i + q$ pour tout i, avec $p \neq 0$. Alors $\bar{y} = p\bar{x} + q$, donc $y_i - \bar{y} = p(x_i - \bar{x})$, et :

$$\operatorname{cov}(x\,;y) = \frac{1}{n}\sum (x_i - \bar{x})\,p(x_i - \bar{x}) = p\,V(x)\ ; \qquad V(y) = \frac{1}{n}\sum p^2 (x_i - \bar{x})^2 = p^2\,V(x)$$

D'où $r = \dfrac{p\,V(x)}{\sigma_x \cdot |p|\,\sigma_x} = \dfrac{p}{|p|}$: valant 1 si $p > 0$ et -1 si $p < 0$. ■ *Contrôle numérique :* points $(0\,;1)$, $(1\,;4)$, $(2\,;7)$ — alignés sur $y = 3x + 1$: cov $= 2$, $V(x) = \frac{2}{3}$, $V(y) = 6$, donc $r = \dfrac{2}{\sqrt{2/3}\,\sqrt{6}} = \dfrac{2}{2} = 1$ ✓ (et $a = \frac{2}{2/3} = 3$, $b = 4 - 3 = 1$: la droite retrouvée).

B — La borne générale par le discriminant (au-delà de l'admis, mais à ta portée). Posons, avec les sommes centrées $A = \sum (x_i - \bar{x})^2 > 0$, $B = \sum (x_i - \bar{x})(y_i - \bar{y})$, $C = \sum (y_i - \bar{y})^2$, et considérons, pour tout réel t :

$$q(t) = \sum \left[(y_i - \bar{y}) - t(x_i - \bar{x})\right]^2 = At^2 - 2Bt + C \ \ge\ 0$$

(une somme de carrés n'est jamais négative — le terme en t vient de $\sum (x_i - \bar{x})^2 = A$ et le terme constant de $\sum (y_i - \bar{y})^2 = C$). Un trinôme en t à coefficient dominant $A > 0$ qui reste ≥ 0 pour tout t a un **discriminant négatif ou nul** (sinon il couperait l'axe deux fois et prendrait des valeurs négatives) :

$$\Delta = 4B^2 - 4AC \le 0 \quad \Longrightarrow \quad B^2 \le AC \quad \Longrightarrow \quad r^2 = \frac{B^2/n^2}{(A/n)(C/n)} = \frac{B^2}{AC} \le 1$$

Donc $|r| \le 1$. ■ *Vérification sur le fil rouge sorgho :* $A = 40$, $B = 52$, $C = 70$; $\Delta = 4(2\,704 - 2\,800) = -384 < 0$ ✓ et $r^2 = \frac{2\,704}{2\,800} = \frac{169}{175} \approx 0{,}97 \le 1$ ✓ — cohérent avec le $r \approx 0{,}98$ de la Partie 3.

ERREUR FRÉQUENTE — Trois erreurs classiques sur r

(1) **Arrondir les écart-types avant le quotient** : $\sigma_y \approx 224$ au lieu de 224,50 peut faire tomber r sous le seuil de décision — garde les racines jusqu'à la fin. (2) **Lire r comme un pourcentage** : $r = 0{,}7$ ne signifie pas « $70\,\%$ de réussite » ; c'est r^2 qui s'interprète en part de variance (et il vaut $49\,\%$). (3) **Tirer une cause d'un r fort** : la corrélation n'est pas la causalité (Partie 3, section 8) — un r fort prouve que les séries varient ensemble, rien de plus.

QUAND L'UTILISER ? — [

Quand calculer r ?]

- « **Montrer que l'ajustement linéaire est justifié** » : calcul de r + comparaison à 0,9 + phrase type ;
- « **La droite est-elle représentative ? Peut-on prédire ?** » : même chaîne — et on ne prédit jamais si $|r| < 0{,}5$;
- **Contrôle croisé** : après la droite et r, vérifier $a = r\,\sigma_y/\sigma_x$ — elle recolle les deux calculs au millième près ;
- **Un r impossible trouvé** ($|r| > 1$) : signal d'erreur — revérifier $V(y)$ (souvent l'oubli d'un y_i^2 dans le tableau).

À TOI DE JOUER — Un r sans données brutes

Une étude donne $\text{cov}(x\,;y) = -3$, $V(x) = 3$ et $V(y) = 12$. Calculer r, puis juger la liaison : force, sens, et verdict sur l'ajustement.

Correction

$\sigma_x\,\sigma_y = \sqrt{3} \times \sqrt{12} = \sqrt{36} = 6$, donc

$$r = \frac{-3}{6} = -0{,}5$$

Force : $|r| = 0{,}5$ — à la **frontière faible/modérée** (premier palier de la grille) : liaison réelle mais nettement insuffisante pour un ajustement sérieux. Sens : $r < 0$, liaison **décroissante** (et on peut prédire $a = r\,\sigma_y/\sigma_x < 0$). **Verdict :** on ne construit pas de prévision sur cette droite. ✓

6. Quand le nuage n'est pas droit : le changement de variable $z = f(y)$

POURQUOI ? — [

Pourquoi forcer une droite sur un nuage qui se courbe ?] Parce que la droite est le seul modèle du programme… mais qu'on peut **changer ce qu'on met dedans**. Si le nuage $(x_i\,;y_i)$ s'incurve, on cherche une transformation f qui **redresse** la liaison : on pose $z_i = f(y_i)$, et si cette fois les points $(x_i\,;z_i)$ sont presque alignés, on ajuste *eux* par les moindres carrés, puis on **revient** à y en inversant f. Le logarithme traite les croissances multiplicatives (Partie 3) ; ici on installe l'autre outil standard : la racine carrée, pour les croissances qui s'accélèrent régulièrement (courbes paraboliques). Même scénario, même rigueur — juste une autre transformation.

COMMENT ON L'OBTIENT ? — [

La méthode générale — et pourquoi elle marche] **Principe :** une transformation f bien choisie *linéarise* la liaison. Deux familles usuelles :

- **croissance multiplicative** (les y_i se multiplient par un facteur voisin à chaque pas de x) $\to$ poser $z = \ln y$: le logarithme transforme les produits en sommes, donc une loi $y = Cm^x$ devient la droite $z = (\ln m)x + \ln C$;
- **croissance quadratique** (les *différences* $y_{i+1} - y_i$ augmentent de façon régulière) $\to$ poser $z = \sqrt{y}$: si $y = (ax+b)^2$ alors $z = ax + b$ *exactement*, car $\sqrt{y}$ et $ax + b$ sont positifs ensemble.

Le point de vigilance central : on ajuste z **en fonction de** x (les moindres carrés s'appliquent au couple $(x_i\,;z_i)$, écarts verticaux) — jamais l'inverse. Puis on revient à y par $y = f^{-1}(z)$: pour $z = ax + b$ obtenu, ln donne $y = \mathrm{e}^b\mathrm{e}^{ax}$ et $\sqrt{\ }$ donne $y = (ax+b)^2$. Tant que la transformation est inversible sur les données (les y_i positifs, ce qui est acquis pour ln et $\sqrt{\ }$), le chemin aller-retour est licite.

MÉTHODE — [

Le changement de variable en 5 étapes]

1. **Diagnostiquer** : nuage courbe ? différences $y_{i+1} - y_i$ régulières et croissantes $\to$ parabole $\to z = \sqrt{y}$; rapports y_{i+1}/y_i voisins $\to$ exponentiel $\to z = \ln y$;
2. **Transformer** : dresser la colonne $z_i = f(y_i)$ (valeurs exactes quand c'est possible) ;
3. **Vérifier l'alignement** des $(x_i\,;z_i)$: à l'œil, ou par le r de la série transformée (il doit viser ± 1) ;
4. **Ajuster** : moindres carrés sur $(x\,;z) \to z = ax + b$ (avec contrôle $G \in D$) ;
5. **Revenir** : $y = (ax+b)^2$ ou $y = \mathrm{e}^b\mathrm{e}^{ax}$, prédire, et **conclure en unités de** y.

Exemple complet : $z = \sqrt{y}$ sur la pépinière — pas à pas

Énoncé. Dans une pépinière de la région d'Abidjan, on relève la hauteur y (en cm) d'un plant de cacaoyer selon le nombre x de semaines après repiquage :

x (semaines)	1	2	3	4	5
y (cm)	4	9	16	25	36

On demande un modèle de croissance, puis une prévision pour $x = 6$.

Étape 1 — Diagnostic : le linéaire déçoit. Les différences $y_{i+1} - y_i$ valent $5\,;\,7\,;\,9\,;\,11$: elles **augmentent** de 2 à chaque pas — signature d'une croissance parabolique, pas rectiligne. Vérifions par les moindres carrés sur $(x\,;y)$: $\bar{x} = 3$, $\bar{y} = 18$; sommes $\sum x_i^2 = 55$, $\sum y_i^2 = 2\,274$, $\sum x_i y_i = 350$; puis

$$\text{cov} = \frac{350}{5} - 3 \times 18 = 16 \ ; \qquad V(x) = \frac{55}{5} - 9 = 2 \ ; \qquad a = 8, \quad b = 18 - 24 = -6$$

Linéaire : $y = 8x - 6$. Il passe le contrôle G ($8 \times 3 - 6 = 18$ ✓) et le coefficient r est **trompeusement élevé** :

$$V(y) = \frac{2\,274}{5} - 324 = 454{,}8 - 324 = 130{,}8 \ ; \qquad r = \frac{16}{\sqrt{2}\sqrt{130{,}8}} = \frac{16}{\sqrt{261{,}6}} \approx 0{,}99$$

Mais regarde les **résidus** de $y = 8x - 6$: prévisions $2\,;\,10\,;\,18\,;\,26\,;\,34$, donc écarts $+2\,;\,-1\,;\,-2\,;\,-1\,;\,+2$ — ils s'enchaînent en **plus, moins, plus** : le nuage ondule *systématiquement* autour de la droite (trop bas au milieu, trop haut aux extrémités), et $S = 4+1+4+1+4 = 14$ de carrés résiduels. Un r élevé **ne garantit pas** que le modèle linéaire soit le bon.

Étape 2 — Transformer. Les y_i sont des carrés parfaits : $z_i = \sqrt{y_i} = 2\,;\,3\,;\,4\,;\,5\,;\,6$. Les différences des z_i valent toutes 1 : **droite en vue**.

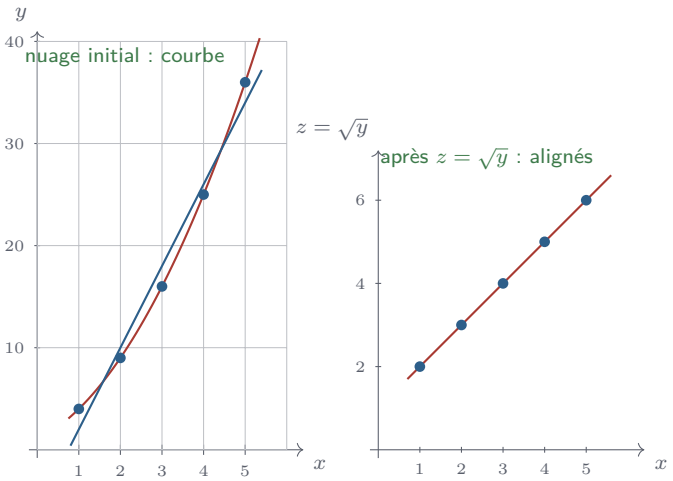
Étape 3 — Ajuster $(x\,;z)$. $\bar{z} = 4$, $\sum x_i z_i = 2 + 6 + 12 + 20 + 30 = 70$:

$$\text{cov}(x\,;z) = \frac{70}{5} - 3 \times 4 = 2 \ ; \qquad a = \frac{2}{2} = 1 \ ; \qquad b = 4 - 1 \times 3 = 1$$

$z = x + 1$ — et $V(z) = \frac{90}{5} - 16 = 2$ donne $r = \dfrac{2}{\sqrt{2}\sqrt{2}} = 1$: **alignement parfait**. Contrôle : chaque point vérifie $z_i = x_i + 1$ ✓.

Étape 4 — Revenir à y. $z = x + 1 \iff \sqrt{y} = x + 1 \iff \boxed{y = (x+1)^2}$ — le modèle de croissance. Vérification sur les données : $(1+1)^2 = 4$, $(2+1)^2 = 9$, …, $(5+1)^2 = 36$ ✓.

Étape 5 — Prédire et comparer. Pour $x = 6$ semaines : modèle $y = (6+1)^2 = 49$ cm. Le linéaire aurait donné $8 \times 6 - 6 = 42$ cm : **7 cm d'écart** (14 %) — voilà ce que le mauvais modèle coûtait. Et la somme des carrés résiduels passe de 14 (linéaire) à 0 (modèle exact). ✓



PROPRIÉTÉ — [

Les deux transformations usuelles du programme]

Transformation	Modèle obtenu	Quand l'utiliser
$z = \ln y$	$y = \mathrm{e}^b\,\mathrm{e}^{ax}$	croissance **multiplicative** : les rapports y_{i+1}/y_i sont voisins d'une constante ; y se multiplie quand x s'additionne (Partie 3)
$z = \sqrt{y}$	$y = (ax+b)^2$	croissance **parabolique** : les différences $y_{i+1} - y_i$ croissent régulièrement ; données « carrés » ou effet qui s'accélère

Dans les deux cas : ajuster z *en fonction de* x, juger avec le r de la série transformée, revenir à y.

ASTUCE — Le détecteur rapide — deux lignes de calcul avant tout modèle

Pose les **différences** $\Delta_i = y_{i+1} - y_i$ et les **rapports** y_{i+1}/y_i : différences $\approx$ constantes $\to$ droite, reste en linéaire ; différences croissant d'un pas constant (ici : $+2$ à chaque fois) $\to$ parabole, pose $z = \sqrt{y}$; rapports $\approx$ constante $\to$ exponentiel, pose $z = \ln y$. Dix secondes de diagnostic économisent un ajustement faux — et l'étape 1 de l'exemple montre qu'il faut aussi **lire les résidus** : un r élevé avec des résidus qui alternent $+, -, +, -$ est un signal d'alarme, pas un feu vert.

ERREUR FRÉQUENTE — Deux façons de rater le retour

(1) **Répondre en** z : à la question « quelle hauteur pour $x = 6$ semaines ? », répondre « $z = 7$ » est **faux** — z est une racine de hauteur ; on revient toujours : $y = 7^2 = 49$ cm. (2) **Ajuster dans le mauvais sens** : on pose $z = f(y)$ et on ajuste z *en fonction de* x ; ajuster x en fonction de z donne une autre droite (et un autre modèle) — c'est le même piège que la régression de x en y de la section 8.

QUAND L'UTILISER ? — [

Quand changer de variable ?]

- **Le nuage s'incurve** visiblement (montée qui s'accentue ou s'essouffle) ;
- **Un** r **médiocre** alors que la liaison est évidente à l'œil (Partie 3, parabole) ;
- **Un** r **élevé mais des résidus systématiques** $(+, -, +, -)$ — le linéaire rate une structure ;
- **L'énoncé parle** de « croissance », de « doublement », ou donne des y qui se multiplient ou dont les différences croissent régulièrement ;
- **Les données sont des carrés** (ou des racines évidentes) : $\sqrt{y}$ rend le tableau lisible.

7. Étude complète — pluviométrie et rendement du mil (Niamey)

Voici l'enchaînement intégral, du tableau brut à la prévision commentée : c'est le gabarit de la question 3 de tout sujet de statistiques. Les données proviennent d'un service agricole : 6 années consécutives (2019–2024) dans une zone de maraîchage près de **Niamey** — pluviométrie annuelle x_i (mm) et rendement moyen du mil y_i (kg/ha).

Énoncé — le sujet complet

Année	Pluviométrie x_i (mm)	Rendement y_i (kg/ha)
2019	320	660
2020	340	600
2021	400	840
2022	440	960
2023	500	1 140
2024	520	1 200

1. Décrire l'allure du nuage et calculer le point moyen G. **2.** Déterminer la droite des moindres carrés (valeurs exactes) et contrôler $G \in D$. **3.** Calculer r et juger l'ajustement. **4.** Prévoir le rendement pour 480 mm, puis pour 700 mm, en qualifiant chaque prévision. **5.** Interpréter la pente en contexte.

Étapes 1–2 — allure du nuage, point moyen

Allure. Les points montent globalement de gauche à droite, avec un nuage assez allongé — en notant le point $(340\,;600)$, légèrement **bas** (année 2020 : pluie correcte, rendement décevant). Un ajustement linéaire paraît envisageable ; on le confirmera par r.
Point moyen, un calcul par ligne :

$$\bar{x} = \frac{320+340+400+440+500+520}{6} = \frac{2\,520}{6} = 420 \ ;$$
$$\bar{y} = \frac{660+600+840+960+1\,140+1\,200}{6} = \frac{5\,400}{6} = 900$$

Résultat : $\boxed{G(420\,;900)}$ — 420 mm de pluie, 900 kg/ha de mil.

Étape 3 — le tableau de calcul unique, puis variances et covariance

Chaque valeur apparaît une fois ($n = 6$) ; ce tableau sert à $V(x)$, $V(y)$ et cov :

i	x_i	y_i	x_i^2	y_i^2	$x_i y_i$
1	320	660	102 400	435 600	211 200
2	340	600	115 600	360 000	204 000
3	400	840	160 000	705 600	336 000
4	440	960	193 600	921 600	422 400
5	500	1 140	250 000	1 299 600	570 000
6	520	1 200	270 400	1 440 000	624 000
Σ	2 520	5 400	1 092 000	5 162 400	2 367 600

Variances et covariance, une transformation par ligne :

$$V(x) = \frac{1\,092\,000}{6} - 420^2 = 182\,000 - 176\,400 = 5\,600 \ ;$$
$$V(y) = \frac{5\,162\,400}{6} - 900^2 = 860\,400 - 810\,000 = 50\,400$$

$$\operatorname{cov}(x\,;y) = \frac{2\,367\,600}{6} - 420 \times 900 = 394\,600 - 378\,000 = 16\,600$$

Résultats : $V(x) = 5\,600$; $V(y) = 50\,400$; $\operatorname{cov}(x\,;y) = 16\,600$ — positive, comme le nuage croissant.

Étape 4 — la droite : pente exacte, ordonnée, contrôle

Pente, en gardant la fraction exacte :

$$a = \frac{\operatorname{cov}(x\,;y)}{V(x)} = \frac{16\,600}{5\,600} = \frac{83}{28} \approx 2{,}96$$

Ordonnée à l'origine (avec la valeur exacte de a ; noter $420/28 = 15$) :

$$b = \bar{y} - a\,\bar{x} = 900 - \frac{83}{28} \times 420 = 900 - 83 \times 15 = 900 - 1\,245 = -345$$

Équation finale : $\boxed{D : y = \frac{83}{28}\,x - 345 \ \approx \ 2{,}96\,x - 345}$ — et b **négatif** : parfaitement possible, pas d'affolement.

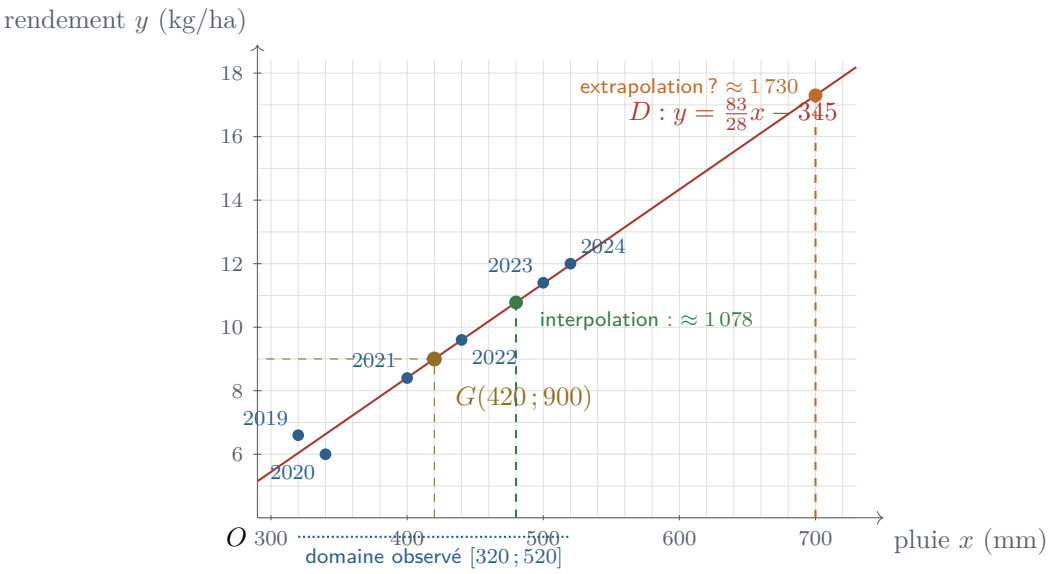
Contrôle systématique : $\frac{83}{28} \times 420 - 345 = 1\,245 - 345 = 900 = \bar{y}$ ✓ — $G(420\,;900)$ appartient à D, comme le veut la théorie (section 3).

Étape 5 — le coefficient r et le jugement

$$\sigma_x = \sqrt{5\,600} \approx 74{,}83 \ ; \qquad \sigma_y = \sqrt{50\,400} \approx 224{,}50 \ ; \qquad \sigma_x\,\sigma_y = \sqrt{282\,240\,000} = 16\,800$$

$$r = \frac{\operatorname{cov}(x\,;y)}{\sigma_x\,\sigma_y} = \frac{16\,600}{16\,800} = \frac{83}{84} \approx 0{,}99$$

Jugement rédigé : comme $|r| \approx 0{,}99 \geq 0{,}9$, la corrélation linéaire est **très forte** et l'ajustement du nuage par la droite D est **justifié** ; $r > 0$: la liaison est **croissante**, cohérente avec le nuage et avec $a > 0$. *Contrôle de cohérence :* $\sigma_y/\sigma_x = \sqrt{9} = 3$, donc $a = r \times 3 = \frac{83}{84} \times 3 = \frac{83}{28}$ ✓ — les deux calculs se recollent *exactement*.



Étape 6 — prévisions en trois temps

Pour $x = 480$ mm. $480 \in [320\,;520]$: **interpolation**, fiable ($|r| \geq 0{,}9$). Calcul, une transformation par ligne :

$$y = \frac{83}{28} \times 480 - 345 = \frac{9\,960}{7} - 345 = \frac{7\,545}{7} \approx 1\,077{,}9$$

Conclusion : on prévoit un rendement d'environ **1 078 kg/ha** pour 480 mm de pluie (interpolation).
Pour $x = 700$ mm. $700 \notin [320\,;520]$: **extrapolation**, risquée. Le calcul donne :

$$y = \frac{83}{28} \times 700 - 345 = 2\,075 - 345 = 1\,730$$

soit 1 730 kg/ha — mais **hors du domaine observé**, rien ne garantit que la tendance rectiligne persiste : à 700 mm, le sol peut être **saturé** (eaux stagnantes, lessivage), des maladies se développer. On annonce le résultat *en le qualifiant* d'extrapolation risquée, ou l'on s'abstient.

Étape 7 — interprétation en contexte, puis les résidus racontent l'histoire

La pente en français. $a = \frac{83}{28} \approx 2{,}96$: dans la plage étudiée, chaque millimètre de pluie supplémentaire correspond, en moyenne, à environ 2,96 kg/ha de rendement en plus (soit ≈ 296 kg/ha pour 100 mm) — une information directement utile au conseil agricole. Quant à $b = -345$, il se lit « à pluie nulle » : hors du domaine observé, cette valeur n'a **pas d'interprétation physique** — c'est un paramètre du modèle, pas une prévision.
Pour aller plus loin — les résidus. Les écarts à la droite valent, dans l'ordre des années :

$$\frac{395}{7} \approx 56{,}4\,; \quad -\frac{440}{7} \approx -62{,}9\,; \quad -\frac{5}{7} \approx -0{,}7\,; \quad \frac{5}{7} \approx 0{,}7\,; \quad \frac{20}{7} \approx 2{,}9\,; \quad \frac{25}{7} \approx 3{,}6 \quad \text{(kg/ha)}$$

Leur somme est **exactement nulle** ($395 - 440 - 5 + 5 + 20 + 25 = 0$) — la propriété démontrée en section 3 ✓. Leur somme des carrés vaut $S_{\min} = \frac{350\,700}{49} = \frac{50\,100}{7} \approx 7\,157$ (kg/ha)^2, et l'on retrouve $S_{\min} = nV(y)(1 - r^2) = 6 \times 50\,400 \times \left(1 - \frac{6\,889}{7\,056}\right) = \frac{50\,100}{7}$ ✓. Le plus gros résidu est celui de 2020 (point bas annoncé dès l'étape 1) : la droite est bonne ($r^2 \approx 0{,}976$, soit $\approx 98\,\%$ de variance expliquée), mais cette année-là un autre facteur (semences, sol, calendrier cultural) a pesé — les statistiques détectent l'écart, l'agronomie l'explique.

ERREUR FRÉQUENTE — Le piège de l'arrondi trop précoce

Si on arrondit $a \approx 2{,}96$ *avant* de calculer b :

$$b = 900 - 2{,}96 \times 420 = 900 - 1\,243{,}2 = -343{,}2 \quad \text{au lieu de} \quad -345$$

et la prévision devient $2{,}96 \times 480 - 345 \approx 1\,075{,}8$ au lieu de $\approx 1\,077{,}9$. L'écart semble petit ici, mais il peut coûter cher quand les nombres sont grands — et le contrôle $G \in D$ **ne détectera pas** l'erreur (la section 3 l'explique : b calculé à partir d'un a arrondi garde le passage par G). **Règle d'or :** valeurs exactes (fractions, racines) jusqu'au dernier résultat, arrondi seulement à la fin.

RÉFLEXE RÉDACTION — La rédaction complète de l'étude — les six phrases types

(1) « Le nuage est allongé et croissant : un ajustement linéaire paraît envisageable. » (2) « $\bar{x} = 420$, $\bar{y} = 900$: le point moyen est $G(420\,;900)$. » (3) « $a = \frac{83}{28} \approx 2{,}96$ et $b = -345$: $D : y = \frac{83}{28}x - 345$; contrôle : $D(420) = 900 = \bar{y}$. » (4) « Comme $|r| = \frac{83}{84} \approx 0{,}99 \geq 0{,}9$, la corrélation est très forte et l'ajustement linéaire est justifié ; $r > 0$: liaison croissante. » (5) « 480 mm est dans le domaine observé : interpolation fiable, $y \approx 1\,078$ kg/ha. » (6) « 700 mm est en dehors : extrapolation risquée (1 730 kg/ha), la tendance peut changer hors du domaine observé. » Six phrases, la structure entière de la question.

8. Le grand piège : régression de y en x ou de x en y ?

POURQUOI ? — [

Pourquoi existe-t-il DEUX droites ?] La droite des moindres carrés $y = ax+b$ minimise les écarts **verticaux** : elle suppose qu'on cherche à *expliquer y par x* (prévoir le rendement connaissant la pluie). Mais certains énoncés demandent l'inverse : *estimer x connaissant y* (quelle surface a été semée, connaissant la récolte ?). Alors il faut minimiser les écarts **horizontaux** — c'est-à-dire échanger les rôles de x et de y. Le résultat n'est **pas** « la droite inverse » : c'est une vraie droite des moindres carrés, avec ses propres coefficients — et les deux droites ne coïncident que dans le cas limite d'un nuage parfaitement aligné.

COMMENT ON L'OBTIENT ? — [

La droite de régression de x en y — même mécanique, rôles échangés] Pour ajuster x en fonction de y, on minimise $\sum(x_i - a'y_i - b')^2$: la démonstration de la section 2 s'applique **telle quelle** en échangeant systématiquement $x \leftrightarrow y$ (les carrés ne voient pas la différence). On obtient :

$$\boxed{a' = \frac{\text{cov}(x\,;y)}{V(y)} \qquad \text{et} \qquad b' = \bar{x} - a'\,\bar{y}}$$

— l'équation s'écrit $x = a'y + b'$: on *exprime* x à partir de y. *Justification de la substitution :* dans la démonstration, $V(x)$ jouait le rôle « variance de la variable explicative » ; ici l'explicative est y, donc le dénominateur devient $V(y)$, et le point moyen s'écrit $b' = \bar{x} - a'\bar{y}$. Ni le numérateur (cov) ni le point G ne changent.

PROPRIÉTÉ — [

Trois propriétés des deux droites]

1. **Les deux passent par** $G(\bar{x}\,;\bar{y})$ — la preuve de la section 3 vaut pour chaque droite (l'équation normale donne $a'\bar{y} + b' = \bar{x}$) ;
2. **Le produit des pentes vaut** r^2 : $a \times a' = \dfrac{\text{cov}^2}{V(x)\,V(y)} = r^2$ *(produit direct des définitions).* Conséquence : comme $r^2 \leq 1$, on a $|a'| \leq 1/|a|$… et surtout, $a \times a' = 1$ **seulement si** $r^2 = 1$;
3. **Les deux droites coïncident** si et seulement si les points sont exactement alignés ($|r| = 1$) : alors x en fonction de y est *vraiment* l'inverse de y en fonction de x. Sinon, elles sont distinctes — c'est le piège.

Les deux droites du fil rouge sorgho — comparaison complète

Fil rouge (Partie 2) : $\bar{x} = 6$, $\bar{y} = 10$, cov $= 10{,}4$, $V(x) = 8$, $V(y) = 14$, droite $D : y = 1{,}3x + 2{,}2$, $r \approx 0{,}98$.

La droite de régression de x en y :

$$a' = \frac{\text{cov}(x\,;y)}{V(y)} = \frac{10{,}4}{14} \approx 0{,}74 \ ; \qquad b' = \bar{x} - a'\bar{y} = 6 - 0{,}74 \times 10 \approx -1{,}43$$

D' : $x \approx 0{,}74\,y - 1{,}43$. **Contrôles :** $0{,}74 \times 10 - 1{,}43 \approx 6 = \bar{x}$ ✓ — $G \in D'$; et $a \times a' \approx 1{,}3 \times 0{,}743 \approx 0{,}966 = r^2$ ✓ (exactement $\frac{169}{175}$, comme en Partie 3).

Comparaison avec « l'inverse de D » (la mauvaise route) : inverser $y = 1{,}3x + 2{,}2$ donne $x = \dfrac{y - 2{,}2}{1{,}3} \approx 0{,}77\,y - 1{,}69$ — **ce n'est pas** D' : pente $0{,}77 \neq 0{,}74$, ordonnée $-1{,}69 \neq -1{,}43$. L'écart se mesure sur une question concrète : pour $y = 20$ (une récolte de 20 t/ha projetée), la bonne droite donne $x \approx 0{,}74 \times 20 - 1{,}43 \approx 13{,}4$ dm, l'inverse illicite donne $\approx 13{,}7$ dm : plus de 0,2 dm d'écart, simplement parce que $r^2 \approx 0{,}97 \neq 1$. ✓

ERREUR FRÉQUENTE — Le piège d'examen : inverser au lieu d'ajuster

Quand l'énoncé dit « **estimer x connaissant y** » ou « prévoir la pluie qu'a reçue une parcelle de rendement donné », la réponse **n'est pas** l'inverse de la droite déjà calculée : c'est la droite de régression de x en y, avec $a' = \text{cov}/V(y)$ et $b' = \bar{x} - a'\bar{y}$. Plus $|r|$ s'éloigne de 1, plus les deux réponses divergent — et l'erreur est doublement sanctionnée : le résultat est faux *et* la méthode est fausse. Même vigilance dans le changement de variable : on ajuste z en fonction de x dans le sens demandé par la question. Et dernier cousin du piège : **extrapoler trop loin** — prédire à x très au-delà du domaine observé est une extrapolation risquée qu'il faut nommer comme telle, jamais présenter comme une prévision sûre.

MÉTHODE — [

La checklist finale — les huit réflexes avant de rendre la copie]

1. Un seul **tableau de calcul** propre (colonnes x_i^2, y_i^2, $x_i y_i$ et leurs sommes) : il sert à $V(x)$, $V(y)$, cov ;
2. Calculer $\bar{x}$, $\bar{y}$ et $G(\bar{x}\,;\bar{y})$ **avant** toute autre chose ;
3. Garder les **valeurs exactes** (fractions, racines) jusqu'au résultat final ; arrondir à la fin ;
4. Vérifier que G appartient à D — contrôle systématique, souvent demandé explicitement ;
5. Vérifier que $-1 \leq r \leq 1$ et que r a le **même signe** que a ;
6. Conclure **en contexte** (mm, kg/ha, FCFA) avec une phrase ;
7. **Sens de la régression** : prédire y connaissant $x \to a = \text{cov}/V(x)$; prédire x connaissant $y \to a' = \text{cov}/V(y)$ — ne jamais inverser ;
8. Interpolation **dedans** = légitime ; extrapolation **dehors** = à signaler ; et l'unité de la réponse annoncée.

QUAND L'UTILISER ? — [

Quand utiliser la droite de x en y ?]

- « **Estimer/prévoir x pour $y = \ldots$** » : c'est D', pas l'inverse de D ;
- « **Montrer que les deux droites passent par G** » ou « **calculer $a \times a'$ et comparer à r^2** » : questions de cours directes (cette section) ;
- « **Dans quel cas les deux droites coïncident-elles ?** » : $|r| = 1$, nuage exactement aligné ;
- **Jamais** « pour améliorer la précision de la prédiction de y » : pour prédire y, la droite de y en x est la seule valable.

À TOI DE JOUER — Quand les deux droites coïncident

Une étude donne $\text{cov}(x\,;y)=10$, $V(x)=4$, $V(y)=25$ et $G(3\,;5)$. **a)** Calculer r. **b)** Donner la droite de régression de y en x, puis celle de x en y. **c)** Vérifier $a\times a'=r^2$. **d)** Que remarque-t-on ?

Correction

a) $\sigma_x\,\sigma_y=\sqrt{4}\sqrt{25}=10$, donc $r=\dfrac{10}{10}=1$: nuage **exactement aligné** (croissant). **b)** $a=\dfrac{10}{4}=2{,}5$ et $b=5-2{,}5\times 3=-2{,}5$: D : $y=2{,}5x-2{,}5$ (contrôle : $2{,}5\times 3-2{,}5=5$ ✓). Puis $a'=\dfrac{10}{25}=0{,}4$ et $b'=3-0{,}4\times 5=1$: D' : $x=0{,}4\,y+1$ (contrôle : $0{,}4\times 5+1=3$ ✓). **c)** $a\times a'=2{,}5\times 0{,}4=1=r^2$ ✓. **d)** L'inverse de D est $x=\dfrac{y+2{,}5}{2{,}5}=0{,}4\,y+1$: **exactement** D' — quand $r=1$, les deux droites coïncident, comme le prédit la théorie. ✓

9. Fiches méthodes de la partie 4

Quatre fiches à relire la veille de l'examen. Chacune : le problème, la recette, l'exemple type.

MÉTHODE — [

Fiche n°1 — « Montrer que $a = \dfrac{\operatorname{cov}(x\,;y)}{V(x)}$ » (démonstration type)] **Les lignes à écrire :** (1) poser $S(a,b) = \sum(y_i - ax_i - b)^2$ et rappeler qu'un trinôme $q(u) = \alpha u^2 + \beta u + \gamma$, $\alpha > 0$, est minimal quand $q'(u) = 0$; (2) dériver par rapport à b : $nb = \sum y_i - a\sum x_i$, d'où $b = \bar{y} - a\bar{x}$; (3) dériver par rapport à a : $a\sum x_i^2 + b\sum x_i = \sum x_i y_i$; (4) substituer et conclure : $a\left(\sum x_i^2 - \bar{x}\sum x_i\right) = \sum x_i y_i - \bar{y}\sum x_i$, soit $a\,nV(x) = n\operatorname{cov}$, d'où $a = \frac{\operatorname{cov}}{V(x)}$ et $b = \bar{y} - a\bar{x}$.
Exemple type : les données du mil donnent $a = \frac{16\,600}{5\,600} = \frac{83}{28}$ et $b = 900 - \frac{83}{28} \times 420 = -345$; les équations normales se vérifient exactement ($7\,470 - 2\,070 = 5\,400$; $2\,367\,600 = 2\,367\,600$). ✓

MÉTHODE — [

Fiche n°2 — Prouver que $G \in D$ et utiliser la forme centrée] **Preuve en deux lignes :** par l'équation normale, $b = \bar{y} - a\bar{x}$, donc $a\bar{x} + b = \bar{y}$: le point $G(\bar{x}\,;\bar{y})$ vérifie l'équation — quel que soit a. **Forme centrée :** $y - \bar{y} = a(x - \bar{x})$, pratique pour prédire sans calculer b. **Bonus :** la somme des résidus $\sum(y_i - ax_i - b)$ est nulle — la droite équilibre le nuage.
Exemple type : mil — $y - 900 = \frac{83}{28}(x - 420)$; pour $x = 480$: $y = 900 + \frac{83}{28} \times 60 \approx 1\,077{,}9$ ✓

MÉTHODE — [

Fiche n°3 — Changer de variable (nuage courbe) : $\sqrt{y}$ ou $\ln y$] **Recette :** (1) diagnostiquer : différences $y_{i+1} - y_i$ croissant régulièrement → $z = \sqrt{y}$; rapports y_{i+1}/y_i voisins → $z = \ln y$; (2) dresser la colonne z_i ; (3) vérifier l'alignement des $(x_i\,;z_i)$ (à l'œil ou par le r transformé) ; (4) moindres carrés sur $(x\,;z)$ → $z = ax + b$ (+ contrôle G) ; (5) revenir : $y = (ax+b)^2$ ou $y = \mathrm{e}^b\,\mathrm{e}^{ax}$ — et conclure **en unités de** y.
Exemple type : pépinière — $y = 4\,;\,9\,;\,16\,;\,25\,;\,36$ donne $z = 2\,;\,3\,;\,4\,;\,5\,;\,6$, droite $z = x + 1$ ($r = 1$), modèle $y = (x+1)^2$; prévision $y(6) = 49$ cm (le linéaire disait 42). ✓

MÉTHODE — [

Fiche n°4 — L'étude complète en 8 étapes (et le modèle de tableau)] **Recette :** (1) nuage et allure ; (2) $\bar{x}$, $\bar{y}$, G ; (3) tableau unique (x_i, y_i, x_i^2, y_i^2, x_iy_i, totaux en bas) → $V(x)$, $V(y)$, cov ; (4) $a = \operatorname{cov}/V(x)$ (fraction exacte !), $b = \bar{y} - a\bar{x}$; (5) contrôle $G \in D$; (6) σ_x, σ_y, r, jugement par $|r| \geq 0{,}9$ + signe ; (7) prédiction en trois temps (justifier, calculer, qualifier) ; (8) interprétation de a en contexte + limite de l'extrapolation.
Exemple type : mil — $G(420\,;900)$, $D : y = \frac{83}{28}x - 345$, $r = \frac{83}{84} \approx 0{,}99$, $y(480) \approx 1\,078$ kg/ha (interpolation), $y(700) = 1\,730$ kg/ha (extrapolation risquée), pente $\approx 2{,}96$ kg/ha par mm. ✓

RÉFLEXE RÉDACTION — Les phrases de la partie 4 qui rapportent des points

(1) « **Montrons que** la droite passe par G : $b = \bar{y} - a\bar{x}$ donc $a\bar{x} + b = \bar{y}$. » (2) « Comme $a = \frac{\operatorname{cov}}{V(x)}$ et $V(x) > 0$, le signe de a est celui de cov. » (3) « $a \times a' = \frac{\operatorname{cov}^2}{V(x)V(y)} = r^2 \neq 1$: les deux droites sont distinctes, on utilise D' pour estimer x. » (4) « Le modèle est $y = (x+1)^2$, **pas** $z = x + 1$: on revient à la variable d'origine. » (5) « 700 mm est hors du domaine observé :

extrapolation **risquée**. » Chaque phrase est une démonstration compressée — écris-la, elle vaut des points.

10. Exercices d'entraînement de la partie 4

10.1 QCM — teste tes réflexes (réponses en bas de section)

1. La droite des moindres carrés passe : a) par l'origine b) par le point moyen G c) par le premier point du nuage d) par aucun point particulier
2. Avec $\text{cov}(x\,;y) = 16\,600$ et $V(x) = 5\,600$, la pente vaut : a) $\frac{83}{28} \approx 2{,}96$ b) 0,34 c) 29,6 d) 8,3
3. Si $r = \frac{83}{84}$ et $\sigma_y/\sigma_x = 3$, la pente vaut : a) $\frac{83}{84}$ b) $\frac{83}{28}$ c) $\frac{84}{83}$ d) 3
4. Des points exactement posés sur une parabole symétrique ont : a) $r = 1$ b) $r \approx 0$ c) $r = -1$ d) $r = 0{,}5$
5. Pour estimer x connaissant y, on utilise : a) l'inverse de $D : y = ax + b$ b) la droite de régression de x en y c) la médiane d) c'est impossible
6. Si la série transformée donne $z = x + 1$ exactement, le modèle pour y (avec $z = \sqrt{y}$) est : a) $y = x + 1$ b) $y = (x+1)^2$ c) $y = \sqrt{x} + 1$ d) $y = \text{e}^{x+1}$

10.2 Sujet type BAC n°1 — l'étude complète (riziculture)

Sujet — rendement du riz et pluviométrie, vallée du Bandama

Cinq périmètres rizicoles sont étudiés : pour chacun, la pluviométrie de saison x_i (en dm) et le rendement y_i (en t/ha) :

Périmètre	P1	P2	P3	P4	P5
Pluie x_i (dm)	2	4	6	8	10
Rendement y_i (t/ha)	3	5	7	8	12

a) Calculer le point moyen G, puis la droite de Mayer après découpage $\{P_1, P_2, P_3\}$ / $\{P_4, P_5\}$. **b)** Donner le tableau de calcul et déterminer la droite des moindres carrés (valeurs exactes) ; contrôler $G \in D$. **c)** Calculer r et juger l'ajustement. **d)** Prévoir le rendement pour 700 mm, puis pour 1 500 mm, en qualifiant chaque prévision. **e)** Comparer les deux droites de a) et b).

Corrigé complet du sujet n°1

a) Point moyen. $\bar{x} = \frac{2+4+6+8+10}{5} = 6\,;\, \bar{y} = \frac{3+5+7+8+12}{5} = \frac{35}{5} = 7$: $G(6\,;7)$. **Mayer.** Groupe 1 : $G_1\left(\frac{2+4+6}{3}\,;\frac{3+5+7}{3}\right) = G_1(4\,;5)$; groupe 2 : $G_2\left(\frac{8+10}{2}\,;\frac{8+12}{2}\right) = G_2(9\,;10)$. Pente : $a_m = \dfrac{10-5}{9-4} = 1$; ordonnée via G : $b_m = 7 - 1 \times 6 = 1$. Droite de Mayer : $y = x + 1$.
b) Tableau et moindres carrés.

i	x_i	y_i	x_i^2	y_i^2	x_iy_i
1	2	3	4	9	6
2	4	5	16	25	20
3	6	7	36	49	42
4	8	8	64	64	64
5	10	12	100	144	120
Σ	30	35	220	291	252

Une transformation par ligne :

$$\operatorname{cov}(x\,;y)=\frac{252}{5}-6\times 7=50{,}4-42=8{,}4\ ;\qquad V(x)=\frac{220}{5}-36=8$$

$$a=\frac{8{,}4}{8}=1{,}05\ ;\qquad b=7-1{,}05\times 6=7-6{,}3=0{,}7$$

$D : y=1{,}05x+0{,}7$. **Contrôle :** $1{,}05\times 6+0{,}7=7=\bar{y}$ ✓
c) Coefficient r**.** $V(y)=\frac{291}{5}-49=58{,}2-49=9{,}2$; $\sigma_x=\sqrt{8}\approx 2{,}83$; $\sigma_y=\sqrt{9{,}2}\approx 3{,}03$; dénominateur $\sqrt{8\times 9{,}2}=\sqrt{73{,}6}\approx 8{,}58$. Donc

$$r=\frac{8{,}4}{8{,}58}\approx 0{,}98$$

Comme $|r|\approx 0{,}98\geq 0{,}9$, la corrélation est **très forte** et l'ajustement linéaire est **justifié** ; $r>0$: liaison **croissante**, cohérente avec le nuage et avec $a=1{,}05>0$.
d) Prévisions. Domaine observé : $x\in[2\,;10]$ (dm). Pour 700 mm = 7 dm (dedans) : $y=1{,}05\times 7+0{,}7=7{,}35+0{,}7=8{,}05$ — **interpolation** fiable : environ 8,05 t/ha. Pour 1 500 mm = 15 dm (dehors) : $y=1{,}05\times 15+0{,}7=15{,}75+0{,}7=16{,}45$ — **extrapolation risquée** : à une telle pluie, l'eau peut stagner et noyer le riz ; on annonce 16,45 t/ha avec cette réserve. ✓
e) Comparaison des droites. Mayer : $y=x+1$; moindres carrés : $y=1{,}05x+0{,}7$. Les deux passent par $G(6\,;7)$ ✓, mais leurs pentes diffèrent : Mayer **dépend du découpage choisi** (G_1 et G_2 changent si l'on coupe ailleurs), tandis que les moindres carrés sont **uniques** et optimaux au sens des carrés. À l'examen, la méthode de référence est celle des moindres carrés — Mayer sert d'approche ou de question intermédiaire. ✓

10.3 Sujet type BAC n°2 — les deux régressions (coton, Korhogo)

Sujet — superficie semée et récolte de coton

Dans cinq exploitations de la région de Korhogo, on relève la superficie semée x_i (en ha) et la quantité de coton récoltée y_i (en tonnes) : $(2\,;4)$, $(4\,;9)$, $(6\,;8)$, $(8\,;14)$, $(10\,;15)$. **a)** Calculer G, le tableau de calcul, puis la droite de régression de y en x ; contrôler $G\in D$. **b)** Calculer r et juger l'ajustement. **c)** Un conseiller agricole veut *estimer la superficie semée connaissant la récolte* : déterminer la droite de régression de x en y (valeurs exactes). **d)** Montrer que les deux droites passent par G, calculer $a\times a'$ et comparer à r^2. **e)** Estimer x pour $y=12$ avec la bonne droite, puis avec l'inverse de D : conclure. **f)** Pourquoi ne faut-il pas estimer x pour $y=40$?

Corrigé complet du sujet n°2

a) $\bar{x} = \frac{30}{5} = 6$; $\bar{y} = \frac{50}{5} = 10$: $G(6\,;10)$. Sommes : $\sum x_i^2 = 4+16+36+64+100 = 220$; $\sum y_i^2 = 16+81+64+196+225 = 582$; $\sum x_i y_i = 8+36+48+112+150 = 354$. Alors :

$$\operatorname{cov}(x\,;y) = \frac{354}{5} - 6\times 10 = 70{,}8 - 60 = 10{,}8 \ ; \qquad V(x) = \frac{220}{5} - 36 = 8$$

$$a = \frac{10{,}8}{8} = 1{,}35 \ ; \qquad b = 10 - 1{,}35\times 6 = 10 - 8{,}1 = 1{,}9$$

$D : y = 1{,}35x + 1{,}9$. **Contrôle :** $1{,}35\times 6 + 1{,}9 = 8{,}1 + 1{,}9 = 10 = \bar{y}$ ✓
b) $V(y) = \frac{582}{5} - 100 = 116{,}4 - 100 = 16{,}4$; $\sigma_x = \sqrt{8} \approx 2{,}83$; $\sigma_y = \sqrt{16{,}4} \approx 4{,}05$; dénominateur $\sqrt{8\times 16{,}4} = \sqrt{131{,}2} \approx 11{,}45$. Donc

$$r = \frac{10{,}8}{11{,}45} \approx 0{,}94$$

$|r| \approx 0{,}94 \geq 0{,}9$: corrélation **très forte**, ajustement **justifié** ; $r > 0$: liaison **croissante** (comme $a = 1{,}35 > 0$). *Contrôle de cohérence :* $r\,\sigma_y/\sigma_x \approx 0{,}94 \times \frac{4{,}05}{2{,}83} \approx 1{,}35$ ✓
c) Droite de régression de x en y — le conseiller *explique x par y* : on échange les rôles (le dénominateur devient $V(y)$) :

$$a' = \frac{\operatorname{cov}(x\,;y)}{V(y)} = \frac{10{,}8}{16{,}4} = \frac{27}{41} \approx 0{,}66 \ ;$$
$$b' = \bar{x} - a'\bar{y} = 6 - \frac{27}{41}\times 10 = \frac{246-270}{41} = -\frac{24}{41} \approx -0{,}59$$

$D' : x = \frac{27}{41}\,y - \frac{24}{41} \approx 0{,}66\,y - 0{,}59$ — on *exprime* x en fonction de y.
d) Les deux droites passent par G. Pour D : fait en a). Pour D' : $\frac{27}{41}\times 10 - \frac{24}{41} = \frac{246}{41} = 6 = \bar{x}$ ✓ — les deux équations sont vérifiées en $G(6\,;10)$, comme le veut la théorie (la preuve de la section 3 s'applique à chaque droite). **Produit des pentes :**

$$a\times a' = \frac{27}{20}\times\frac{27}{41} = \frac{729}{820} \approx 0{,}89 \qquad \text{et} \qquad r^2 = \frac{\operatorname{cov}^2}{V(x)\,V(y)} = \frac{10{,}8^2}{8\times 16{,}4} = \frac{729}{820}$$

Égalité **exacte** : $a\times a' = r^2$, et comme $r^2 \approx 0{,}89 \neq 1$, les deux droites sont **distinctes**.
e) Estimation pour $y = 12$ tonnes. Avec la **bonne** droite (D', car on estime x) :

$$x = \frac{27}{41}\times 12 - \frac{24}{41} = \frac{324-24}{41} = \frac{300}{41} \approx 7{,}3$$

Avec l'**inverse de D** (la mauvaise route) : $x = \frac{12-1{,}9}{1{,}35} = \frac{10{,}1}{1{,}35} \approx 7{,}5$. Les deux réponses diffèrent de 0,2 ha : l'inverse de D **n'est pas** la droite de régression de x en y (elles ne coïncident que si $r^2 = 1$). **Conclusion :** superficie estimée $\approx 7{,}3$ ha pour une récolte de 12 t — calculée avec D'. ✓
f) Pourquoi pas $y = 40$? Deux raisons : (1) le domaine observé est $y \in [4\,;15]$ — $y = 40$ est **très loin** dehors : c'est une extrapolation extrême, la tendance rectiligne n'est pas garantie ; (2) avec $r^2 \approx 0{,}89 \neq 1$, l'incertitude sur x croît d'autant plus qu'on s'éloigne des données. On refuse l'estimation, ou on la donne en précisant qu'elle est **sans valeur pratique**. ✓

10.4 Exercices d'application — solutions détaillées

Exercice 1 — Covariance et changement d'unité

Le fil rouge sorgho (Partie 2) donne $\text{cov}(x\,;y) = 10{,}4$ (x en dm, y en t/ha), $V(x) = 8$, $D : y = 1{,}3x + 2{,}2$. On exprime désormais le rendement en kg/ha : $y' = 1\,000\,y$. **a)** Calculer $\text{cov}(x\,;y')$ sans refaire le tableau. **b)** En déduire la nouvelle pente et la nouvelle ordonnée. **c)** Vérifier directement avec les sommes ($\sum x_i y'_i = 352\,000$, $\bar{y}' = 10\,000$).

Solution a. Par la propriété affine (section 4) : $\text{cov}(x\,;y') = 1\,000 \times 10{,}4 = 10\,400$ (dm×kg/ha).

Solution b. $a' = \dfrac{10\,400}{8} = 1\,300$ kg/ha par dm ; $b' = \bar{y}' - a'\bar{x} = 10\,000 - 1\,300 \times 6 = 2\,200$. La droite devient $y' = 1\,300x + 2\,200$ — c'est la même droite exprimée en kg (les points n'ont pas bougé).

Solution c. $\text{cov}(x\,;y') = \dfrac{352\,000}{5} - 6 \times 10\,000 = 70\,400 - 60\,000 = 10\,400$ ✓ — la propriété épargne tout le tableau. ✓

Exercice 2 — Mini ajustement exponentiel (la variante ln)

Une population de graines germées double approximativement : pour $x = 1, 2, 3, 4$ jours, $y = 8\,;\ 12\,;\ 18\,;\ 27$ (en centaines). **a)** Quel changement de variable s'impose ? **b)** Montrer que les points $(x\,;Z)$ sont exactement alignés sur $Z = (\ln 1{,}5)\,x + \ln\frac{16}{3}$. **c)** En déduire le modèle et prévoir y pour $x = 5$.

Solution a. Les rapports valent $\frac{12}{8} = \frac{18}{12} = \frac{27}{18} = 1{,}5$: croissance **multiplicative** à taux constant → poser $Z = \ln y$.

Solution b. Chaque $y_i = 8 \times 1{,}5^{\,x_i - 1}$ (vérification : 8, 12, 18, 27 ✓), donc

$$Z_i = \ln y_i = \ln 8 + (x_i - 1)\ln 1{,}5 = (\ln 1{,}5)\,x_i + (\ln 8 - \ln 1{,}5) = (\ln 1{,}5)\,x_i + \ln\tfrac{16}{3}$$

Les points $(x_i\,;Z_i)$ sont **exactement** sur la droite annoncée ($r = 1$). ✓

Solution c. En revenant à y : $y = \mathrm{e}^{\ln(16/3)} \times \mathrm{e}^{x\ln 1{,}5} = \dfrac{16}{3} \times 1{,}5^{\,x}$. Contrôle : $y(4) = \frac{16}{3} \times 5{,}0625 = 27$ ✓. Prévision pour $x = 5$: $y = \frac{16}{3} \times 7{,}59375 = 40{,}5$ centaines — **extrapolation** (le doublement ne peut pas durer indéfiniment). ✓

Exercice 3 — $S_{\min}$, résidus et r^2 sur les données du mil

La droite $D : y = \frac{83}{28}x - 345$ ajuste les données du mil ($n = 6$, $V(y) = 50\,400$, $r = \frac{83}{84}$). **a)** Calculer les six résidus et vérifier que leur somme est nulle. **b)** Calculer $S_{\min}$ de deux façons et conclure.

Solution a. Résidu $e_i = y_i - \left(\frac{83}{28}x_i - 345\right)$; par exemple pour 2019 : $660 - \frac{83}{28} \times 320 + 345 = 1\,005 - \frac{6\,640}{7} = \dfrac{395}{7}$. De même, dans l'ordre :

$$\frac{395}{7}\,;\quad -\frac{440}{7}\,;\quad -\frac{5}{7}\,;\quad \frac{5}{7}\,;\quad \frac{20}{7}\,;\quad \frac{25}{7} \quad \text{et} \quad \frac{395 - 440 - 5 + 5 + 20 + 25}{7} = \frac{0}{7} = 0\ \checkmark$$

La somme des résidus est **exactement nulle** — la droite équilibre le nuage (section 3).

Solution b. Première façon : $S_{\min} = \sum e_i^2 = \dfrac{395^2 + 440^2 + 5^2 + 5^2 + 20^2 + 25^2}{49} = \dfrac{350\,700}{49} = \dfrac{50\,100}{7} \approx 7\,157$ (kg/ha)^2. Seconde façon : $S_{\min} = n\,V(y)\,(1 - r^2) = 6 \times 50\,400 \times \left(1 - \frac{6\,889}{7\,056}\right) = 302\,400 \times \frac{167}{7\,056} = \dfrac{50\,100}{7}$ ✓ — les deux routes tombent sur la même valeur, et $r^2 = \frac{6\,889}{7\,056} \approx 0{,}976$: la droite explique $\approx 98\,\%$ de la variance des rendements. ✓

Exercice 4 (corsé) — Démonstration guidée : alignement $\Rightarrow r = \pm 1$

a) Montrer que si tous les points sont exactement sur la droite $y = px + q$ ($p \neq 0$), alors $\text{cov}(x\,;y) = p\,V(x)$, $V(y) = p^2 V(x)$ et $r = \dfrac{p}{|p|}$. **b)** Appliquer aux points $(0\,;1)$, $(1\,;4)$, $(2\,;7)$ et conclure.

Solution a. Si $y_i = px_i + q$ pour tout i, alors $\bar{y} = p\bar{x} + q$ (linéarité de la moyenne), donc $y_i - \bar{y} = p(x_i - \bar{x})$. Alors, une ligne par calcul :

$$\text{cov}(x\,;y) = \frac{1}{n}\sum (x_i - \bar{x}) \cdot p(x_i - \bar{x}) = p\,V(x) \;\; ; \qquad V(y) = \frac{1}{n}\sum p^2 (x_i - \bar{x})^2 = p^2\,V(x)$$

Donc $\sigma_y = |p|\,\sigma_x$ (la racine carrée de p^2 est $|p|$!), et

$$r = \frac{p\,V(x)}{\sigma_x \times |p|\,\sigma_x} = \frac{p}{|p|} = \begin{cases} 1 & \text{si } p > 0 \\ -1 & \text{si } p < 0 \end{cases} \qquad \blacksquare$$

Le piège de la ligne finale : oublier la valeur absolue et écrire $r = p\,V(x)/(p\,\sigma_x^2) = 1$ *toujours* — faux pour une droite décroissante ($p < 0$ donne $r = -1$).

Solution b. Les points vérifient $y = 3x + 1$ exactement ($3 \times 0 + 1 = 1$, etc.), donc $p = 3 > 0$ et la théorie prédit $r = 1$. Vérification complète : $\bar{x} = 1$, $\bar{y} = 4$; $\sum x_i^2 = 5$, $\sum y_i^2 = 66$, $\sum x_i y_i = 18$; $\text{cov} = \frac{18}{3} - 4 = 2$; $V(x) = \frac{5}{3} - 1 = \frac{2}{3}$; $V(y) = 22 - 16 = 6$;

$$r = \frac{2}{\sqrt{2/3}\,\sqrt{6}} = \frac{2}{\sqrt{4}} = 1 \;\checkmark \qquad (\text{et } a = \tfrac{2}{2/3} = 3,\ b = 4 - 3 = 1 : \text{la droite des moindres carrés retrouve } y = 3x + 1).$$

QCM : 1-b 2-a 3-b 4-b 5-b 6-b

ASTUCE — La carte mentale de la partie 4

Toute la partie tient dans trois idées : (1) **tout se prouve** — la pente $a = \text{cov}/V(x)$ sort du système 2×2 des équations normales, le passage par G sort de $b = \bar{y} - a\bar{x}$, la borne $|r| \leq 1$ sort de $S_{\min} = nV(y)(1 - r^2) \geq 0$; (2) **tout se contrôle** — $G \in D$, somme des résidus nulle, signe de r = signe de a, $a \times a' = r^2$; (3) **tout se qualifie** — ajustement justifié ou non ($|r|$), interpolation ou extrapolation (position de x), modèle droit, $\sqrt{\ }$ ou ln (allure du nuage). La Partie 5 condense le chapitre entier en une fiche de révision unique.

11. Table de synthèse de la partie 4

Objet	Formule / règle	Ce qu'il faut retenir
Chaîne de l'étude	nuage $\to G \to$ variances, cov $\to D \to r \to$ jugement $\to$ prévision	l'ordre des calculs du BAC ; un seul tableau sert à tout
Démonstration des moindres carrés	dériver $S(a,b)$ selon b puis a, résoudre le système 2×2	$\alpha > 0$ justifie le minimum ; donne a et b sans magie
Pente et ordonnée	$a = \dfrac{\operatorname{cov}(x\,;y)}{V(x)}$, $b = \bar{y} - a\bar{x}$	valables si $V(x) > 0$ (x_i non tous égaux)
Passage par G	$a\bar{x} + b = \bar{y}$ (preuve par substitution)	contrôle n°1 ; vrai pour toute pente — pas un certificat de qualité
Forme centrée	$y - \bar{y} = a(x - \bar{x})$	prédire sans calculer b ; garde G sous les yeux
Somme des résidus	$\sum(y_i - ax_i - b) = 0$	la droite équilibre le nuage ; contrôle gratuit
Covariance	$\operatorname{cov} = \frac{\sum n_i x_i y_i}{N} - \bar{x}\bar{y} = E(XY) - E(X)E(Y)$	unités de $x \times y$; $\operatorname{cov}(x\,;x) = V(x)$; symétrique
Effet affine	$\operatorname{cov}(x\,;\alpha y + \beta) = \alpha \operatorname{cov}(x\,;y)$	changer l'unité de y multiplie la pente par α
cov nulle	cov $= 0 \neq$ « aucune liaison »	parabole parfaite : cov $= 0$, liaison courbe intacte
Coefficient r	$r = \dfrac{\operatorname{cov}}{\sigma_x\,\sigma_y}$; $-1 \le r \le 1$	nombre pur ; $r = \pm 1$ si nuage aligné (démontré) ; borne intuitive par $S_{\min} = nV(y)(1-r^2) \ge 0$
Seuils	$\lvert r\rvert \ge 0{,}9$ très forte ; 0,7/0,5 décroissance	$\lvert r\rvert < 0{,}5$: ne pas prédire ; sens sur le signe
Deux régressions	$a' = \dfrac{\operatorname{cov}}{V(y)}$, $b' = \bar{x} - a'\bar{y}$; $a \times a' = r^2$	estimer x connaissant y : utiliser D', jamais l'inverse de D ; coïncidence ssi $\lvert r\rvert = 1$
Changement de variable	$z = \ln y \to y = \mathrm{e}^b \mathrm{e}^{ax}$; $z = \sqrt{y} \to y = (ax+b)^2$	ajuster z en fonction de x, puis revenir à y ; diagnostic : rapports constants ou différences croissantes
Contrôles réflexes	$\sum n_i = N$; $\sum f_i = 1$; $\sum n_i(x_i - \bar{x}) = 0$; $G \in D$; $-1 \le r \le 1$; signes	cinq secondes chacun, avant de rendre copie
Étude du mil (Niamey)	$G(420\,;900)$; $D : y = \frac{83}{28}x - 345$; $r = \frac{83}{84} \approx 0{,}99$	$y(480) \approx 1\,078$ kg/ha (interpolation) ; $y(700) = 1\,730$ (extrapolation risquée) ; $a \approx 2{,}96$ kg/ha par mm
Sujets BAC de la partie	riz : $y = 1{,}05x + 0{,}7$, $r \approx 0{,}98$; coton : $a' = \frac{27}{41}$, $a \times a' = \frac{729}{820} = r^2$	à refaire sans regarder les corrigés

ASTUCE — Le chapitre est complet — la révision finale en trois tours

Premier tour : relis les tables de synthèse des Parties 1 à 4 en récitant chaque formule. **Deuxième tour :** refais sans corriger l'étude du mil (section 7) puis les deux sujets BAC (section 10), en chronométrant — visons 45 minutes pour l'ensemble. **Troisième tour :** déroule les sept contrôles réflexes sur tes propres copies. Les valeurs ont été choisies pour que chaque calcul « tombe » : si le tien ne tombe pas, c'est la méthode qu'il faut corriger — pas la calculatrice.